ИТМО

Состязательные примеры

Состязательные примеры

ИТМО

1. Введение

2. Состязательные атаки

3. FGSM и T-FGSM

4. I-FGSM

5. FGSM vs I-FGSM

6.RayS

7. Метрики

8. Выводы

Введение

(x, y)

x - объект (картинка)

y - истинная метка

f - модель

$f(x) = y$

$\tilde{x} : \tilde{x} \approx x, f(\tilde{x}) \neq y$

Введение

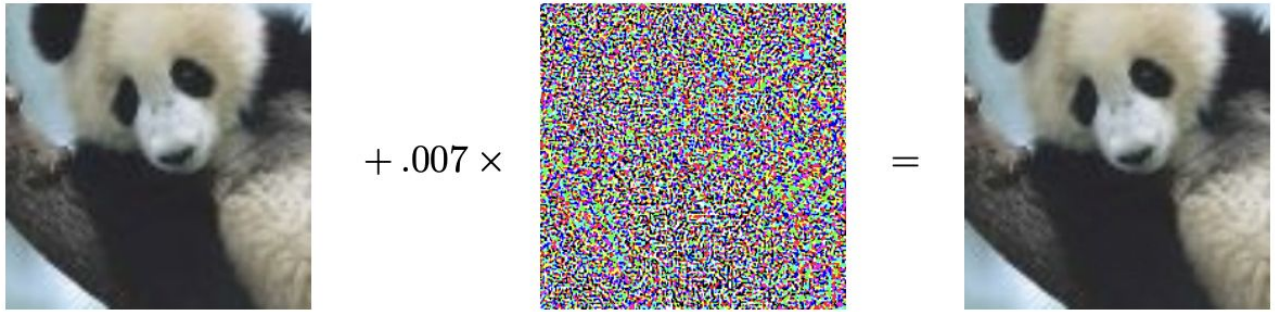

$+ .007 \times$ $=$

$\boldsymbol{x}$

“panda”
57.7% confidence

$\text{sign}(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y))$

“nematode”
8.2% confidence

$\boldsymbol{x} + \epsilon\text{sign}(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y))$

“gibbon”
99.3 % confidence

*__Explaining and Harnessing Adversarial Examples__ Ian Goodfellow, Jonathon Shlens, Christian Szegedy 2014 arXiv: 1412.6572

Состязательные атаки

ИТМО

Алгоритмы $\tilde{x}$:

- white box: атакующий знает параметры θ
- black box: у атакующего есть доступ только к оракулу

Типы атак:

- untargeted: $f(\tilde{x}) \neq y$
- targeted: $f(\tilde{x}) = t$

*__Towards Evaluating the Robustness of Neural Networks__ Carlini & Wagner, 2017 arXiv: 1608.04644

FGSM

Fast Gradient Sign Method:

- White box
- Градиентная атака
- Одношаговая атака
- Обычно untargeted(**цель – вызвать ошибку классификации**)

Идея: линейная аппроксимация функции потерь
Плюсы: быстро
Минусы: слабее итеративных атак

*__Explaining and Harnessing Adversarial Examples__ Ian Goodfellow, Jonathon Shlens, Christian Szegedy 2014 arXiv: 1412.6572

FGSM

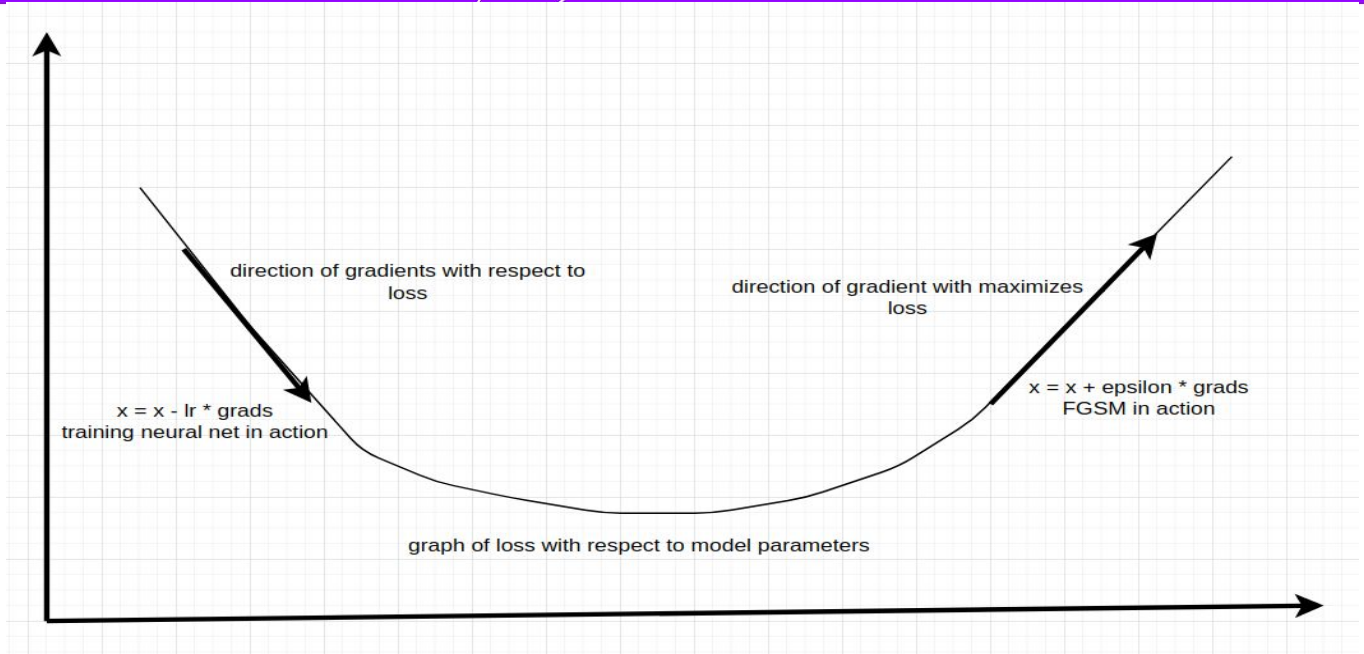

*https://neptune.ai/blog/adversarial-attacks-on-neural-networks-exploring-the-fast-gradient-sign-method

FGSM

$x_{adv} = x + \varepsilon \times sign(\nabla_x \ell(f(x), y))$ - FGSM

- $\max \ell(f(x + \delta), y)$
- $||\delta||_\infty \leq \varepsilon$

$x_{adv} = x - \varepsilon \times sign(\nabla_x \ell(f(x), t))$ - T-FGSM

- $\min \ell(f(x + \delta), t)$
- $||\delta||_\infty \leq \varepsilon$

x - исходное изображение
x_{adv} - состязательный пример
y - истинная метка
t - целевой класс
ε - величина изменения входа (допустимый предел)
ℓ - функция потерь
δ - модификация изображения (конкретное изменения входа)

$||\delta||_\infty \leq \varepsilon$

- Ни один пиксель не изменится больше чем на ε
- Изменение остается малозаметным

*__Explaining and Harnessing Adversarial Examples__ Ian Goodfellow, Jonathon Shlens, Christian Szegedy 2014 arXiv: 1412.6572

I-FGSM

Fast Gradient Sign Method:

- White box
- Градиентная атака
- **Итеративная атака**
- Обычно untargeted

$$x^{k+1} = min(max(x^k + \alpha \times sign(\nabla_x \ell) , x - \varepsilon), x + \varepsilon))$$

- $\max\limits_{||\delta||_\infty \le \varepsilon} \ell(f(x + \delta), y)$

***Adversarial Examples in the Physical World** Alexey Kurakin, Ian Goodfellow, Samy Bengio 2016 arXiv: 1607.02533

FGSM vs I-FGSM

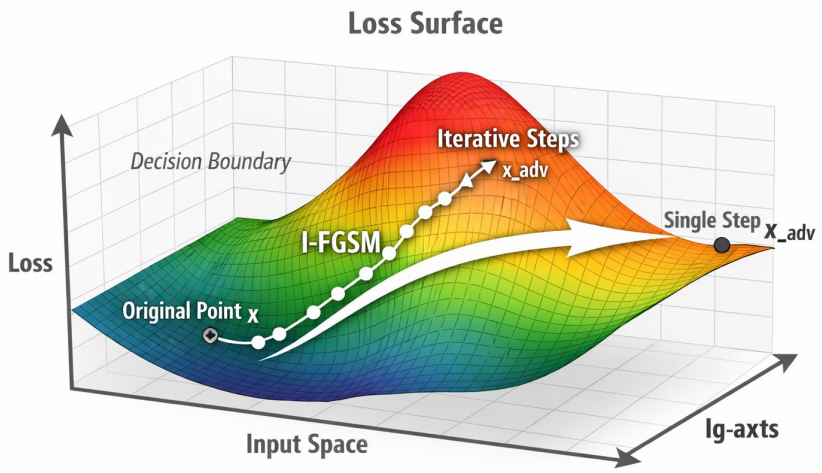

I-FGSM: Iterative path vs. FGSM: Single step.

FGSM: одно обновление на основе знака градиента — вычислительно эффективно, но менее точно.

I-FGSM: итеративные градиентные обновления — требует больше вычислений, но обычно приводит к более сильным атакам.

RayS

1. Выбор направления: $d \in \{-1, +1\}^n$
2. Движение вдоль направления: $x_{adv} = x + r \cdot d$
3. С помощью бинарного поиска найти: $f(x + r\,d) \neq y$

Цель: найти минимальное изменение входа, которое переводит пример за границу принятия решения модели

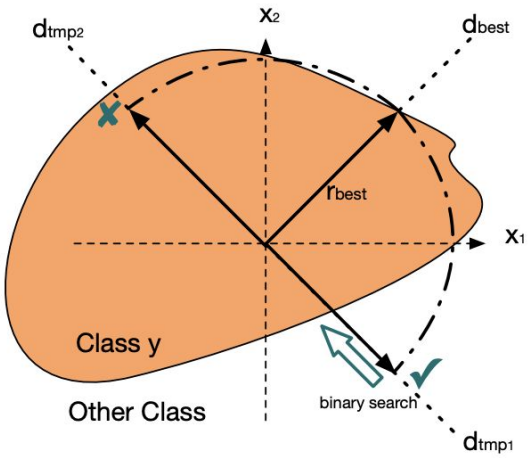

*J. Chen and Q. Gu, **“Rays: A ray searching method for hard-label adversarial attack,”** in Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2020, pp. 1739–1747

Метрики

- ASR: *кол - во успешных атак / число примеров*
- Robust Accuracy: *кол-во правильных* x_{adv} */ общее число*
- Distortion: $||\delta||$ *– показывает на сколько сильно изменилось изображение*
- Minimal Perturbation: $\min||\delta||$, $f(x + \delta) \neq y$
- Loss under attack: $\ell(f(x_{adv}), y)$

Спасибо
за внимание!

ITsMOre than a UNIVERSITY