Visual Language Models

Козьма А. П., M4145

Введение

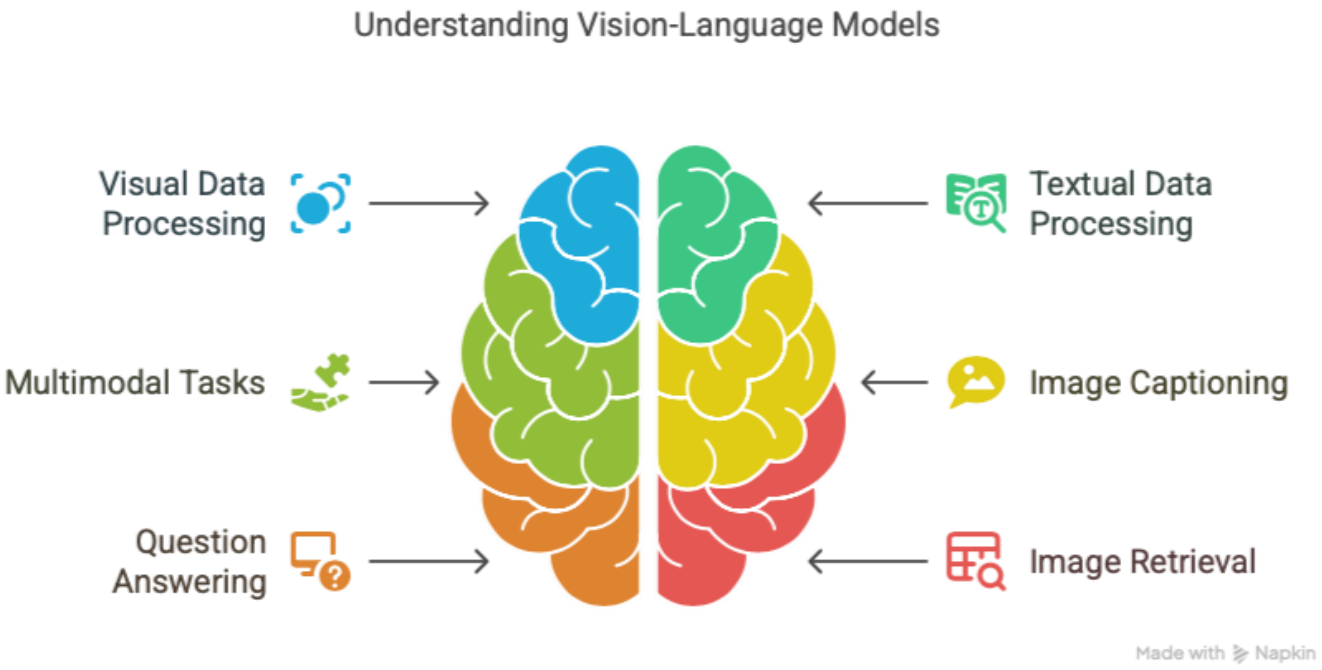
Understanding Vision-Language Models
Visual Data Processing
Textual Data Processing
Multimodal Tasks
Image Captioning
Question Answering
Image Retrieval
Made with Napkin

Что такое VLM

Визуально-лингвистические модели работают сразу с двумя модальностями — картинкой и текстом. На вход такие системы получают изображение, подпись либо их сочетание, а на выходе выдают осмысленный текст или составной (мультимодальный) ответ.

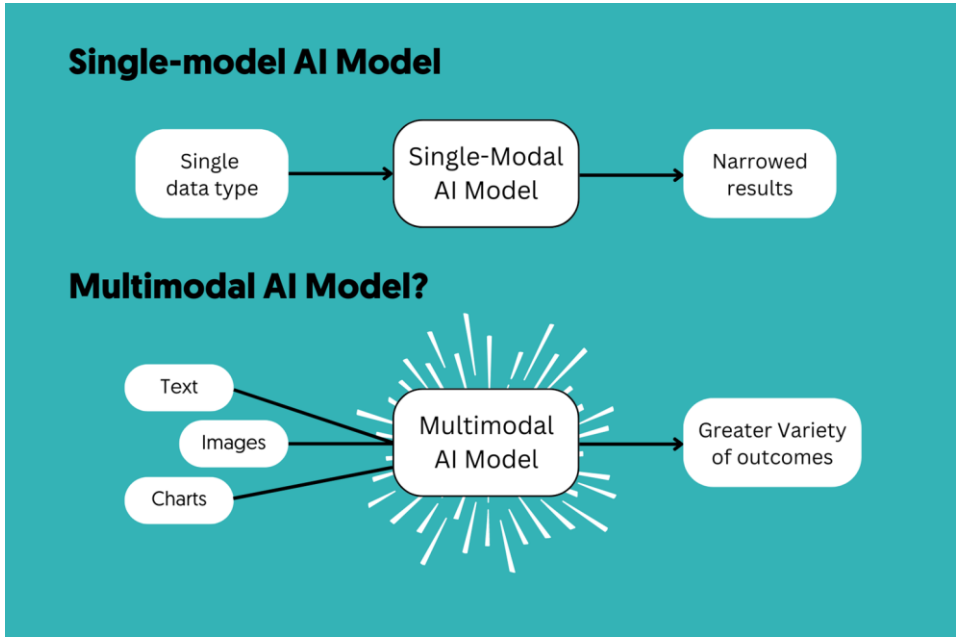

Как устроены VLM

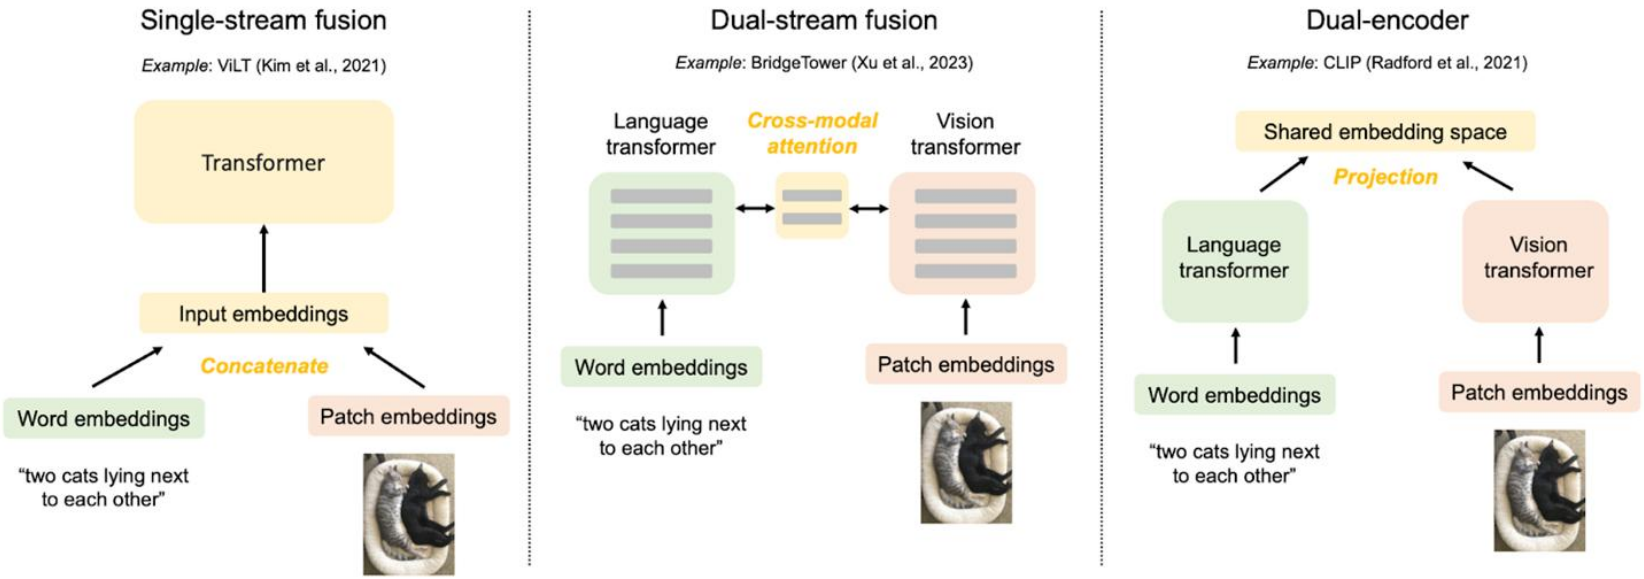

Эволюция архитектур

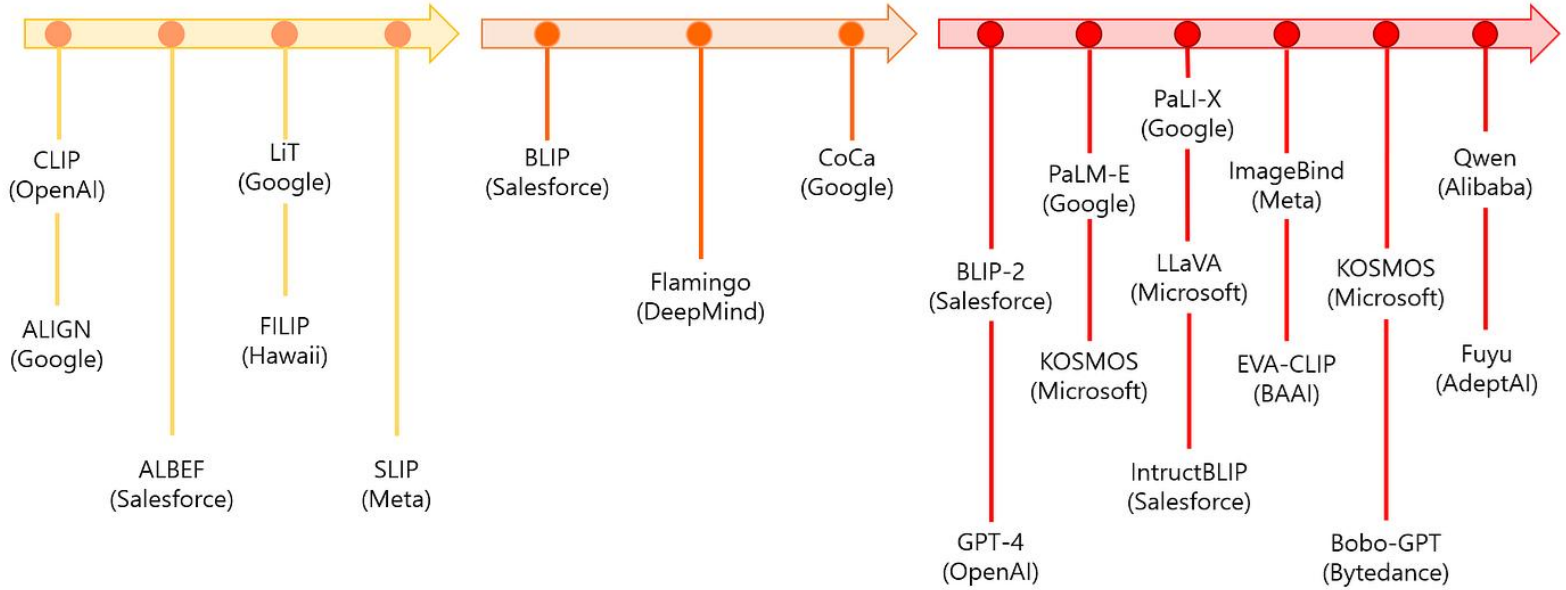

CLIP

```
Detected objects: ['dog', 'cat']
All prompts: ['A dog and cat sitting quietly in a room', 'A calm scene with dog and cat doing nothing', 'A dog and cat resting peace
fully', 'A dog and cat standing still outdoors', 'A dog and cat running around wildly', 'A busy scene with dog and cat interacting',
'A dog and cat happy and excited', 'A dog and cat sleeping under a tree', 'A dog and cat eating food together', 'A dog and cat watch
ing something intently', 'A dog and cat surfing on waves', 'A dog and cat flying in the sky', 'A dog and cat performing tricks', 'A
dog and cat climbing a hill', 'A dog and cat swimming in a poolA dog and cat sitting side by sideA dog and cat sitting calmly', 'A c
haotic scene', 'An empty area']
Similarity scores: [[  0.0010166    0.011627  0.00095463    0.035278    0.040588     0.13525     0.55176  2.3842e-07    0.015656
0.095886  7.2479e-05   0.0020218    0.074646  0.00022328    0.032104   0.0029869  3.7014e-05]]
```

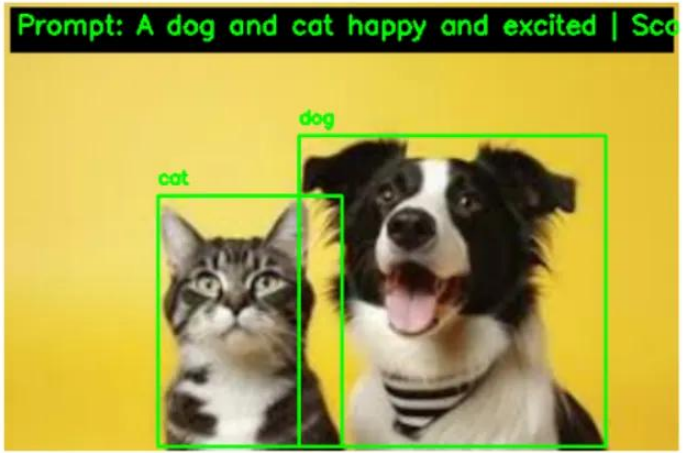

CLIP = сопоставление, а не reasoning

Ограничение: нет объяснения

```
Best match: 'A dog and cat happy and excited' (Score: 0.55), Objects: ['dog', 'cat']
```

Flamingo

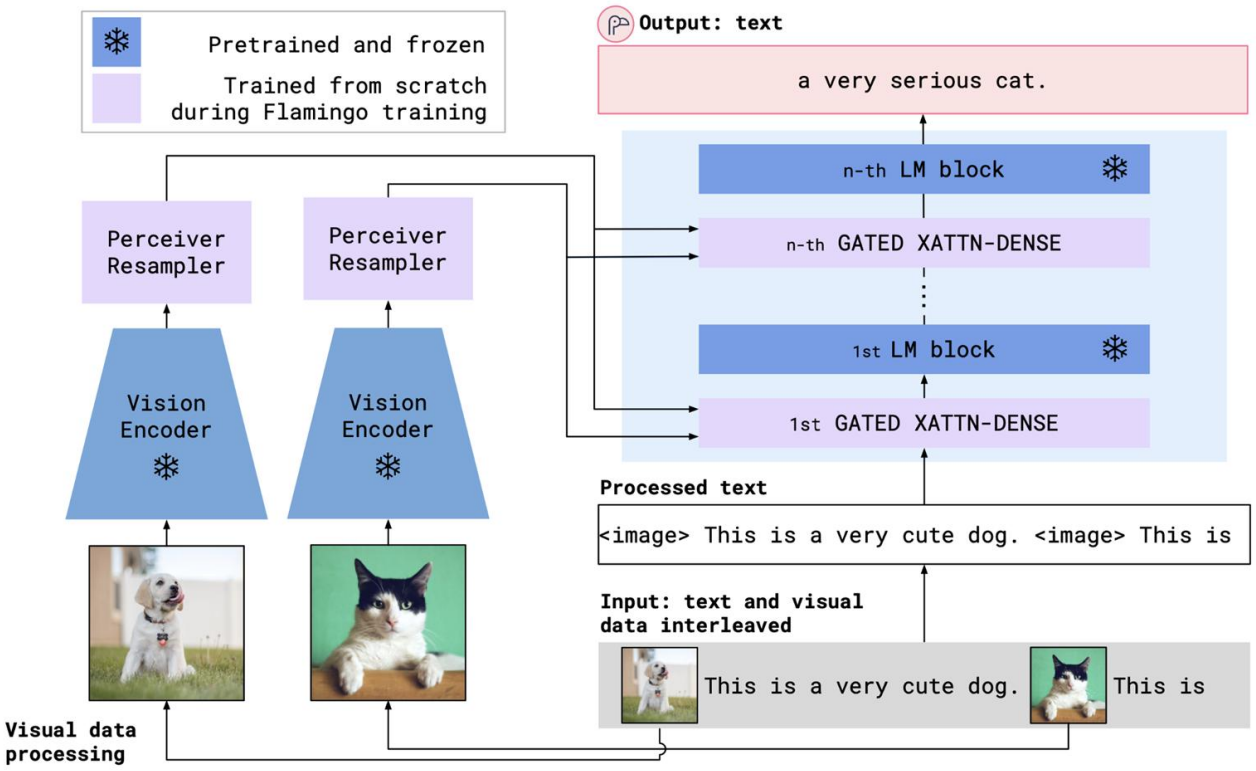
Pretrained and frozen
Trained from scratch during Flamingo training
Output: text
a very serious cat.
n-th LM block
n-th GATED XATTN-DENSE
1st LM block
1st GATED XATTN-DENSE
Perceiver Resampler
Perceiver Resampler
Vision Encoder
Vision Encoder
Processed text
<image> This is a very cute dog. <image> This is
Input: text and visual data interleaved
This is a very cute dog.
This is
Visual data processing

Flamingo

Single Image Samples

Input Prompt	Question: What do you think the capacities of these are? Answer:	Question: What is odd about this image? Explain why it is unusual. Answer:	Question: What country is this? Why do you think so? Answer:
Completion	**The floppy disk is 1.44MB and the CD is 700MB.**	**The image is odd because the elephant is in the back of the truck. It is unusual because elephants are not usually transported in the back of a truck.**	**It is Canada. I think so because the flag is the Canadian flag.**

BLIP-2

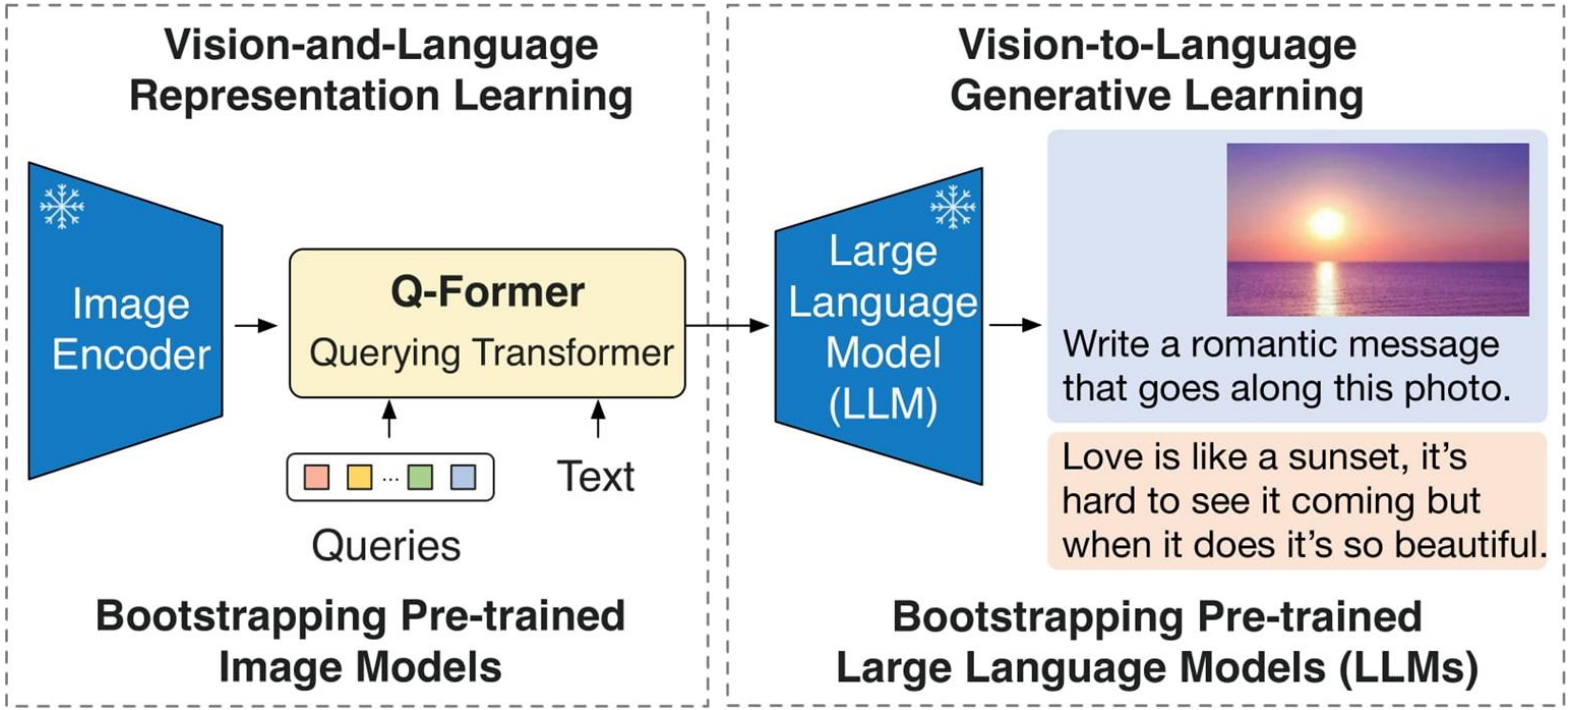
Vision-and-Language
Representation Learning
Image
Encoder
Q-Former
Querying Transformer
Text
Queries
Bootstrapping Pre-trained
Image Models
Vision-to-Language
Generative Learning
Large
Language
Model
(LLM)
Write a romantic message
that goes along this photo.
Love is like a sunset, it's
hard to see it coming but
when it does it's so beautiful.
Bootstrapping Pre-trained
Large Language Models (LLMs)

LLaVA

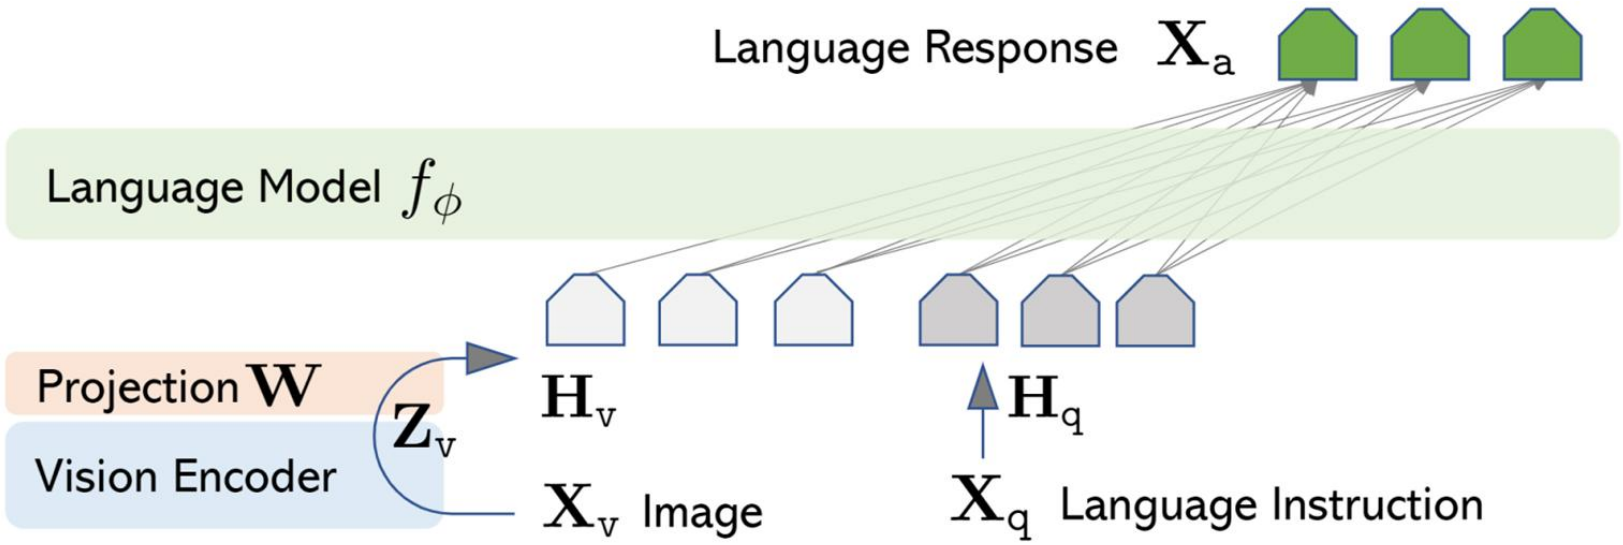
Language Response $\mathbf{X}_a$
Language Model f_ϕ
Projection $\mathbf{W}$
Vision Encoder
$\mathbf{Z}_v$
$\mathbf{H}_v$
$\mathbf{H}_q$
$\mathbf{X}_v$ Image
$\mathbf{X}_q$ Language Instruction

Qwen-VL

Unified token processing

Text + Visual tokens -> одна последовательность

Dynamic resolution + grounding

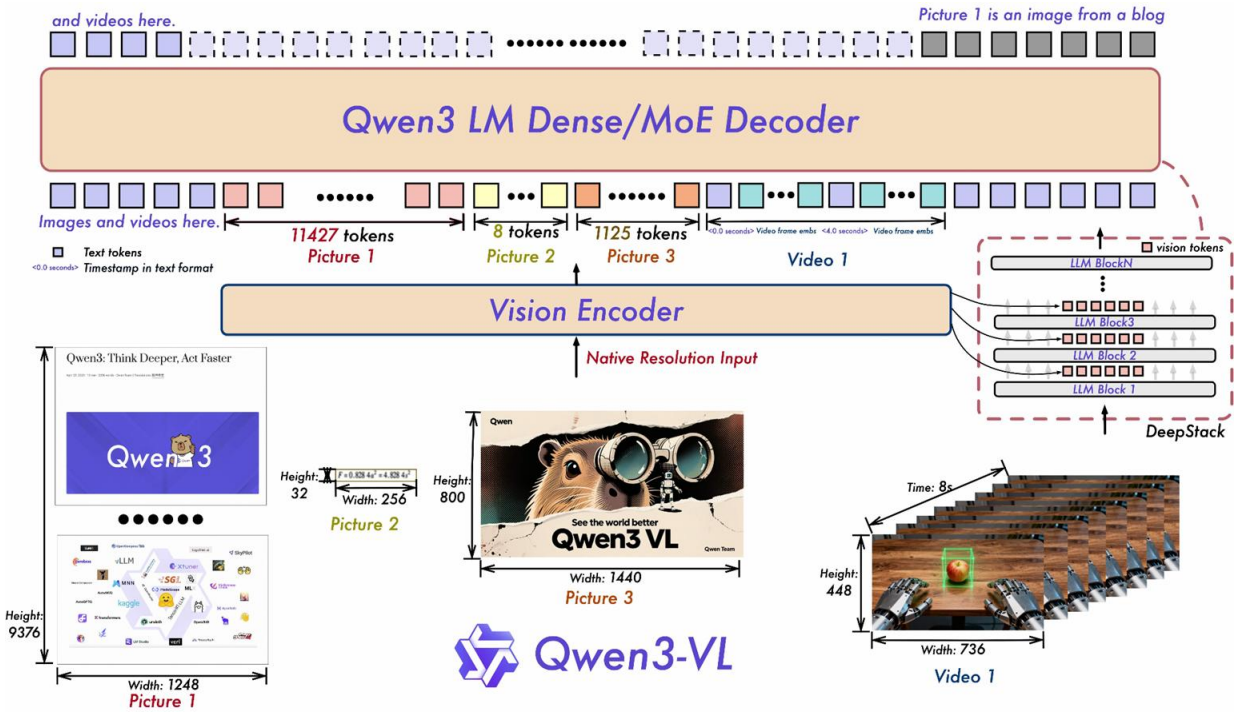

Qwen-VL

SOTA зависит от задачи
Разные бенчмарки -> разные лидеры

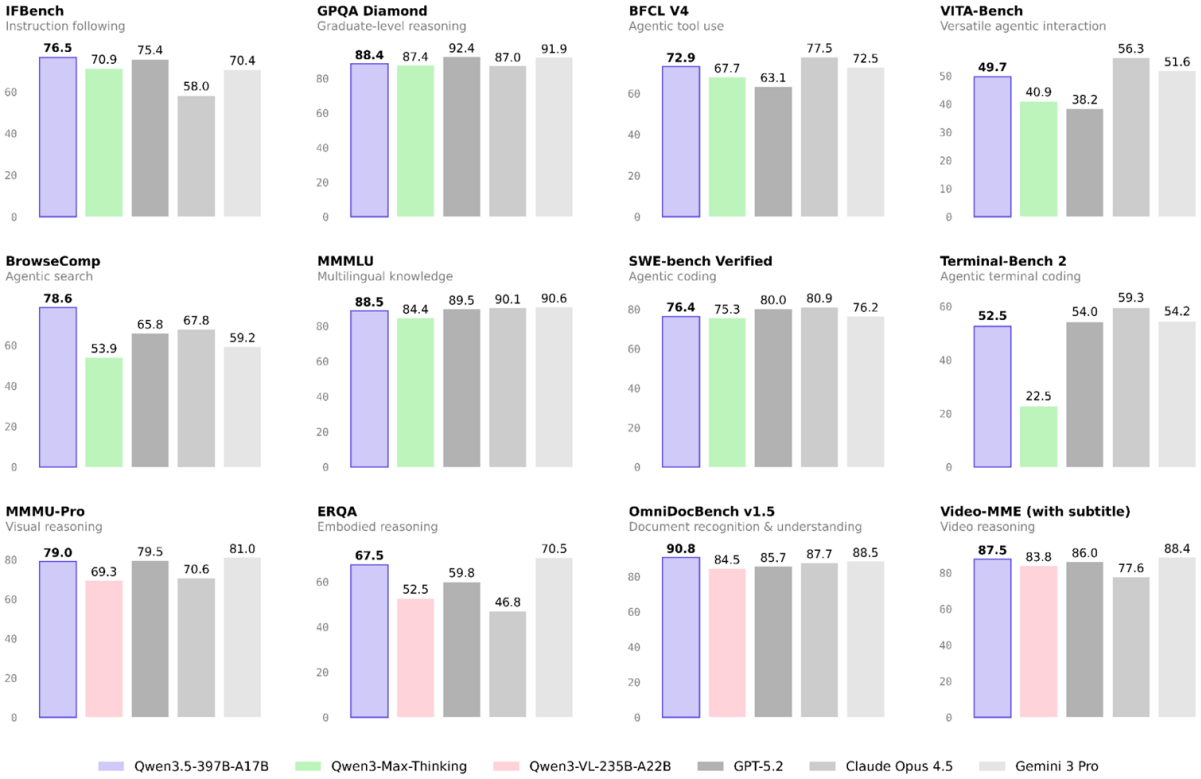

Современные VLM

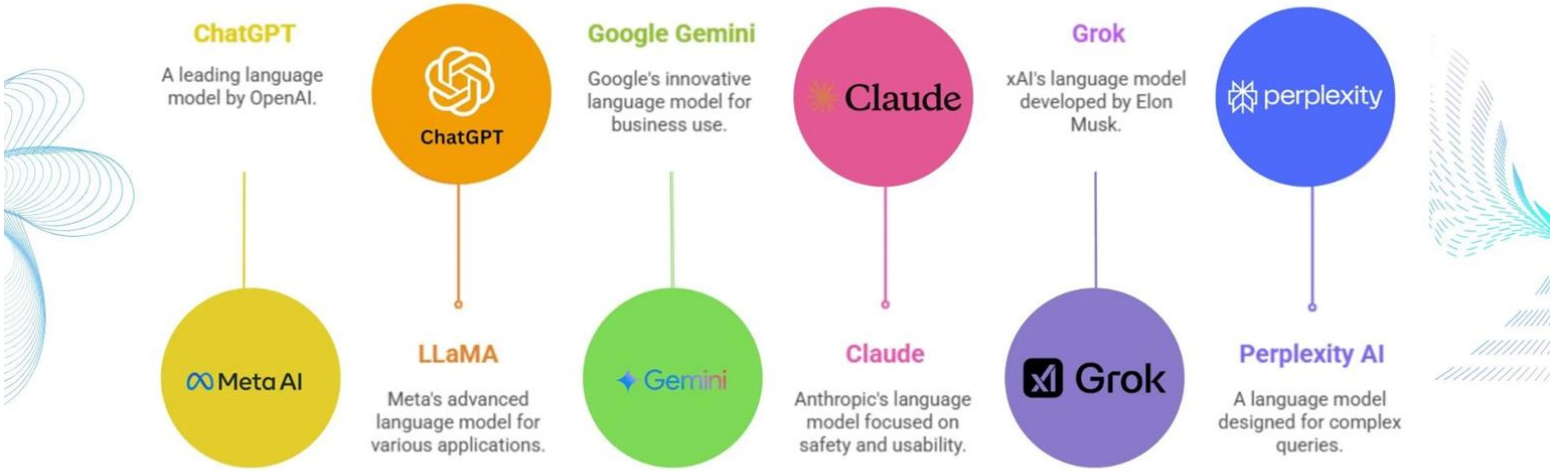

SOTA

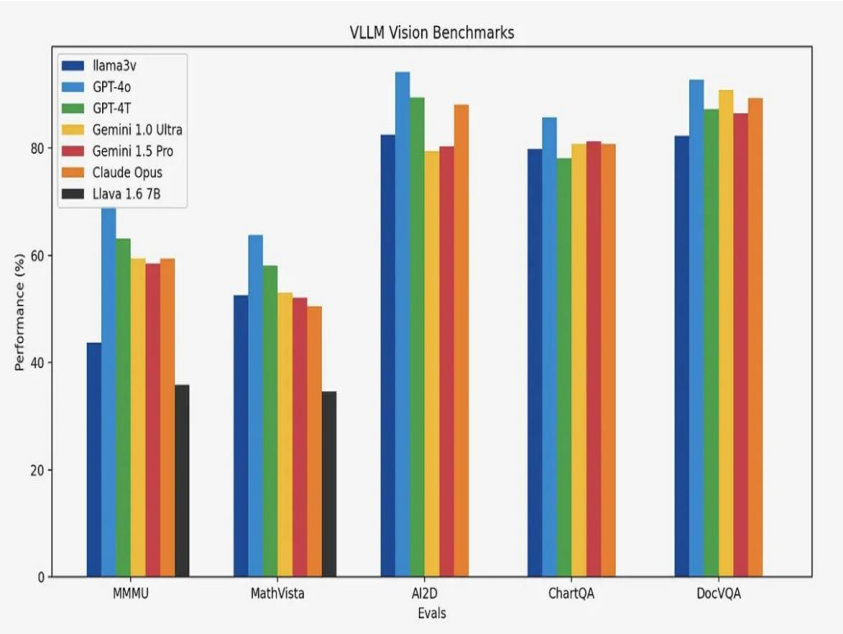

Среди закрытых систем лидируют GPT, Claude и Gemini.

В открытом сегменте сильные результаты показывают Qwen-VL, DeepSeek-VL и LLaVA.

Для локального использования доступны версии LLaVA-7B/13B, Qwen-VL-7B и DeepSeek-VL-7B, уступающие по масштабу, но сохраняющие архитектурные преимущества и гибкость.

Long-context

Длинные мультимодальные последовательности
Ключевая проблема — удержание контекста

Long-context LLM vs. RAG

Long-context LLM	RAG
✓ Quick retrieval	✓ Useful for complex tasks
✓ Easier to use	✓ Resource-friendly
✓ Handy for simple tasks	✓ Easier to debug/evaluate
	✓ Up-to-date
	✓ Strategically handles information

Почему VLM до сих пор ошибаются

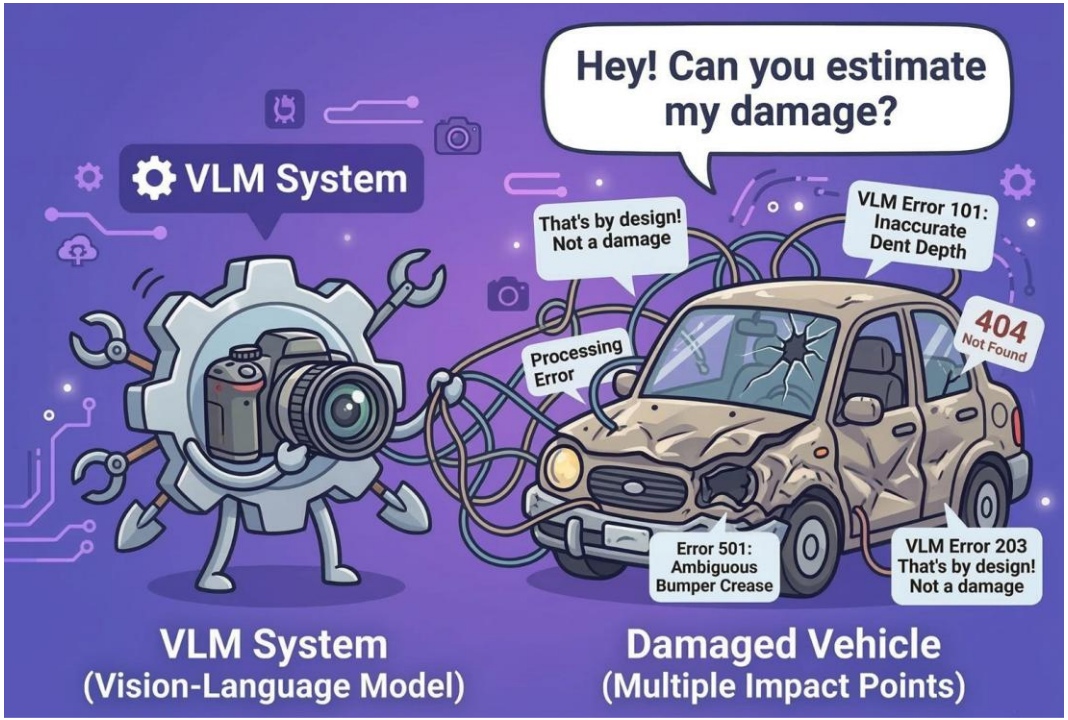

Выводы

Современные vision-language модели прошли путь от простого сопоставления изображений и текста к системам, способным выполнять сложное мультимодальное рассуждение.

Ключевым архитектурным сдвигом стало использование LLM как ядра, в которое интегрируются визуальные токены, что позволяет обрабатывать разные модальности в едином пространстве представлений.

При этом эффективность таких систем определяется не только архитектурой, но и качеством соединения модальностей, а также обучающими данными и alignment-процедурами.

Несмотря на значительный прогресс, VLM все еще сталкиваются с проблемами галлюцинаций, слабого grounding и работы с длинным контекстом, что указывает на то, что задача полноценной интеграции визуального восприятия и языкового мышления остается открытой.

Источники

1) Radford A. et al. Learning transferable visual models from natural language supervision //International conference on machine learning. – PmLR, 2021. – С. 8748-8763.
2) Alayrac J. B. et al. Flamingo: a visual language model for few-shot learning //Advances in neural information processing systems. – 2022. – Т. 35. – С. 23716-23736.
3) Li J. et al. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models //International conference on machine learning. – PMLR, 2023. – С. 19730-19742.
4) Liu H. et al. Visual instruction tuning //Advances in neural information processing systems. – 2023. – Т. 36. – С. 34892-34916.
5) Bai S. et al. Qwen3-vl technical report //arXiv preprint arXiv:2511.21631. – 2025.
6) Vision Language Models Explained https://huggingface.co/blog/vlms
7) Understanding vision language models and their applications https://www.ultralytics.com/blog/understanding-vision-language-models-and-their-applications

Спасибо за внимание