Генерация видео

Sora

Хайруллин Артур M3434

О генерации видео

Сложная задача:

- Большой размер данных
- Temporal consistency
- Десятки и сотни кадров
- Движения должны выглядеть правдоподобно
- Кадры зависимы друг от друга
- Видео 512x512 с 24 кадрами - ~6 млн. пикселей

144-frame video
(768 x 768)

Даже сейчас некоторые сгенерированные видео выглядят физически далеко не правдоподобно

История генеративных моделей для видео

- Первые работы примерно в 2016-2018гг. - GAN
- Авторегрессионные модели для генерации последовательности кадров.
- Стабильное качество - диффузионные модели.

Pouring Coffee into Coffee Cup

Aluminum cans on conveyor belt

Star Time Lapse in Japan

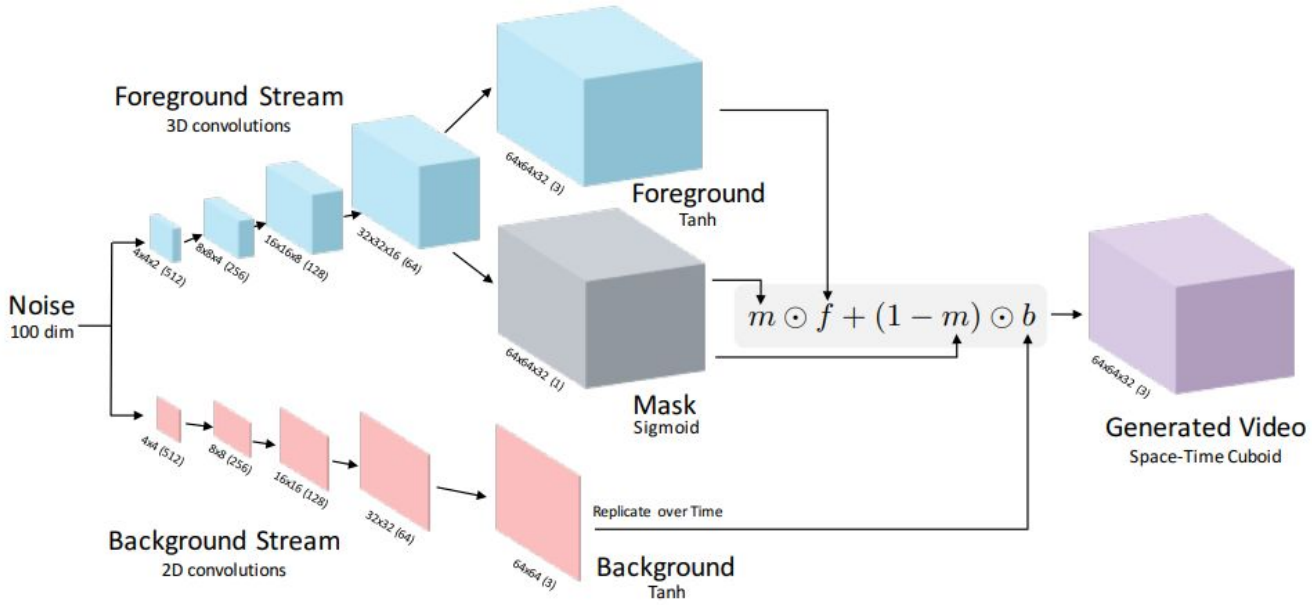

Video Generator Network (2016)

preview

Генерация коротких видео (32 кадра 64x64) на основе неразмеченных (Flickr), также дообучение на UCF101 для human action recognition

Двухпотоковый генератор:

- Foreground - 3D свертки
- Background - 2D свертки
- Маска - ЧБ видео

Дискриминатор состоит из 3D сверток

	Percentage of Trials				
"Which video is more realistic?"	Golf	Beach	Train	Baby	Mean
Random Preference	50	50	50	50	50
Prefer VGAN Two Stream over Autoencoder	88	83	87	71	82
Prefer VGAN One Stream over Autoencoder	85	88	85	73	82
Prefer VGAN Two Stream over VGAN One Stream	55	58	47	52	53
Prefer VGAN Two Stream over Real	21	23	23	6	18
Prefer VGAN One Stream over Real	17	21	19	8	16
Prefer Autoencoder over Real	4	2	4	2	3

Frame-by-frame генерация

1. Взять text2image модель
2. Генерировать каждый кадр отдельно
3. Объединить кадры в видео

Проблемы: flickering

[Text2Video-Zero (2023)](#)
последовательная генерация кадров с cross-attention

[preview](#)

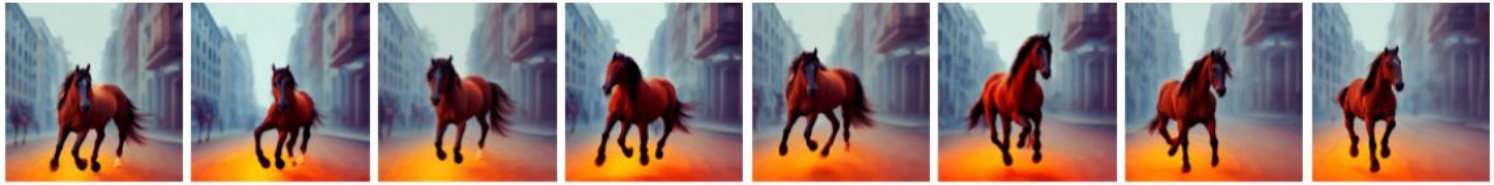

Text-to-Video generation: "a horse galloping on a street"

Text-to-Video generation: "a panda is playing guitar on times square"

Генерация сразу m кадров из диффузии (SD):

1. Случайный шум для 1 кадра
2. t шагов DDIM backward
3. Сдвиг по диагонали
4. t шагов DDPM forward
5. m разных, но связанных латентов

DDIM sampling с cross-frame attention

Background Smoothing опционально

CLIPScore выше, чем у CogVideo (9.4b): 31.19 vs 29.63

$$\text{Cross-Frame-Attn}(Q^k, K^{1:m}, V^{1:m}) = \text{Softmax}\left(\frac{Q^k (K^1)^T}{\sqrt{c}}\right) V^1$$

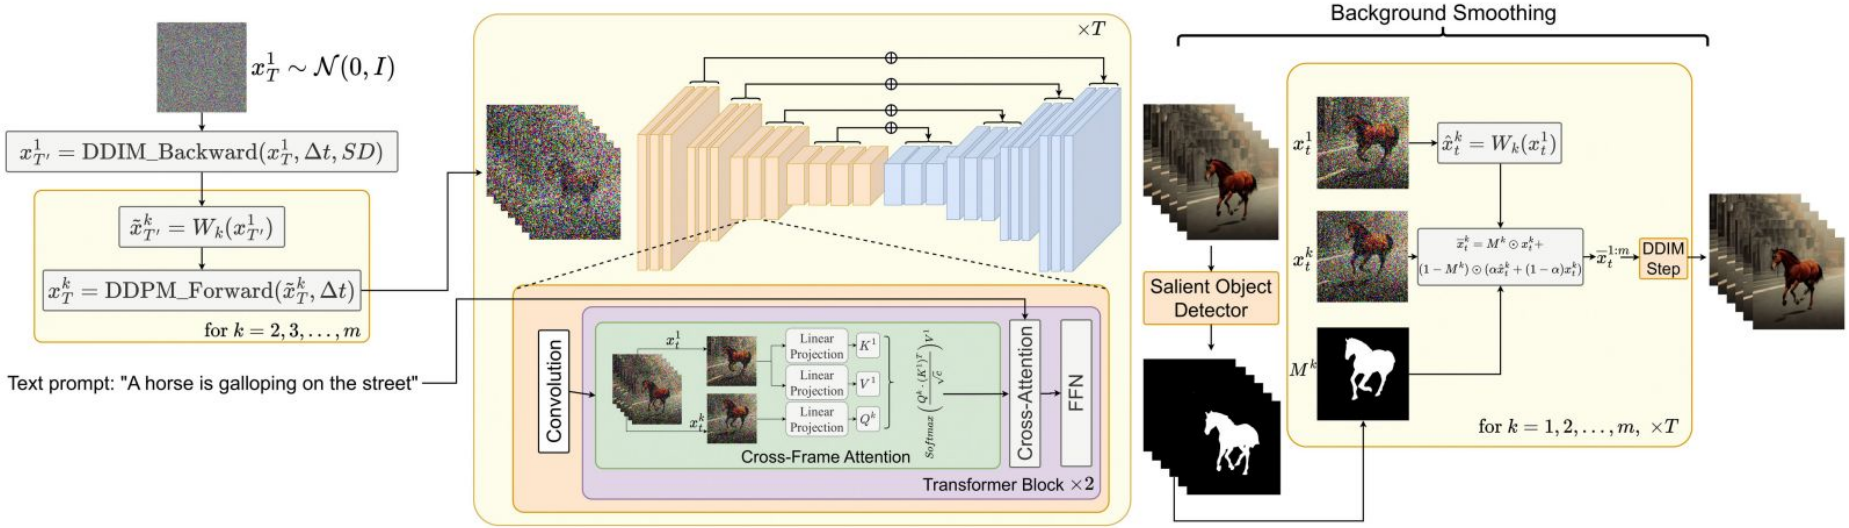

AnimateDiff (2024) - учим motion module для генерации видео в разных стилях

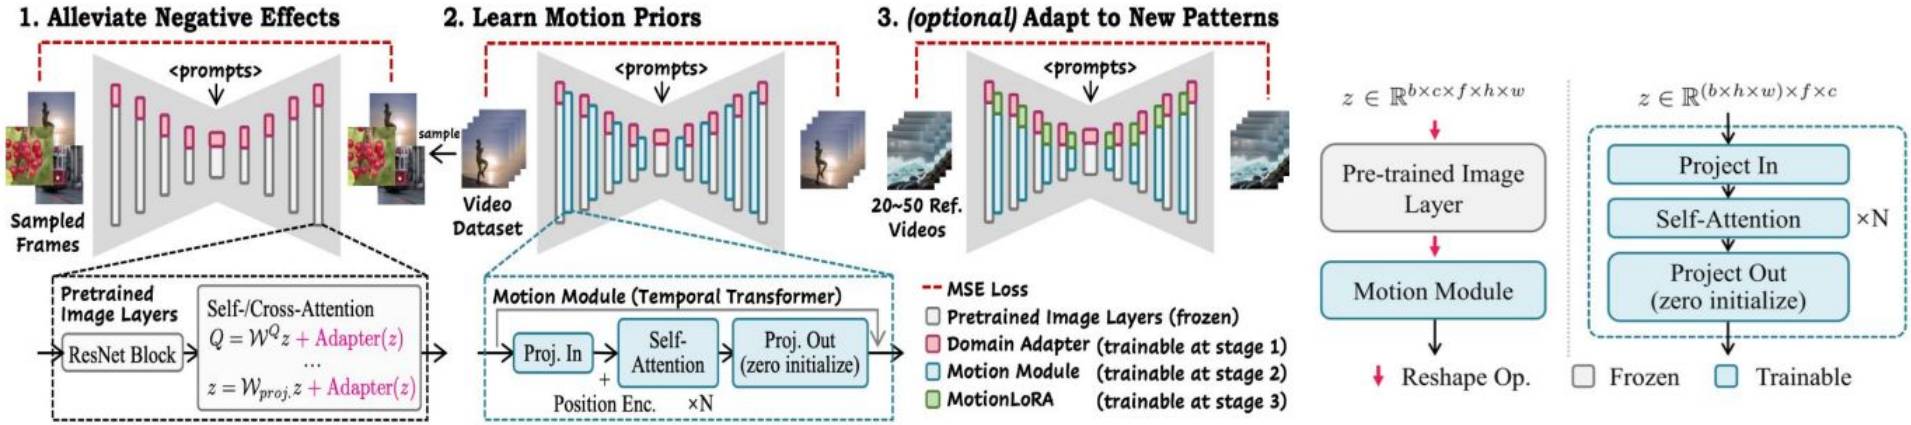

WebVid хуже по качеству чем датасет с картинками

Inflated Model + Temporal Transformer, остальное frozen

LoRA для специальных движений камеры

preview

Video Diffusion Models

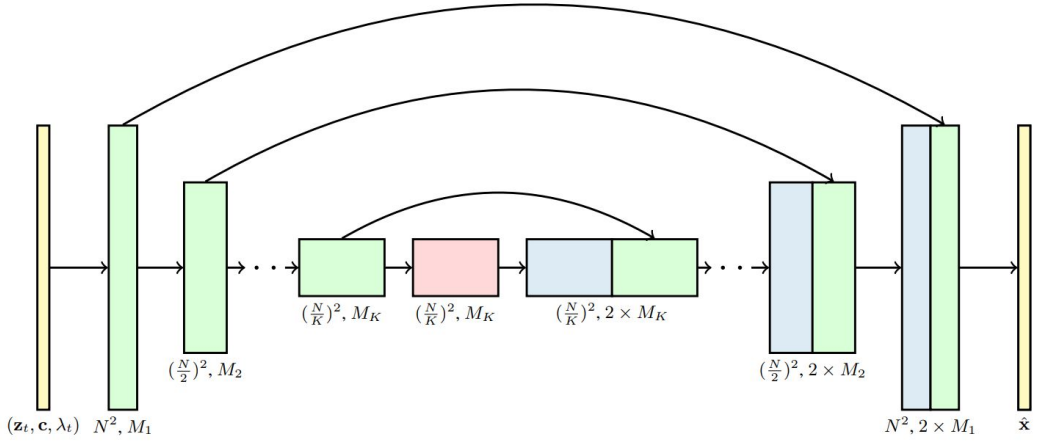

Replacement method плох для видео с большим числом кадров.
Reconstruction-guided sampling: добавляется градиент, заставляющий новый блок соответстовать предыдущему.

$$\tilde{\mathbf{x}}_\theta^b(\mathbf{z}_t) = \hat{\mathbf{x}}_\theta^b(\mathbf{z}_t) - \frac{w_r \alpha_t}{2} \nabla_{\mathbf{z}_t^b} \|\mathbf{x}^a - \hat{\mathbf{x}}_\theta^a(\mathbf{z}_t)\|_2^2 .$$

3D UNet:
Пространственные слои с 2D свертками + spatial attention
Временные слои - temporal attention после spatial блоков
Шумный видео-тензор на входе, предсказание шума для всех кадров одновременно

Imagen Video (Google, 2022)
ModelScope T2V, Video-Crafter, Open-Sora

https://video-diffusion.github.io (2022) - новая SOTA на UCF101 (в 10 раз меньше FID, IS почти в 2 раза больше)

Latent Video Diffusion - high-res* видео с любым базовым ILDM

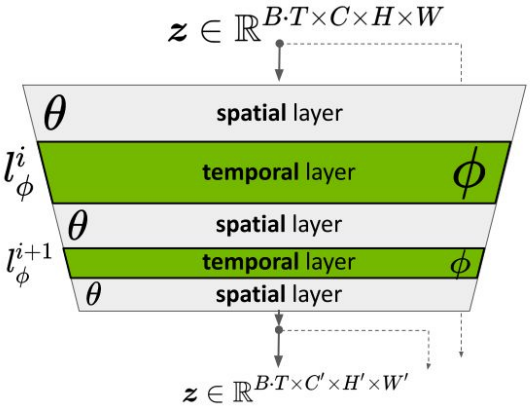

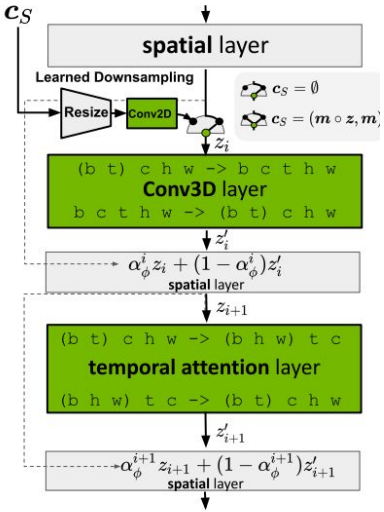

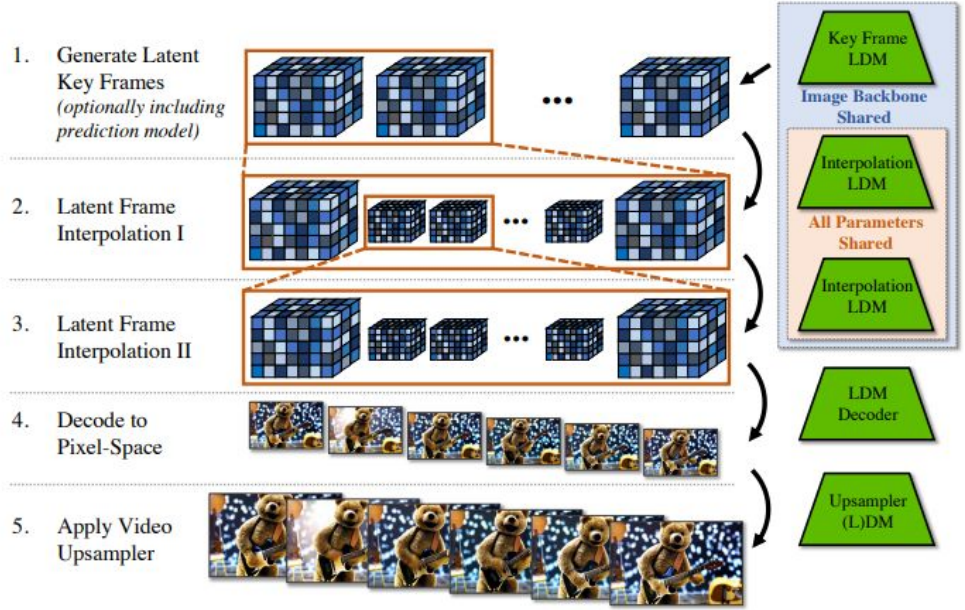

Берём image LDM, добавляем temporal слои после spatial в декодере (их заморозим), обучаем только temporal на видео. Добавляем 3D conv дискриминатор. Избавляемся от фликера. Upsampling для получения high-res. Prediction для долгих видео.

Latent Video Diffusion - идея (SOTA на Driving Videos), Stable Video Diffusion (2023) - реализация с обучением на огромном числе видео

*1280x2048 на text2video

Пример работы Stable Video Diffusion со [страницы на HuggingFace]

Transformer-based video models

preview

CogVideo (2022)

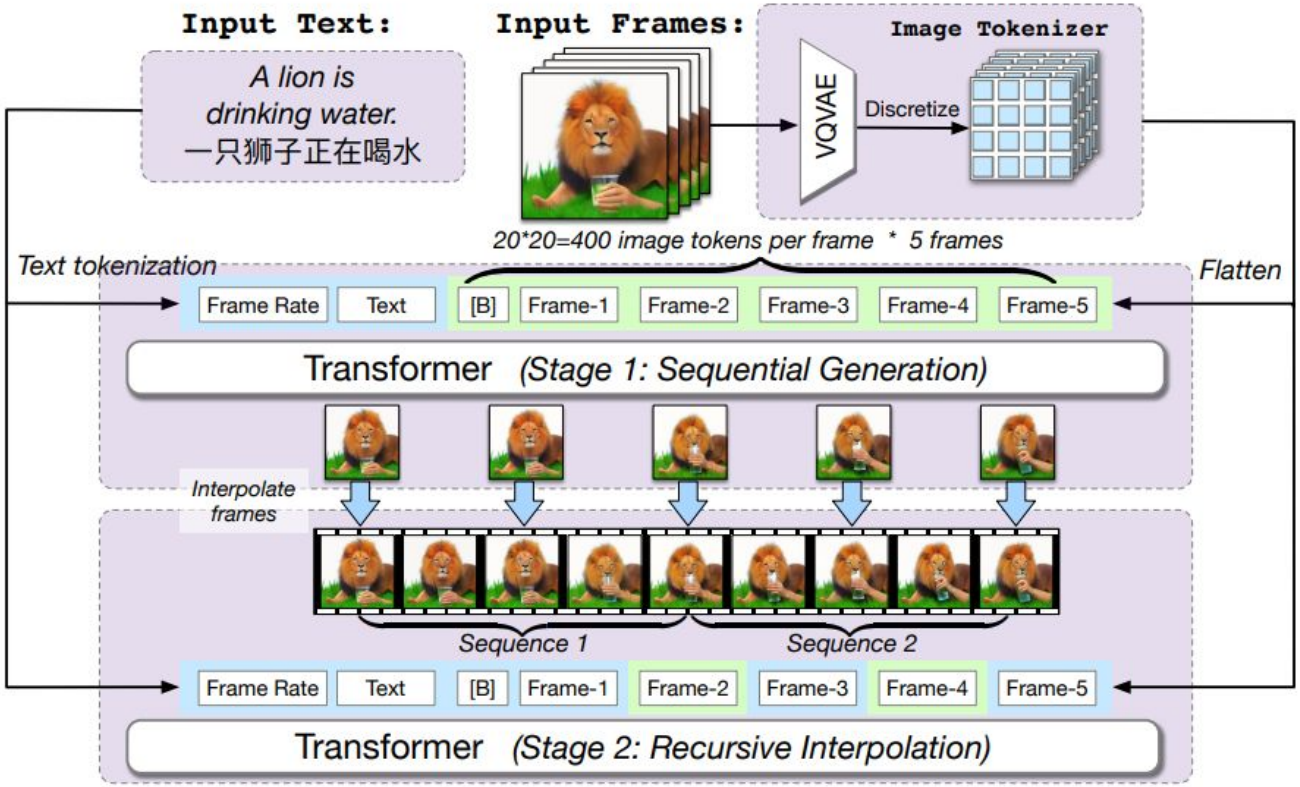

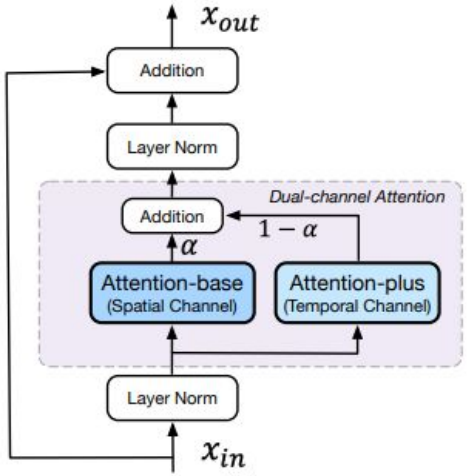

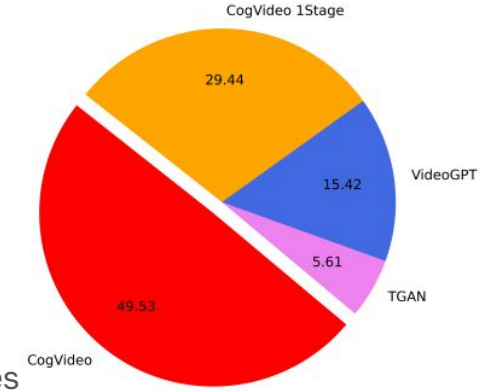

UCF101 human preferences

К CogView2 добавим temporal-канал и будем обучать только его - ~3.4B/9.4B параметров обучается.

preview

CogVideoX (2025)

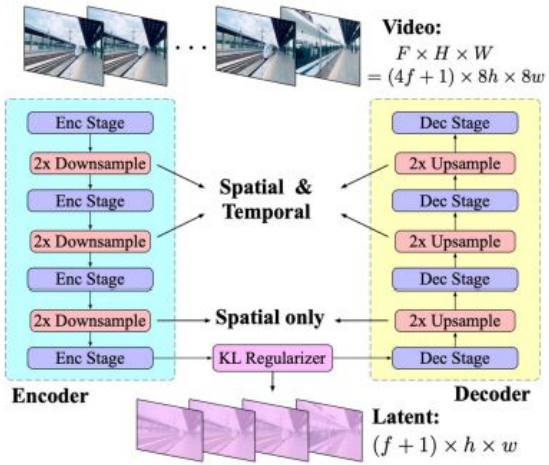

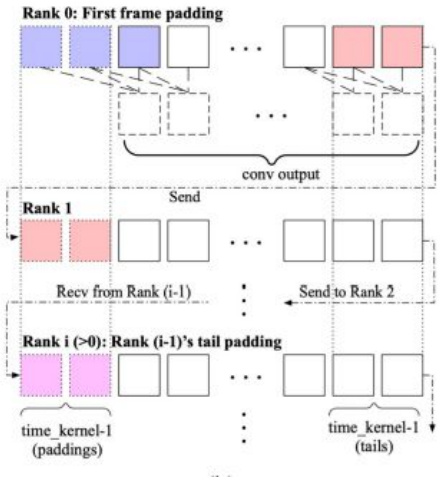

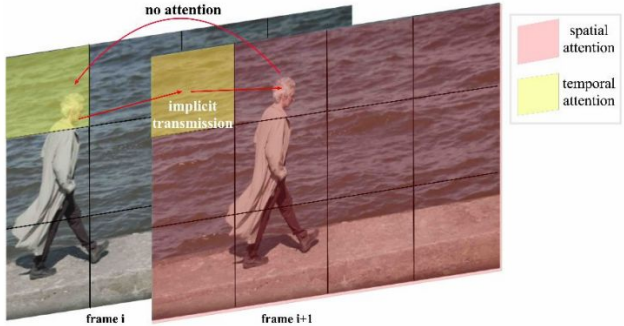

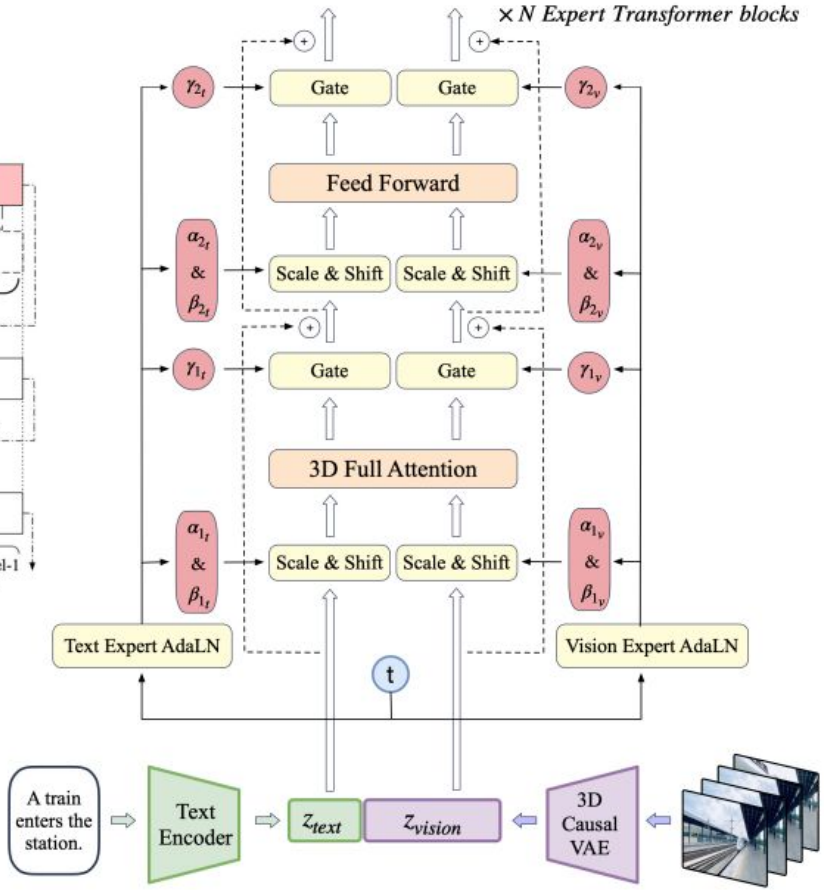

3D causal VAE
Expert Transformer
3D full attention
(с 3D RoPE)
Dense captioning
SOTA среди открытых моделей

Video foundation models

Могут: text2video, image2video, video2video (редактирование)

Закрытые: Sora, Runway Gen3, Luma Dream Machine, Kling

Открытые: Open-Sora, CogVideoX, VideoCrafter2, SVD-XT

В больших моделях часто используется DiT + 3D VAE, но есть отличия в том, как склеиваются текст и видео (Expert AdaLN, MVL, MM-DiT)

preview Luma

Open-Sora (2024)

preview

STDiT - разделение пространственного и временного внимания
3D VAE - 2D VAE от SD-XL + temporal compression
Инициализация из PixArt-a
I2V + T2V
VBench 2024 - 79.76, SOTA среди открытых

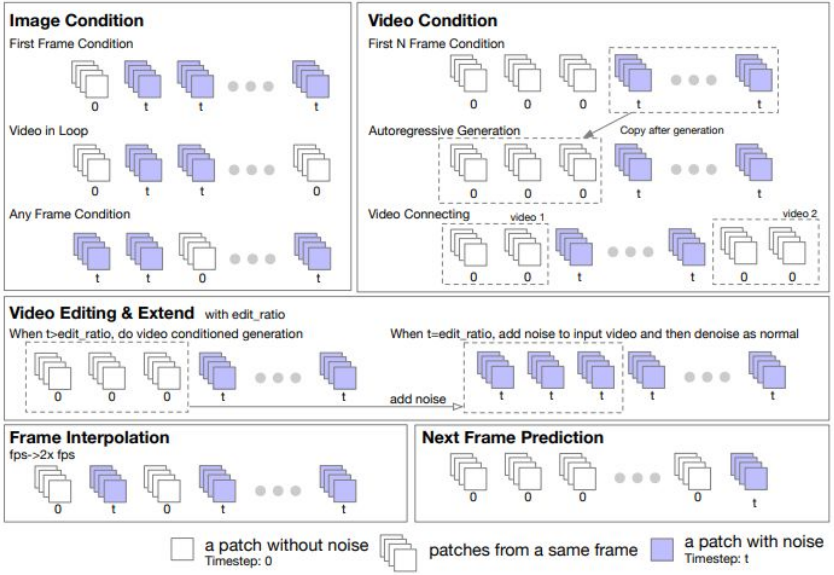

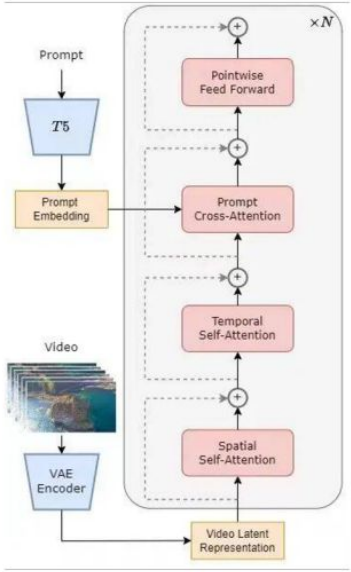

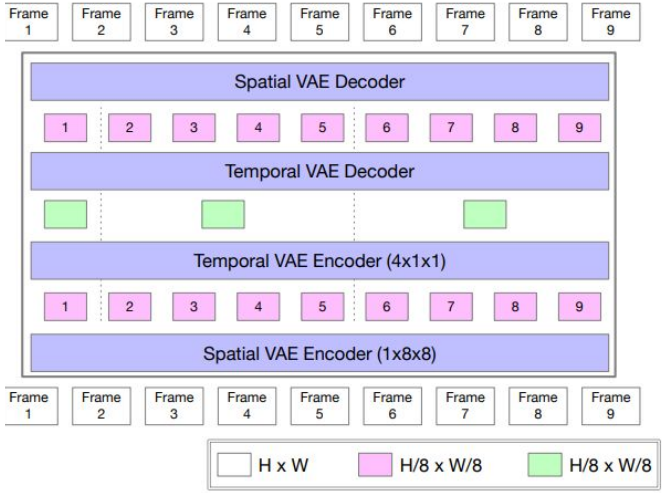

HunyuanVideo (2024) - 13b модель

Causal 3D VAE: сжатие 4*8*8

DiT: dual-stream + single-stream

Text encoder: MLLM + CLIP + bidirectional refiner

3D-RoPE

Иерархическая фильтрация данных + JSON captioning

По Human Score обгоняет Runway Gen-3, Luma 1.6 и топовые китайские закрытые модели

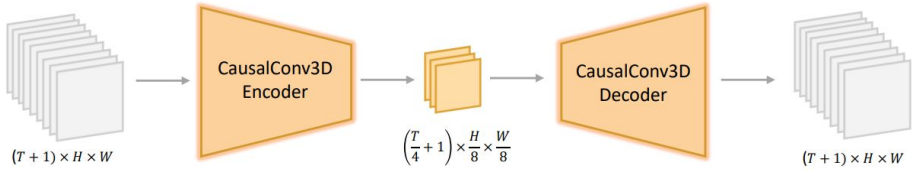

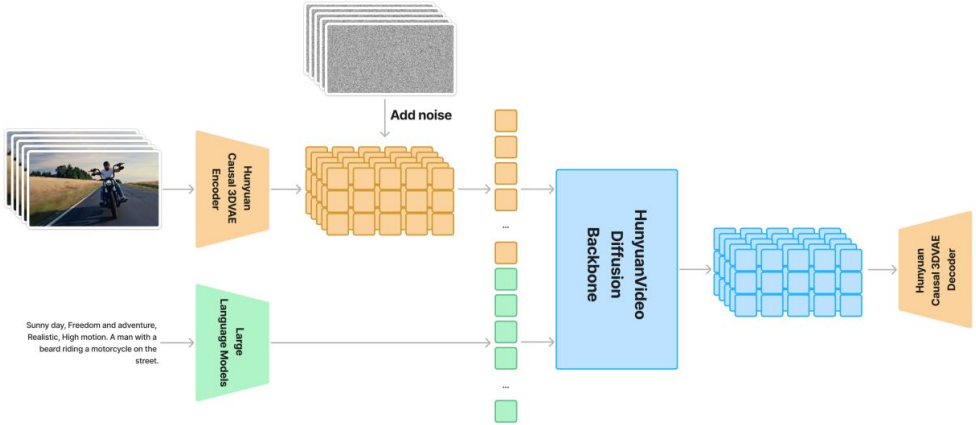

preview

Open-Sora 2.0 (2026) - качество за $200k

3D автоэнкодер (Video DC-AE): сжатие 4*32*32, ускоренный инференс и меньший расход токенов

MMDiT: dual-stream блоки + single-stream блоки

3D full attention + 3D-RoPE

Инициализация из FLUX-11b

Motion Score как токен в конце промпта, контролирует силу движения

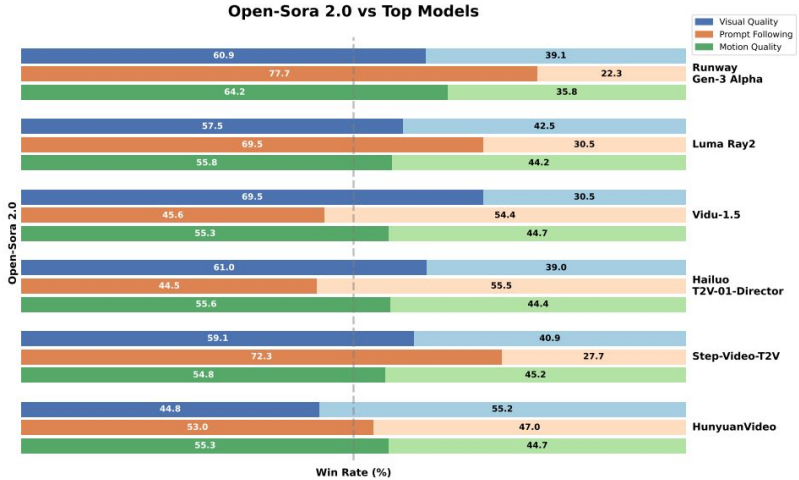

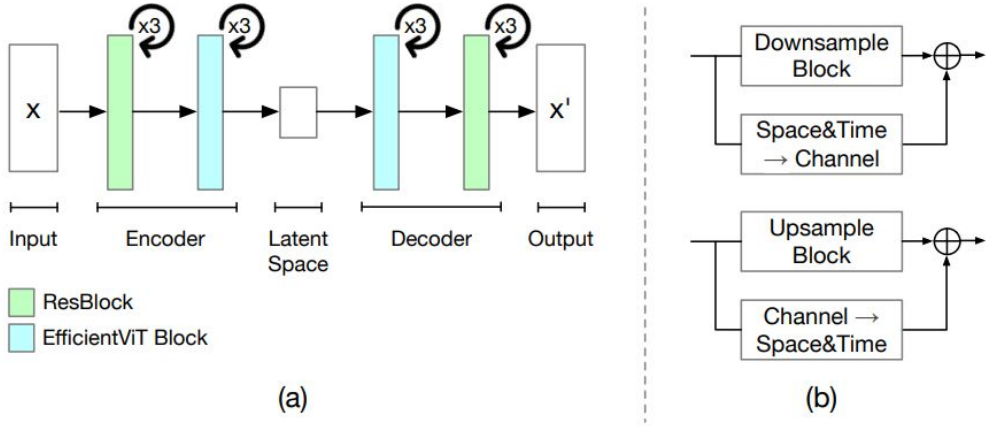

Sora (2024)

Diffusion + patches + VAE

Картинка

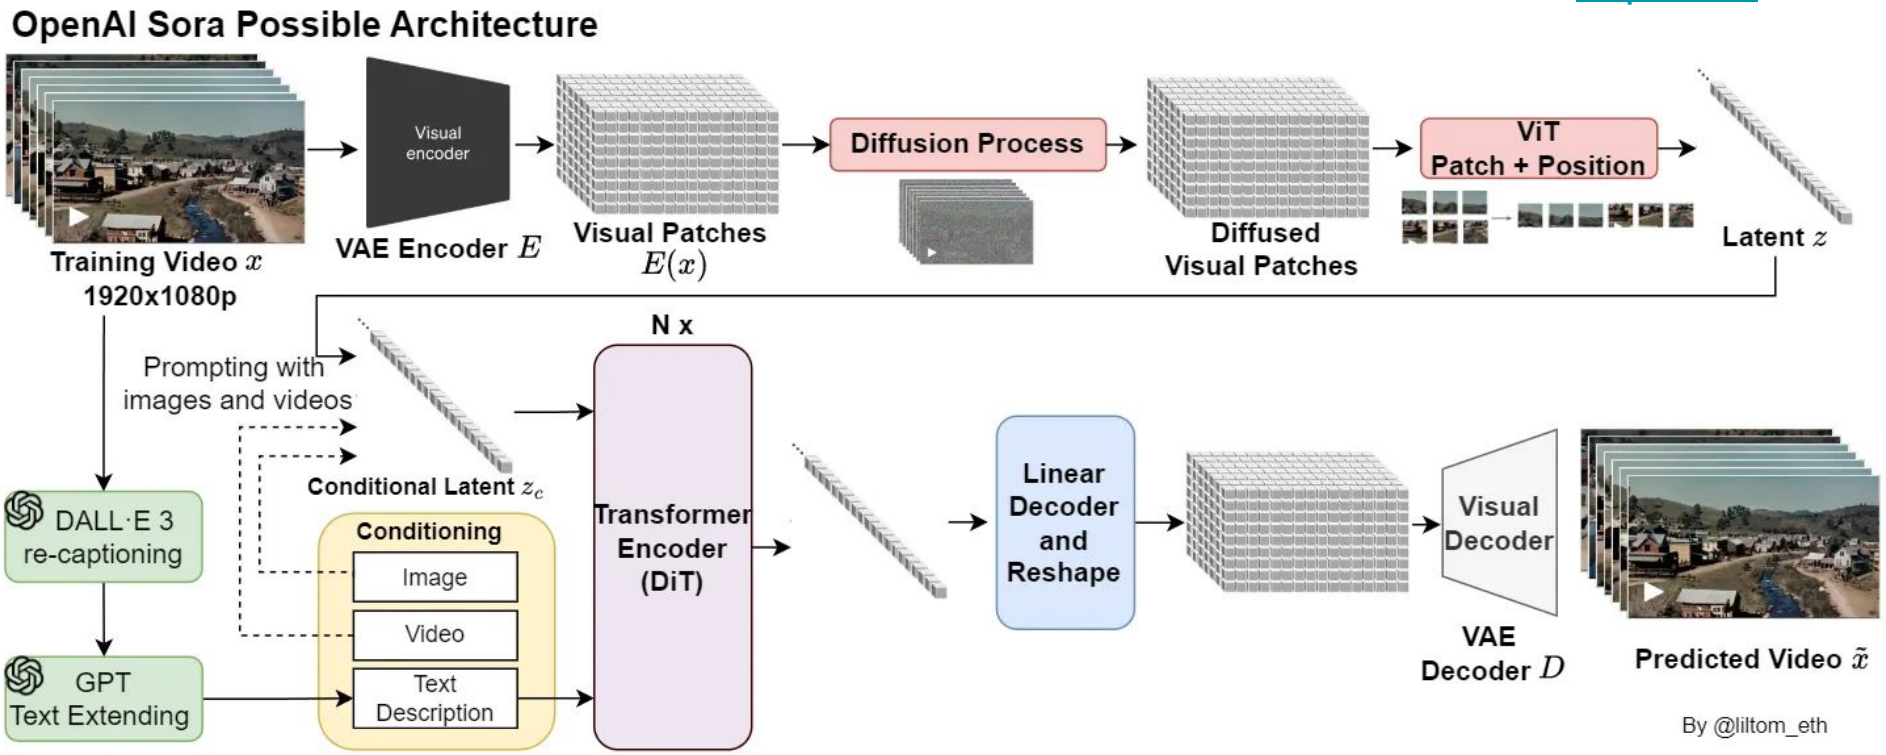

Примеры работы Sora

Промпты:

1. “*it is ITMO University. classroom. "Video generation" is on the board. it is computer vision lesson.*”
2. *“черепаха учит компьютерное зрение в Университете ИТМО. она сидит в классе и учит компьютерное зрение. на доске написано CV”*

Про метрики

FID

FVD - расстояние Фреше между распределениями настоящих видео и сгенерированных (пропускаем видео через предобученный ConvNet, получаем для каждого видео вектор из активаций, считаем статистики)

IS

Human Score

Will Smith eating spaghetti (unofficial)

Из Reddit r/ChatGPT

Что нас ждёт?

Более длинные видео в высоком разрешении

Ещё дешевле и быстрее

Полная мультимодальность

Контроль и редактирование

Открытые модели догоняют закрытые

Оптимизации (MoE архитектуры)

Этика и регулирование

Спасибо за внимание!