Детекция и генерация дипфейков

Пахалюк Евгений Эдуардович

Что такое дипфейк?

Дипфейк – сгенерированный медиафайл, на котором подменены лицо, либо голос одного человека лицом, либо голосом другого.

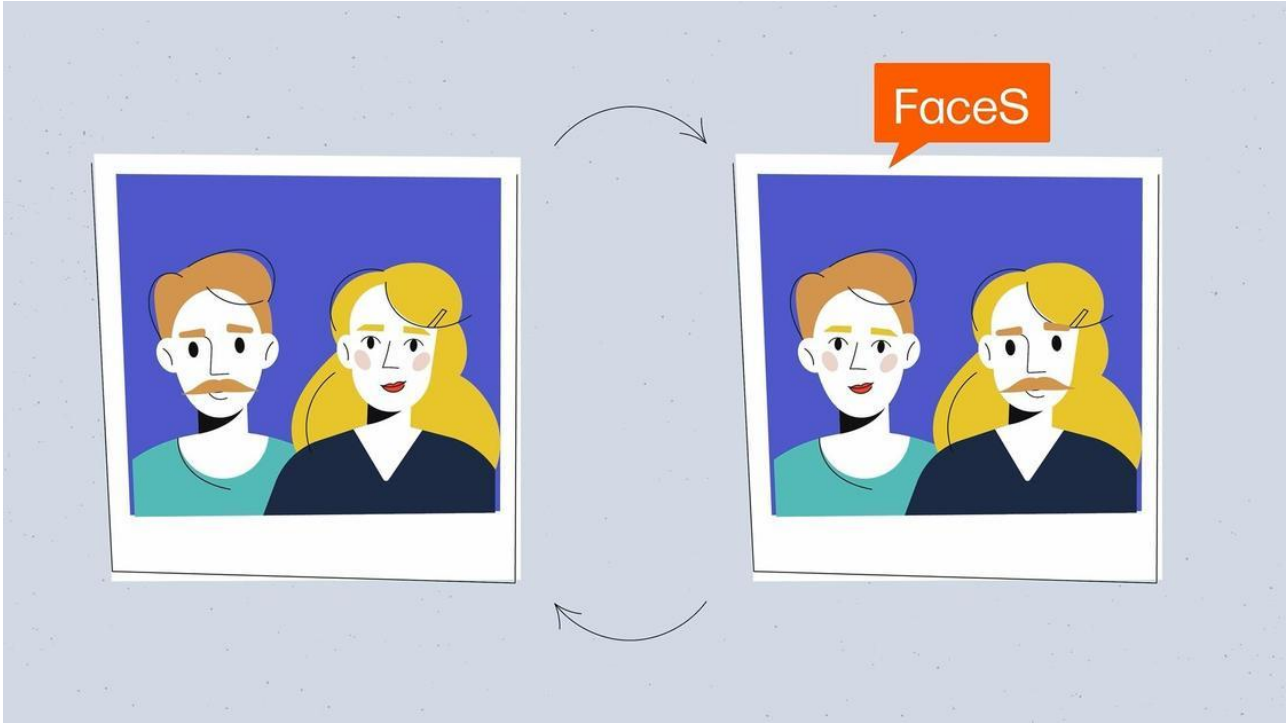

Мотивация

Легитимные применения

- Кино (de-aging, CGI)
- Игры
- Образование (интерактивные экспонаты)
- Дубляж видео
- Анонимизация данных
- Ритейл (виртуальные примерочные)

Негативные кейсы

- Мошенничество
- Фейки в СМИ
- Шпионаж

Исторические предпосылки

До 2014

- Компьютерная графика (CGI) и VFX
- Motion capture
- Ручная обработка видео
- Ограниченная реалистичность и ОЧЕНЬ высокая стоимость

2014

- Появление GAN
- Реалистичные лица

2017

- Появление термина «deepfake»
- Первые face-swap видео
- Использование автоэнкодеров

2018-2020

- Резкий рост качества видео
- Появление DeepFaceLab, FaceSwap
- Массовое использование

2020+

- Диффузионные модели (Stable diffusion)
- Трансформеры (ViT, Swin)
- Рост качества, сложность детекции

Методы генерации: AutoEncoder-based (baseline)

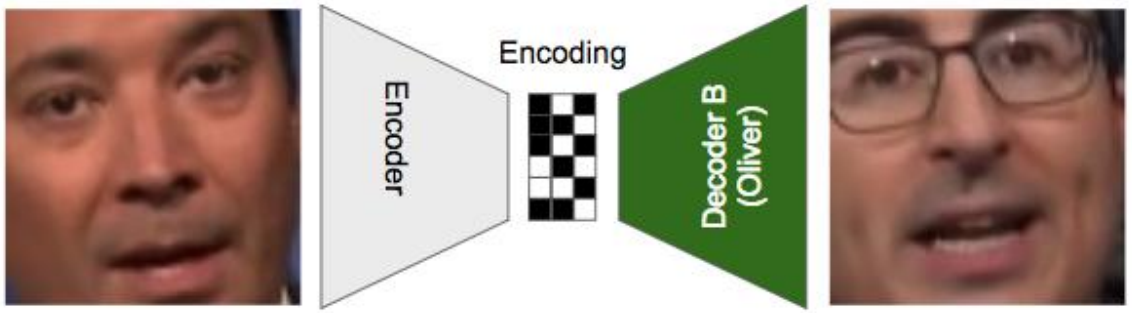

1. Обучить автоэнкодеры на первом и втором человеке
2. Покадрово вырезать лицо, которое хотим заменить
3. Прогнать через энкодер оригинальной картинки и декодер вставляемой
4. Вставить в оригинальную картинку

Методы генерации: SimSwap

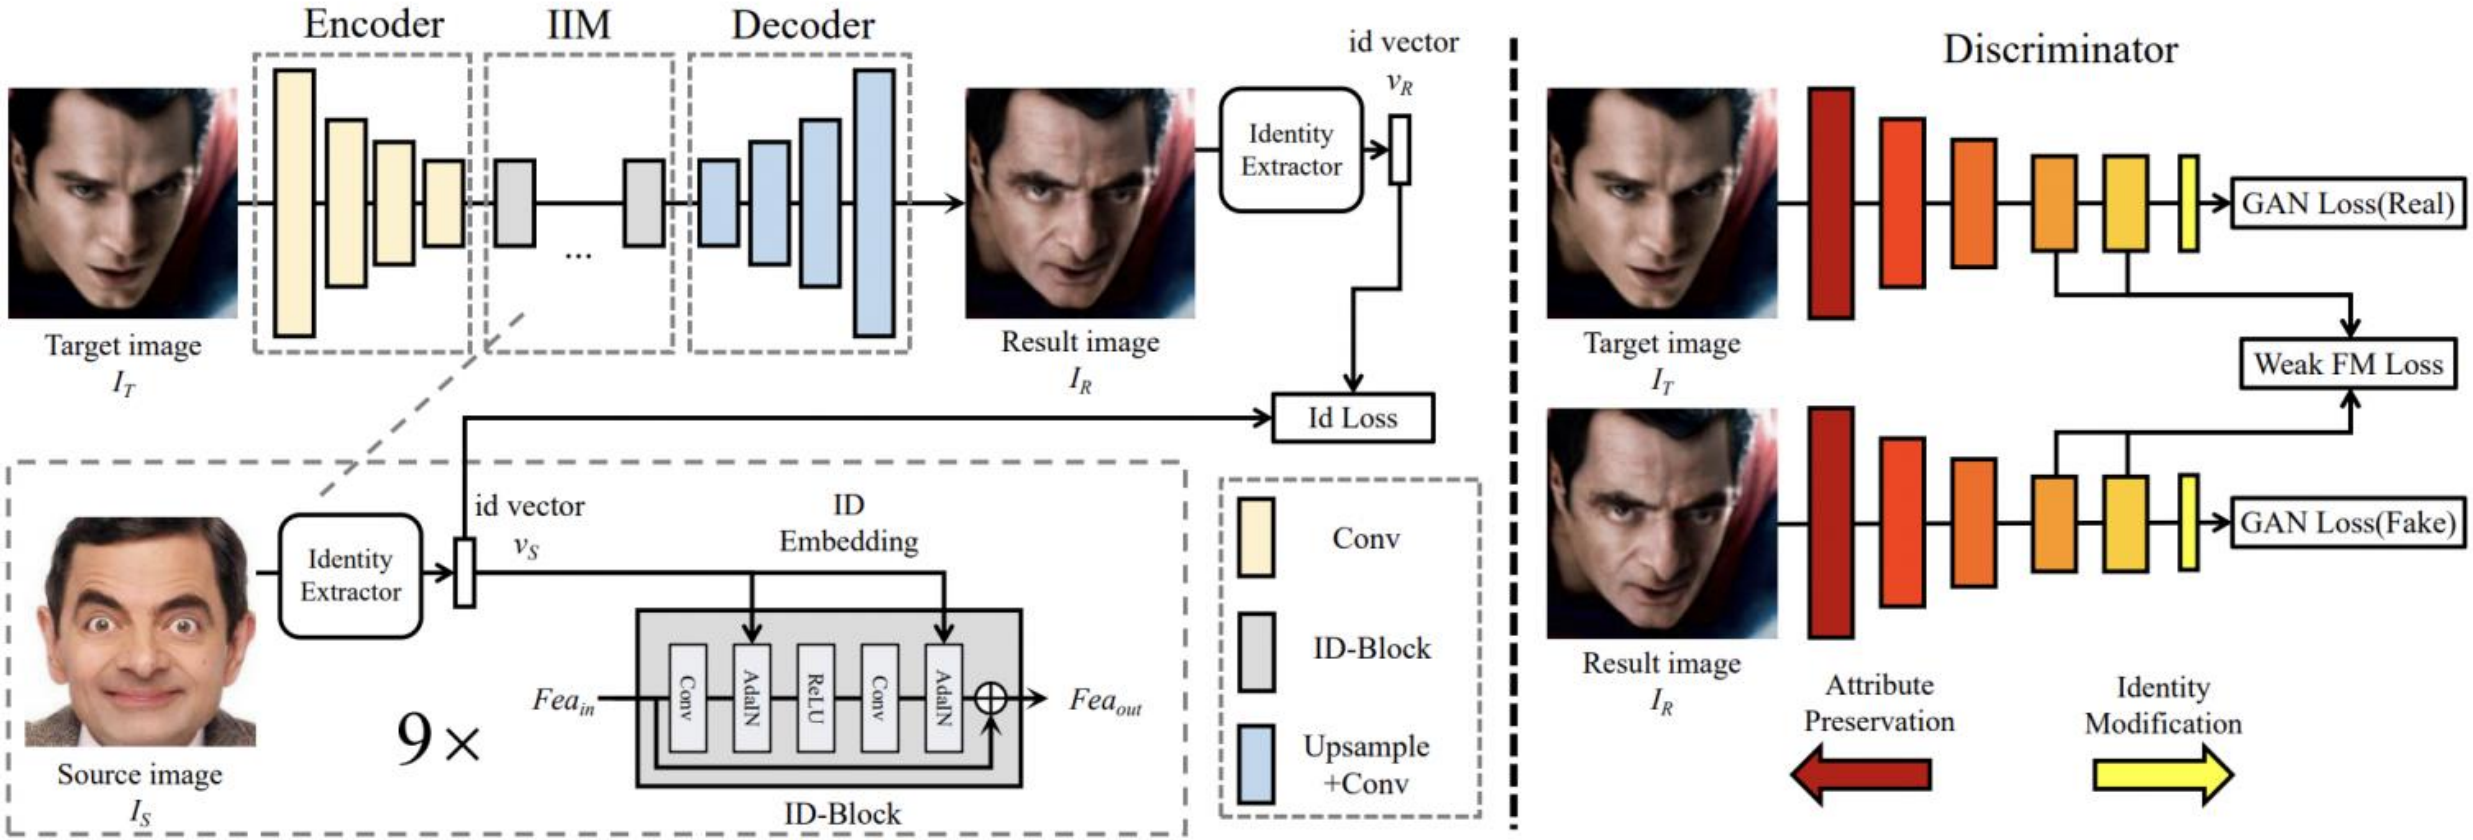

Методы генерации: SimSwap

Методы генерации: FSGAN

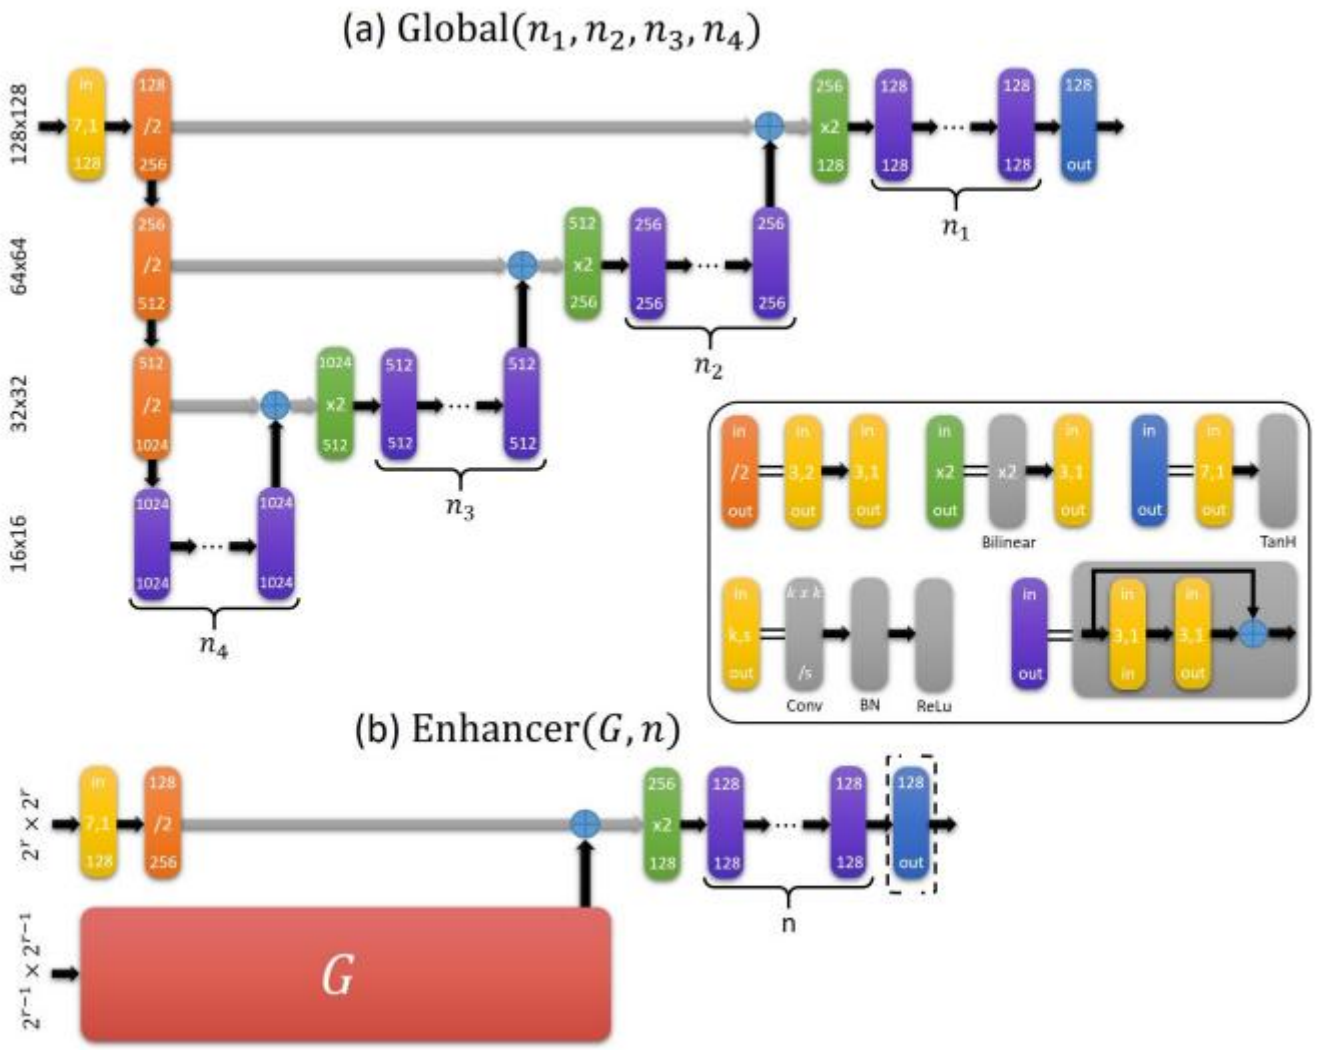

Методы генерации: FSGAN

Методы генерации: FlashFace

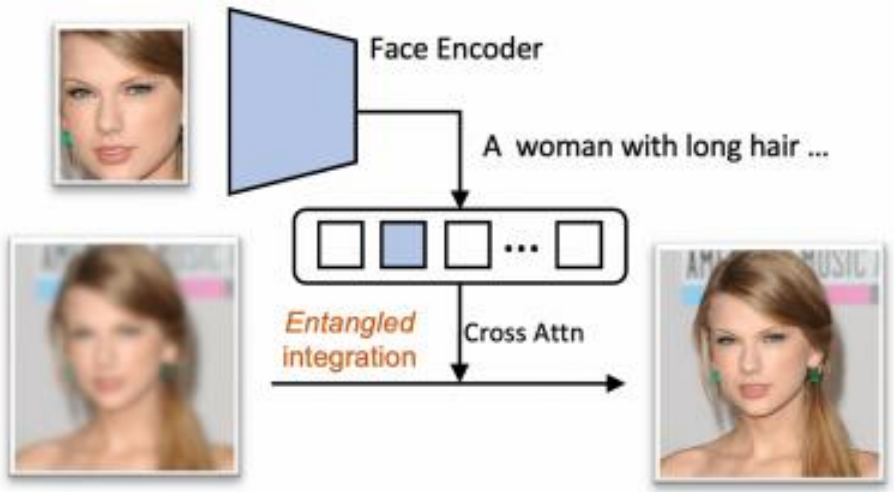

(a) Embedding-based methods and training data format

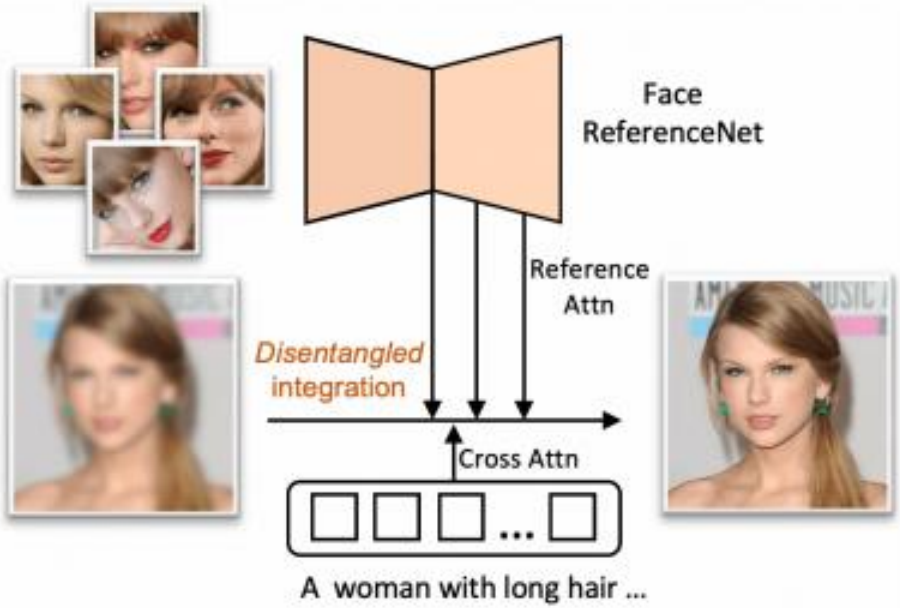

(b) FlashFace and training data format

Методы генерации: FlashFace

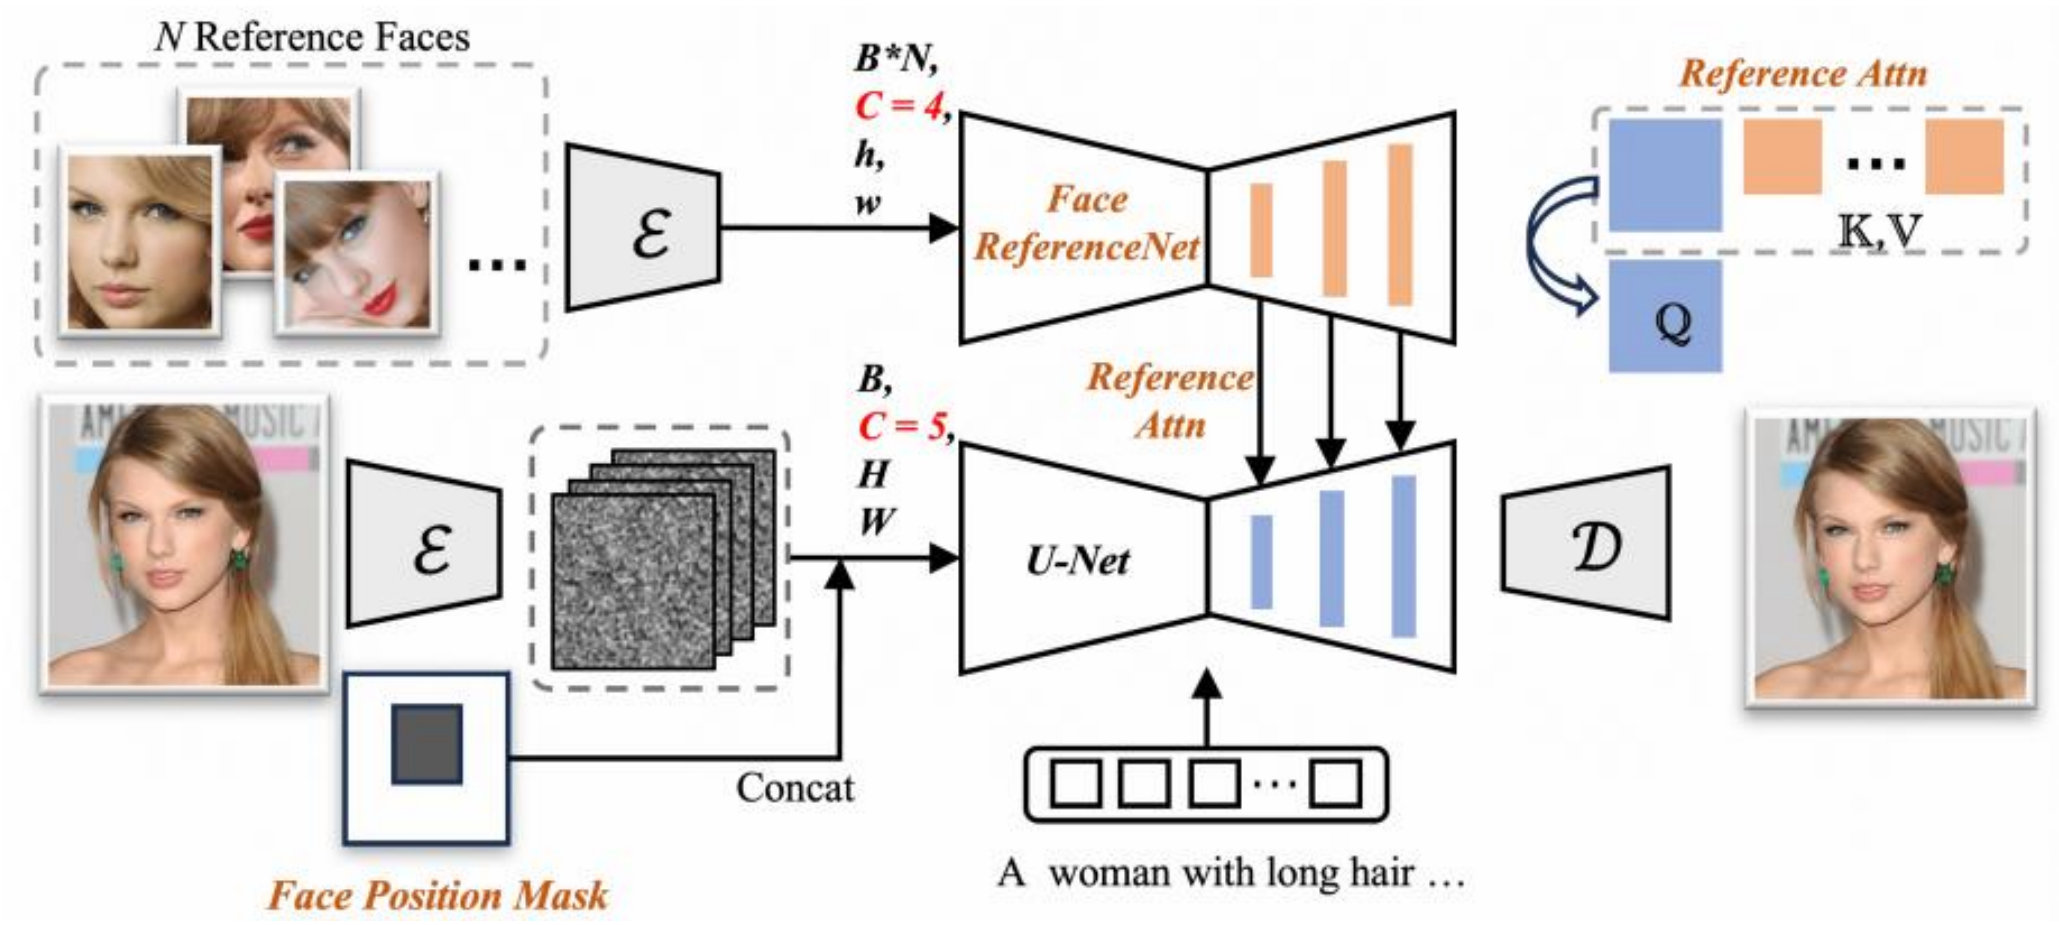

Методы генерации: FlashFace

Методы детекции: CNN-based (baseline)

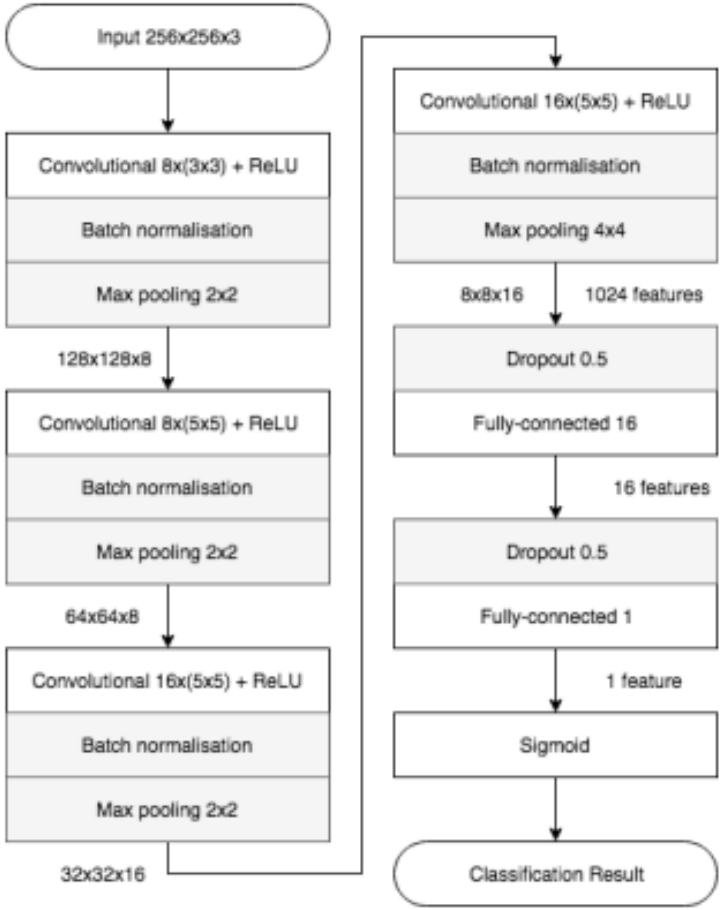

- XceptionNet
- Meso-4
- ResNet
- EfficientNet

Методы детекции: GFADE

Figure 1. Overall framework diagram of the generalized feature adaptation and discrimination enhancement (GFADE) model.

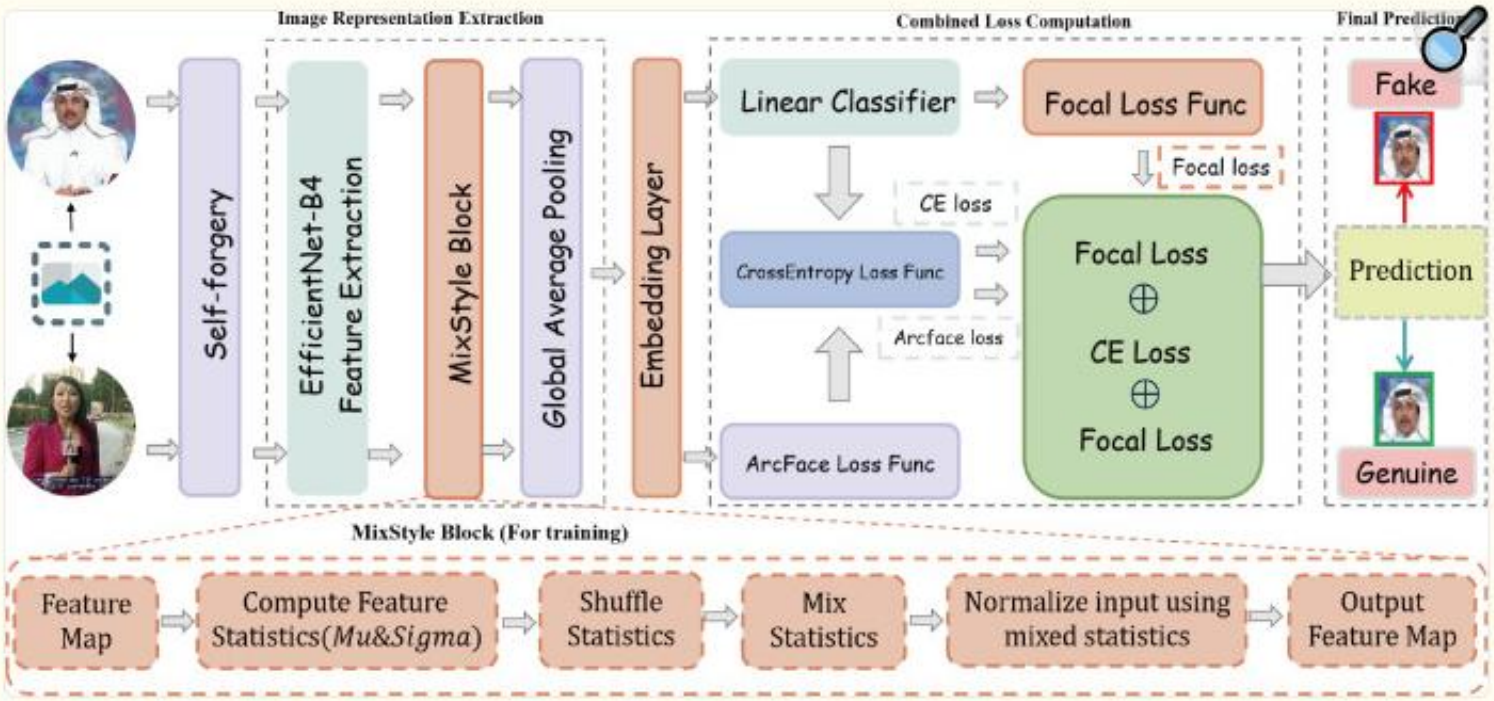

Open in a new tab

Методы детекции: ViT

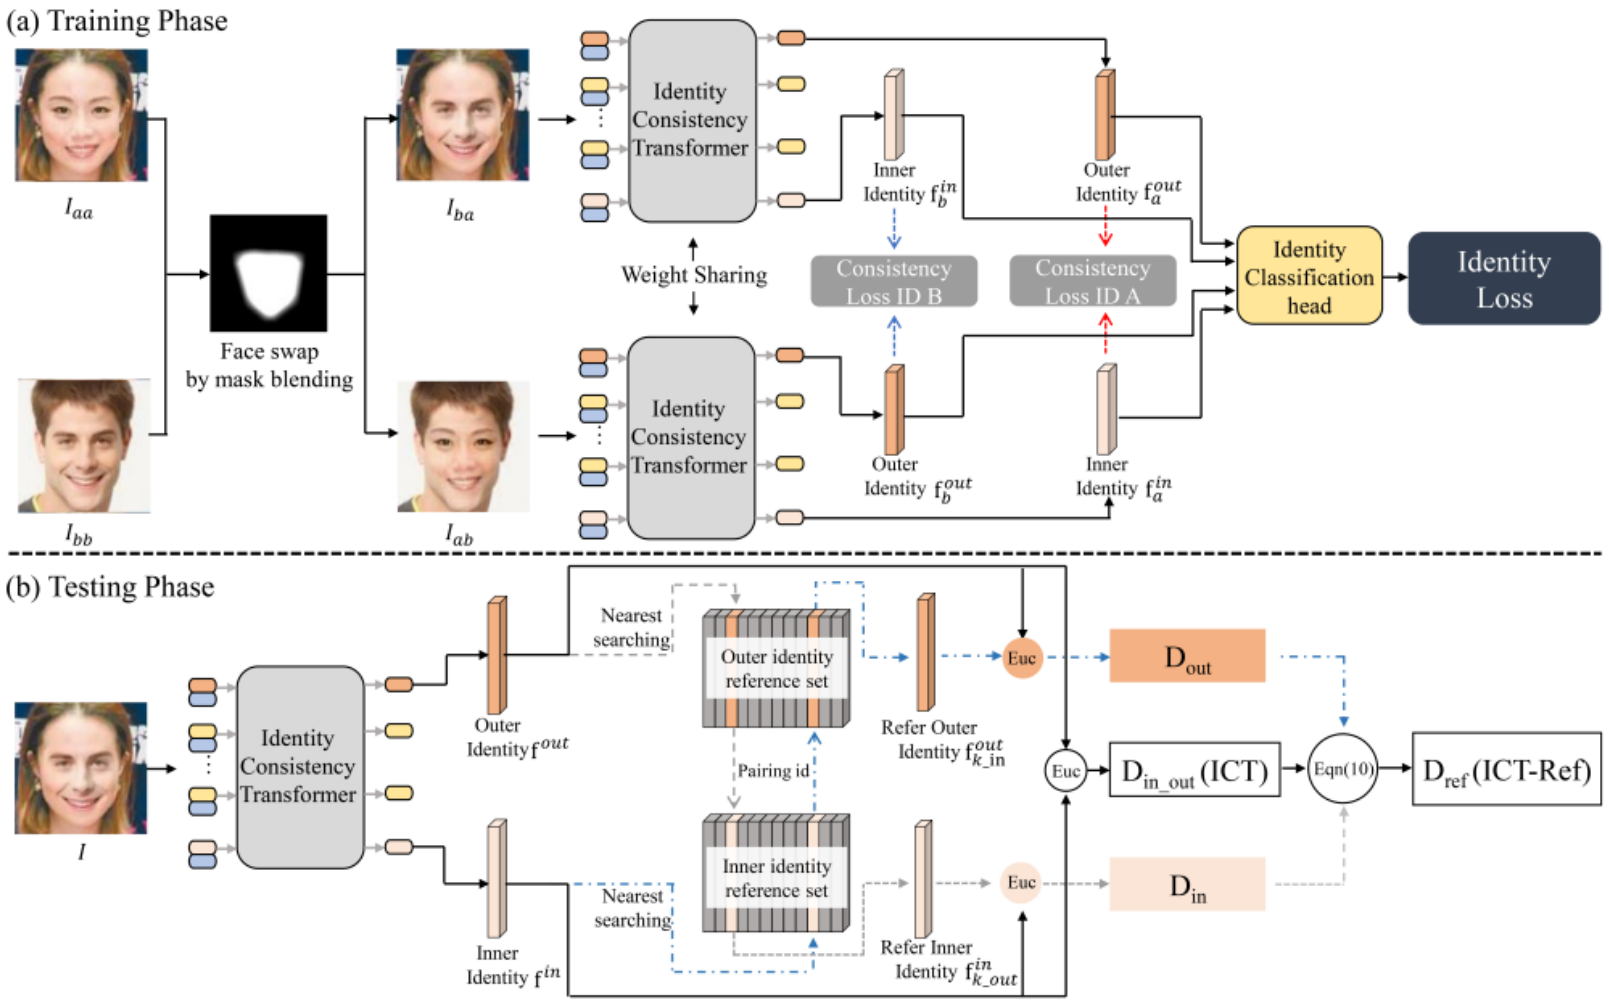

Методы детекции: WMamba

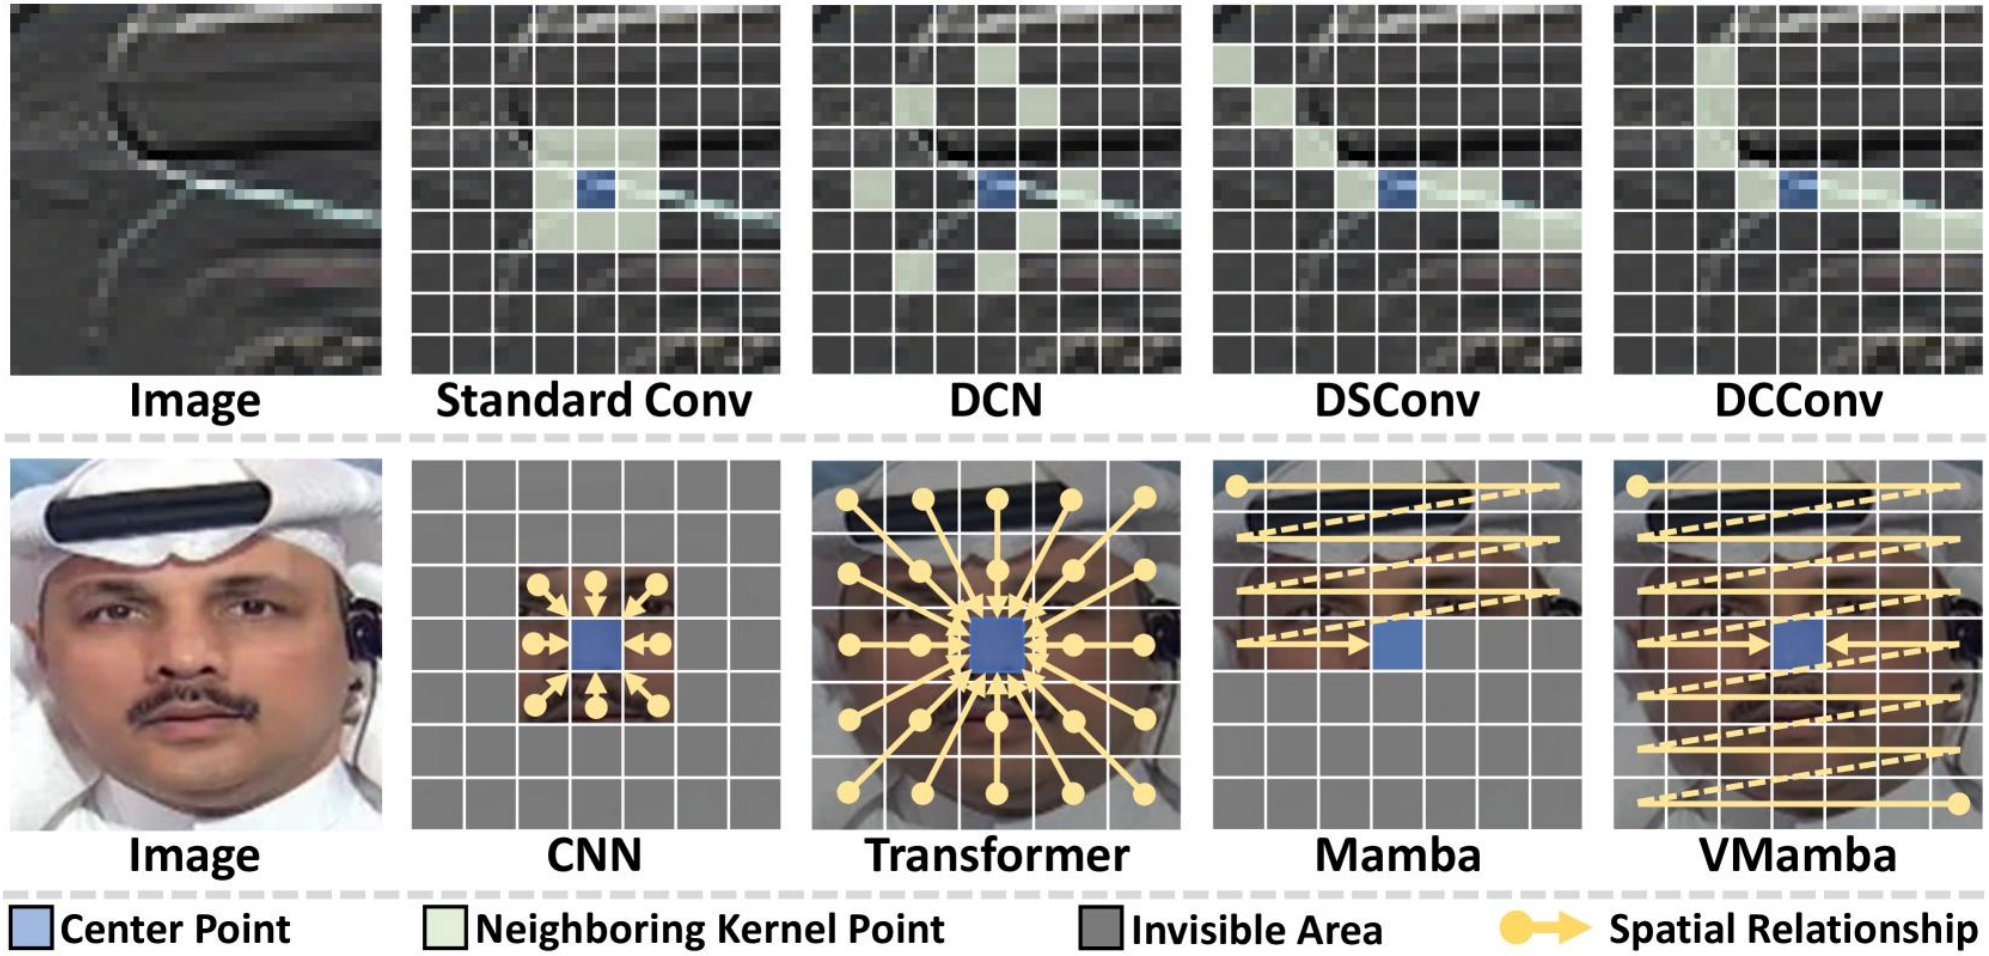

Методы детекции: WMamba

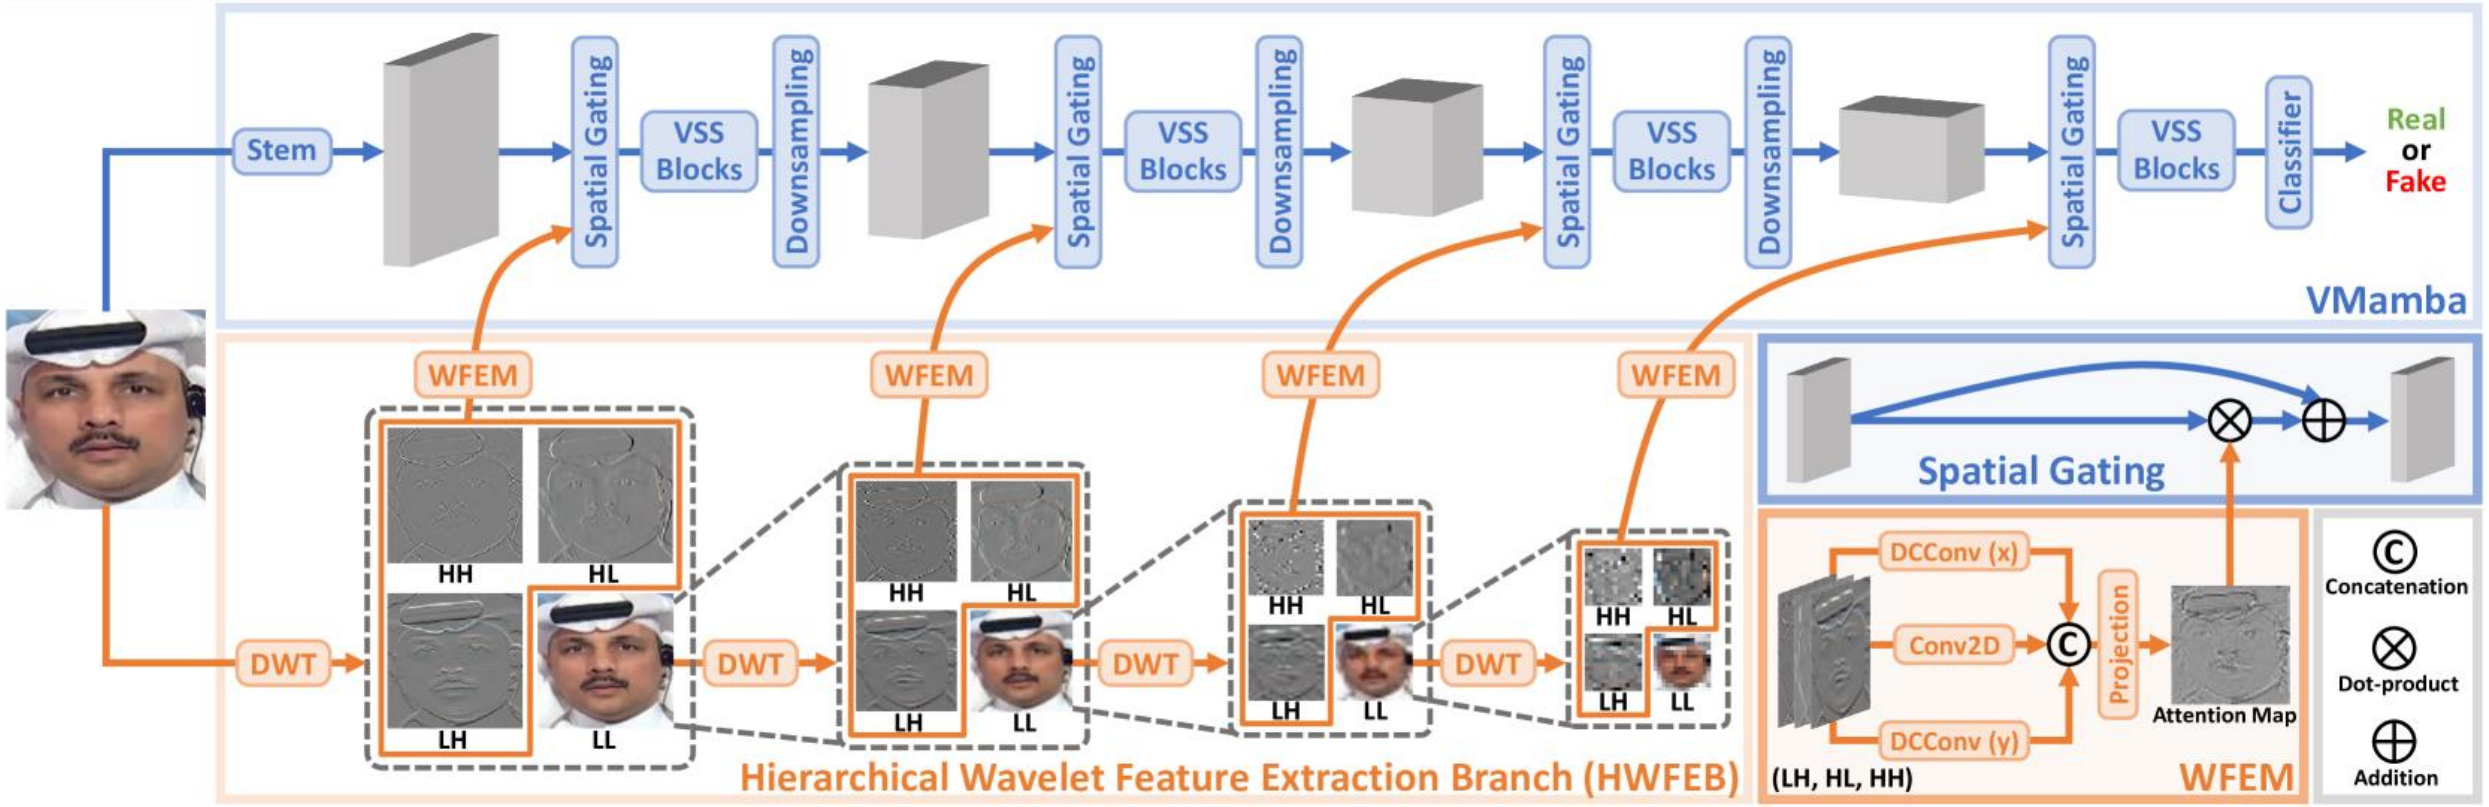

Методы детекции: WMamba

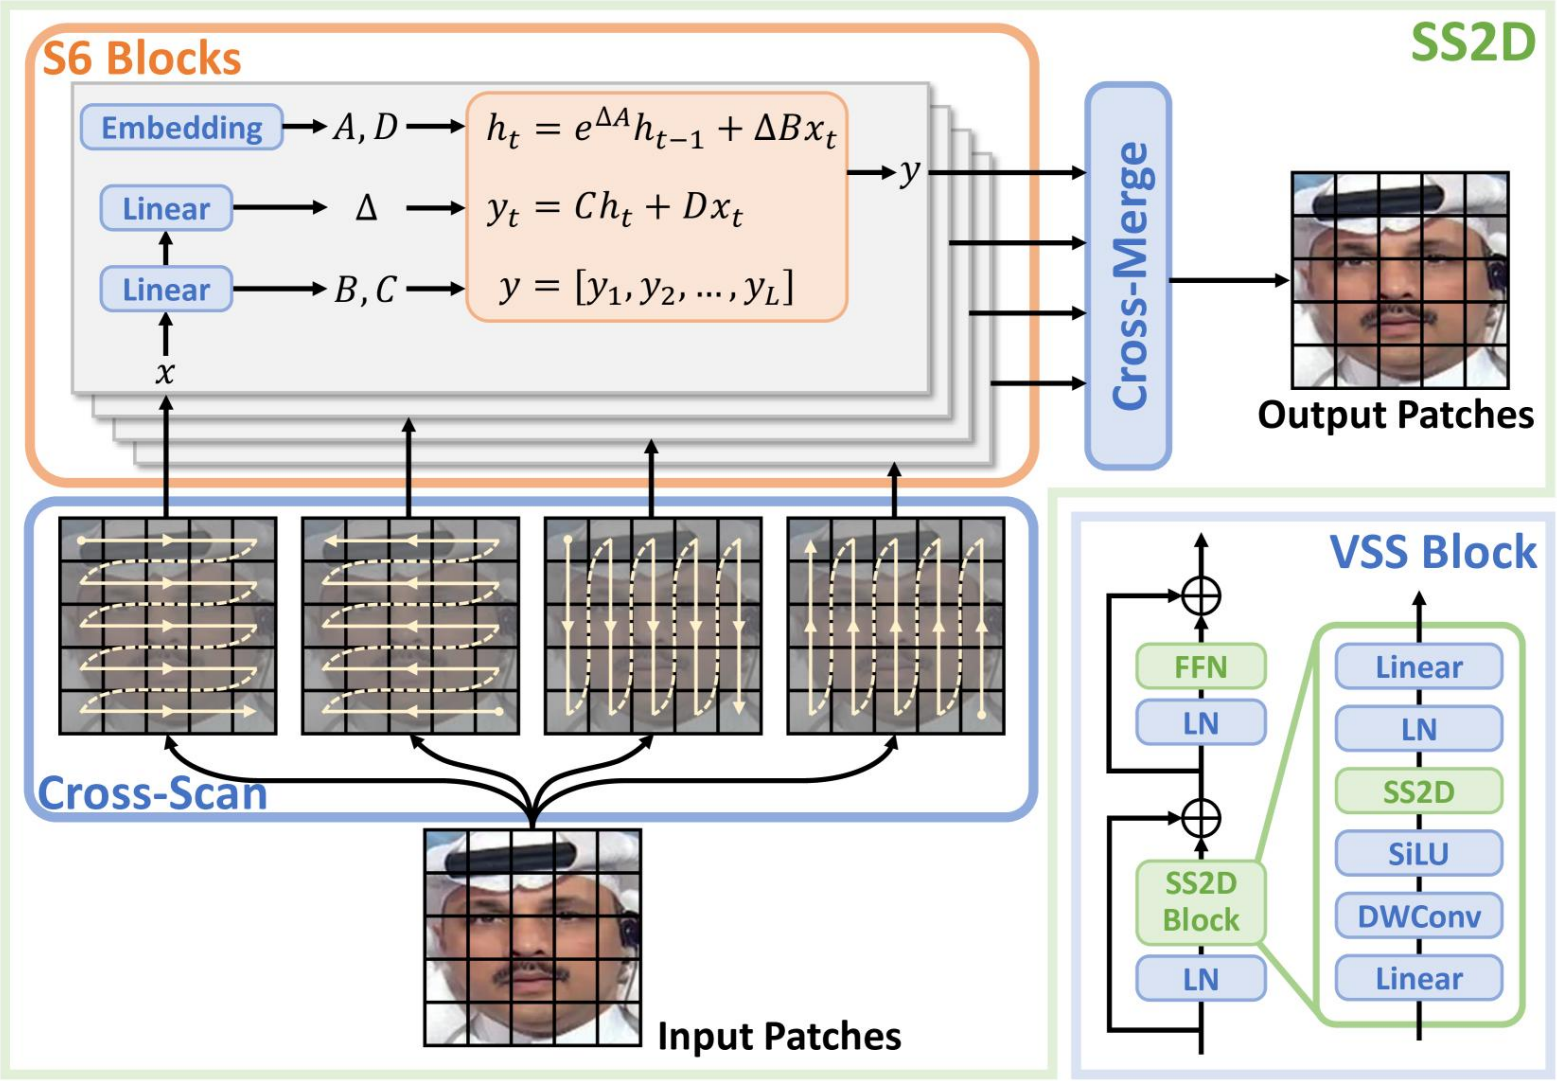

Методы детекции: WMamba

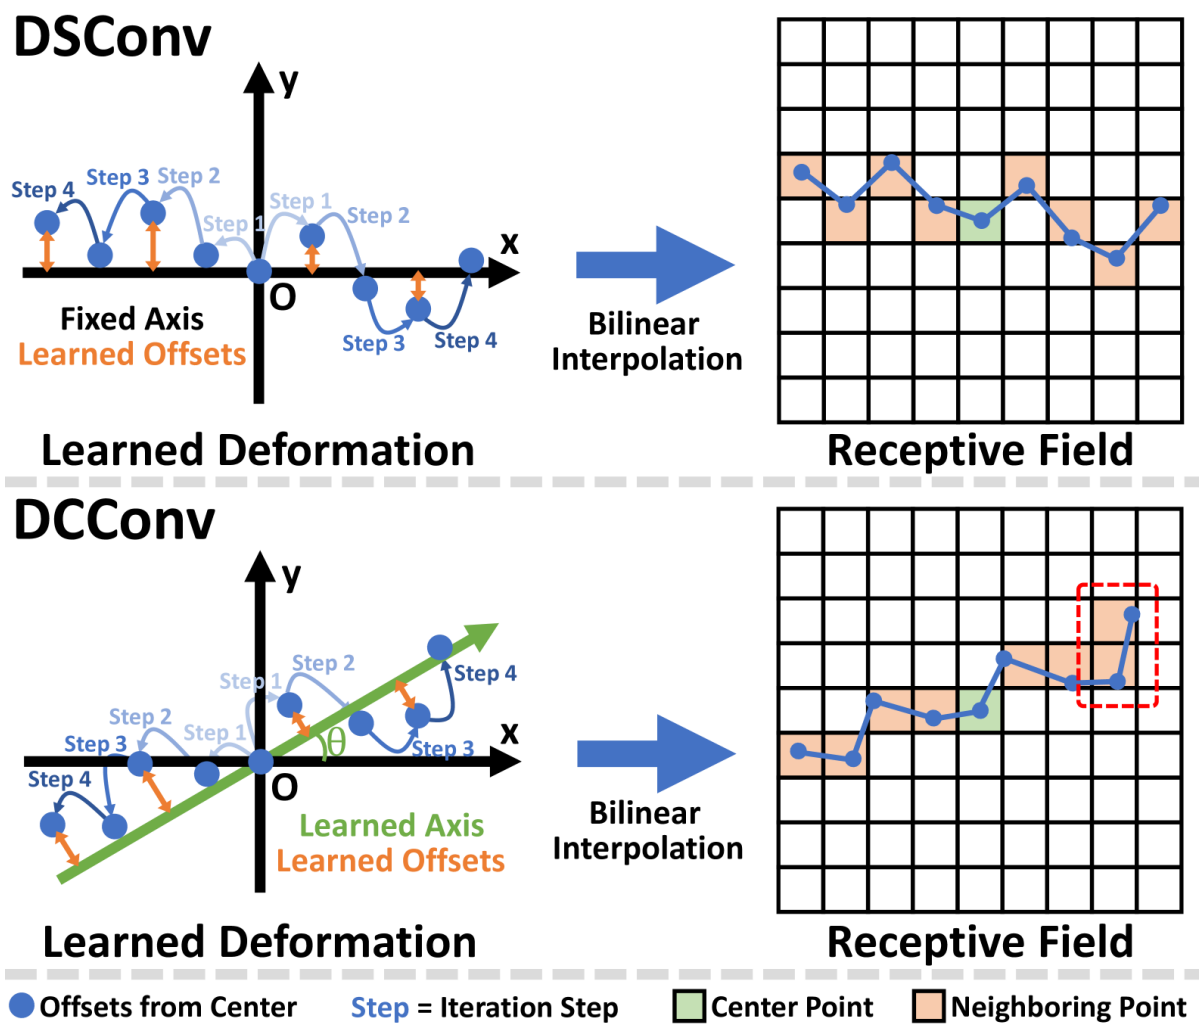

Сравнение подходов: SimSwap

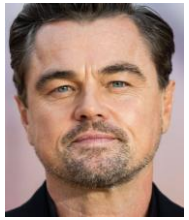

Сравнение подходов: Детекция

Сравнение подходов: FSGAN

Сравнение подходов: Детекция

Сравнение подходов: Nano Banana Pro

Сравнение подходов: Детекция

Сравнение метрик + выводы

	A	B	C	D
1		FF++	Celeb-DF v2	DFDC
2	XceptionNet	93.0	65.27	69.90
3	EfficientNet-B4	99.22	68.52	70.12
4	ViT		99.40	93.63
5	GFADE	99.79	93.88	80.81
6	WMamba		96.29	82.97

	FID ↓	SSIM ↑	ID Similarity ↑	PSNR ↑
FSGAN	10,5	0.931		27
SimSwap	12	0,93	0,92	
FlashFace	26,60	0,9	0,95	31

Ваши вопросы