Обучение диффузионных моделей (LoRa)

Выполнила:
Виноградова

Что будем обсуждать?

- Генеративные модели и диффузионный подход
- Архитектура современных диффузионных моделей
- Проблема обучения и fine-tuning больших моделей
- Метод Low-Rank Adaptation (LoRA)
- Использование LoRA

Диффузионные модели

Диффузионные модели — это вероятностные генеративные модели, которые учатся превращать шум в данные.

Основные задачи:

- Генерация изображений
- Условная генерация изображений (например по тексту)
- Повышение разрешения изображений

Диффузионные модель

Идея в том, что мы постепенно превращаем изображение в шум, а затем обучаем модель делать обратный процесс — восстанавливать изображение из шума.

Forward diffusion process

Математически процесс задаётся как цепочка распределений:

$$q(x_{1:T} \mid x_0) = \prod_{t=1}^{T} q(x_t \mid x_{t-1})$$

Каждый шаг добавления шума задаётся нормальным распределением:

$$q(x_t \mid x_{t-1}) = \mathcal{N}\left(\sqrt{1-\beta_t}\, x_{t-1}, \beta_t I\right)$$

Логика в том, что мы немного уменьшаем вклад изображения и добавляем гауссовский шум.

β_t — уровень шума на шаге t

I — единичная матрица

Параметры β_1 ... β_T называют **расписанием дисперсии** (noise schedule).

Reverse diffusion process

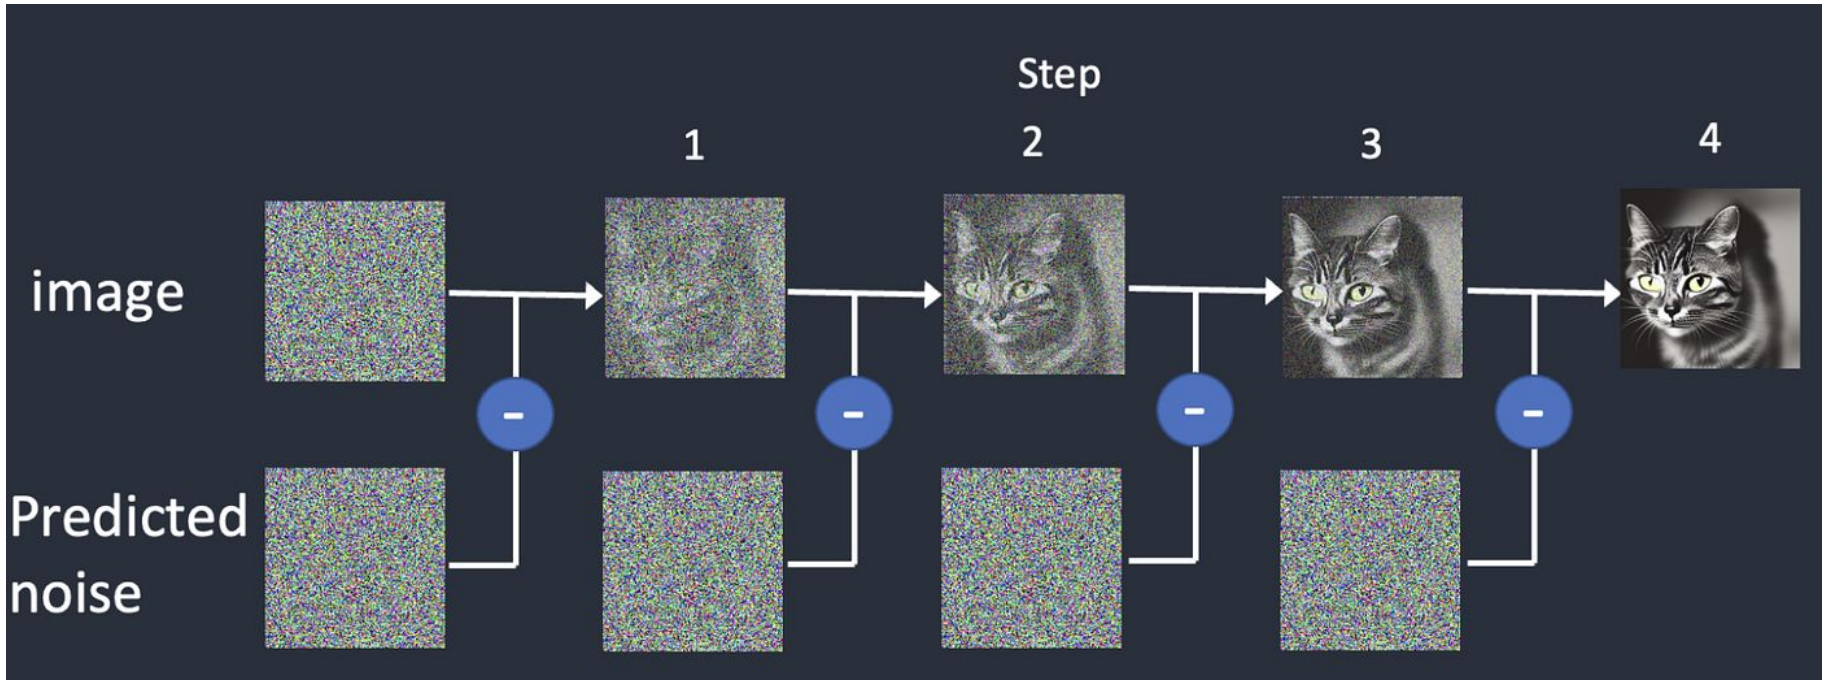

Нейросеть получает:

- зашумлённое изображение x_t
- номер шага t

А далее она предсказывает **какой шум нужно убрать**.

Для обучения используется **MSE между настоящим шумом и предсказанным**.

Stable Diffusion

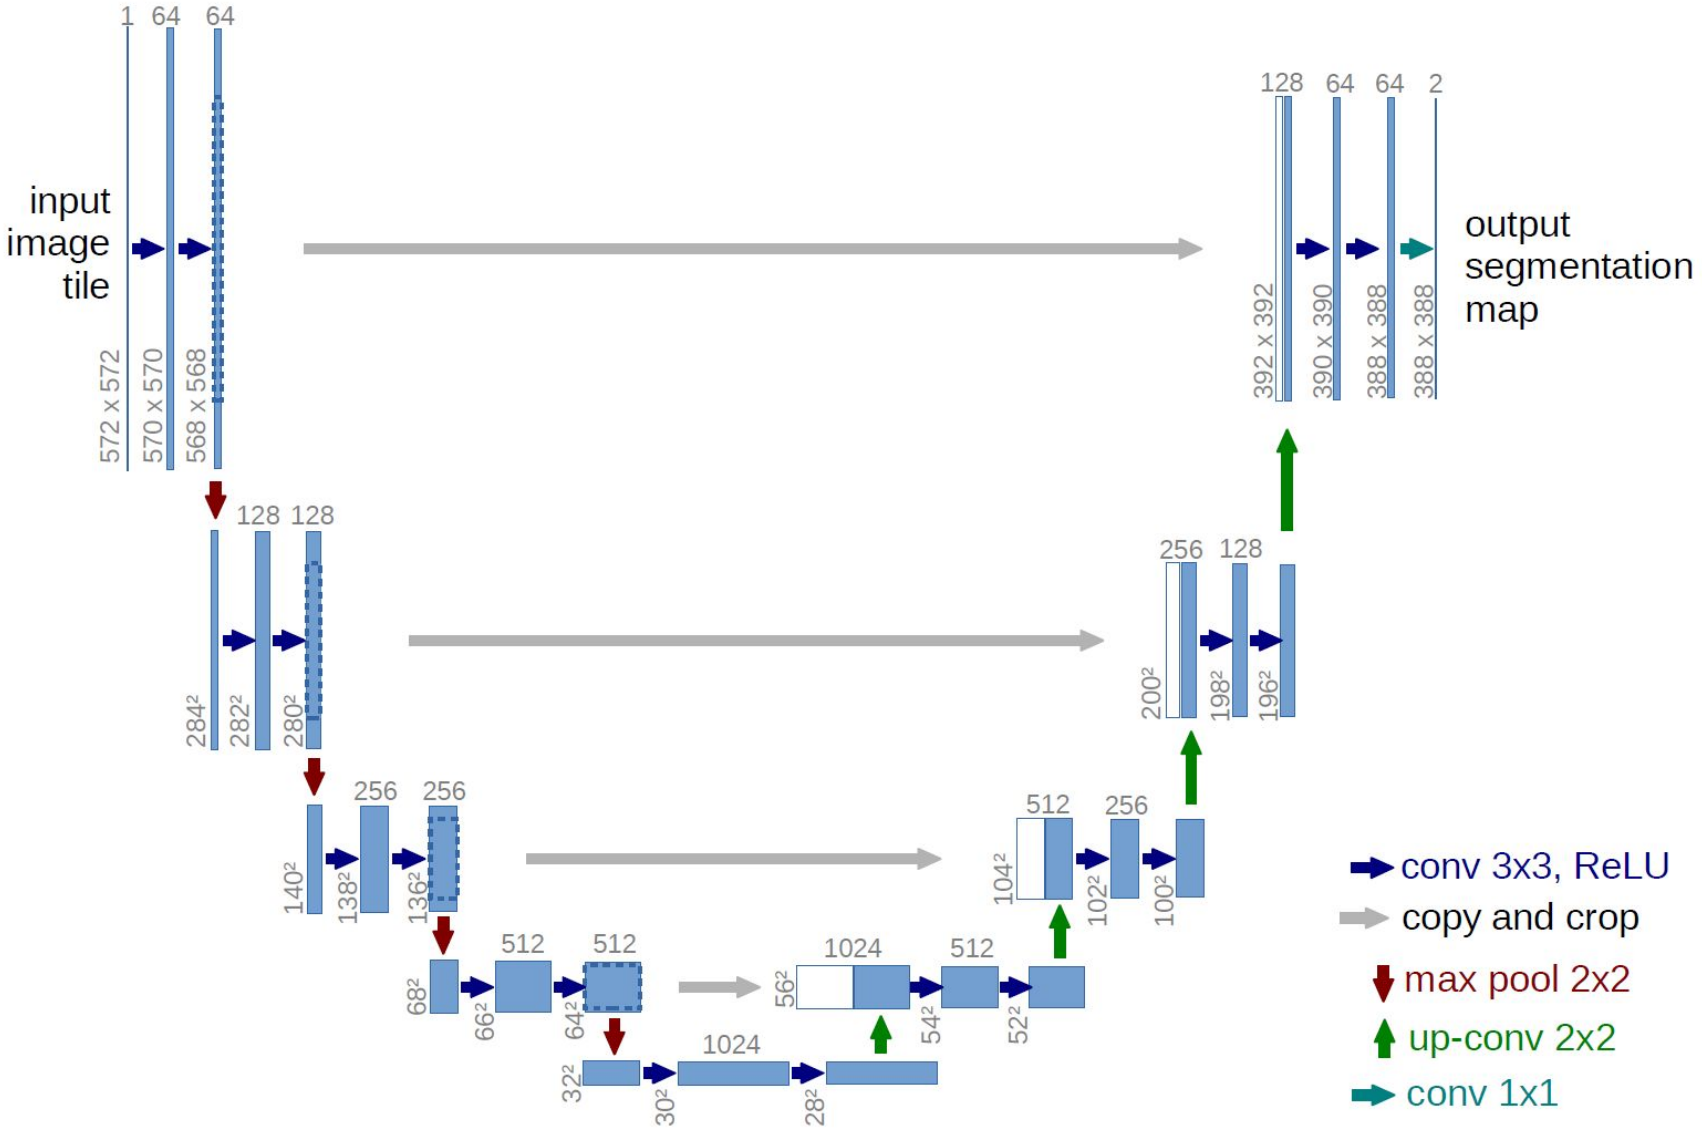

Основные компоненты

1. **VAE encoder** (переводит изображение в латентное пространство)
2. **U-Net** (предсказывает шум)
3. **Text encoder** (кодирует текстовое условие)

Проблемы обучения

Современные модели имеют **сотни миллионов и миллиарды параметров**.

При классическом fine-tuning:

- обновляются **все веса модели**
- требуется много **GPU-памяти**
- нужно хранить **отдельную копию модели для каждой задачи**

Как пришли к LoRa

Многие предыдущие работы показали, что перепараметризованные большие модели располагаются на низкой внутренней размерности. Основная идея LoRA заключается в том, что изменение весов во время адаптации модели также имеет низкий внутренний ранг/размерность. Т.е:

если W□□ представляет веса одного слоя,

а ΔW□□ представляет изменение весов во время адаптации модели,

авторы LoRa предполажили, что ΔW□□ является матрицей низкого ранга, т.е.

$$rank(\Delta W_{n\times k}) << \min(n, k)$$

В чем смысл?

При адаптации такой модели к конкретной задаче или набору данных необходимо выделить или переучить лишь несколько признаков. Это означает, что матрица обновления (ΔW) может быть матрицей низкого ранга.

Формула

В обычном fine-tuning обновляется матрица весов:

$$W' = W + \Delta W$$

LoRA предполагает, что обновление имеет **низкий ранг**:

$$\Delta W = BA$$

$$W' = W + BA$$

Как достигается выигрыш?

Тут играет роль “Low Rank” — матрицу маленького ранга можно представить как произведение двух меньшей размерности.

Наша матрица может быть размером 100 на 70, но ранг, то есть количество линейно независимых строк или столбцов может быть меньше чем 70 — например 4 или 20.

Обычный слой: d×k

LoRA: r(d+k)

где, r≪d,k

- $d = 4096$
- $k = 4096$
- $r = 8$

100x2 x 2x70 = 100x70

Архитектура LoRa

В LoRA основная матрица весов **не изменяется**. Она остаётся **замороженной**.

Вместо этого в слой добавляется дополнительное преобразование:

BA

Таким образом итоговый выход слоя становится:

h=Wx+BA

При обучении обновляются только **матрицы A и B**, которые имеют гораздо меньший размер. Это позволяет **значительно сократить число обучаемых параметров**.

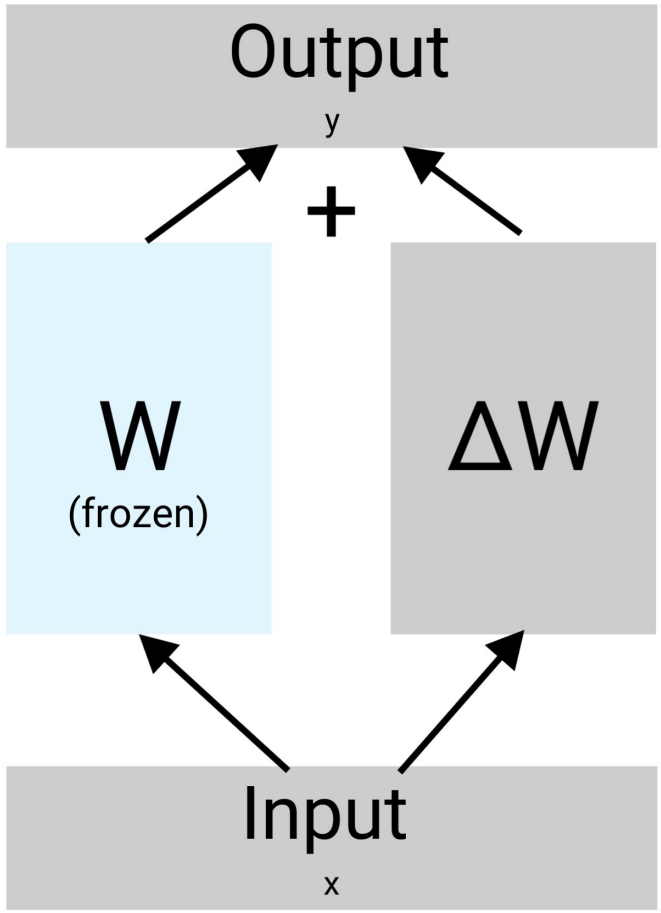

Как достигается выигрыш?

Таким образом, во время обучения нам необходимо хранить в памяти веса W исходной модели и дообучаемой, а считать градиенты только для "новых" маленьких матриц A и B.

При инициализации модели мы создаем матрицу A случайным образом (например из гауссового распределения), а матрицу B инициализируем нулями, что бы изначально

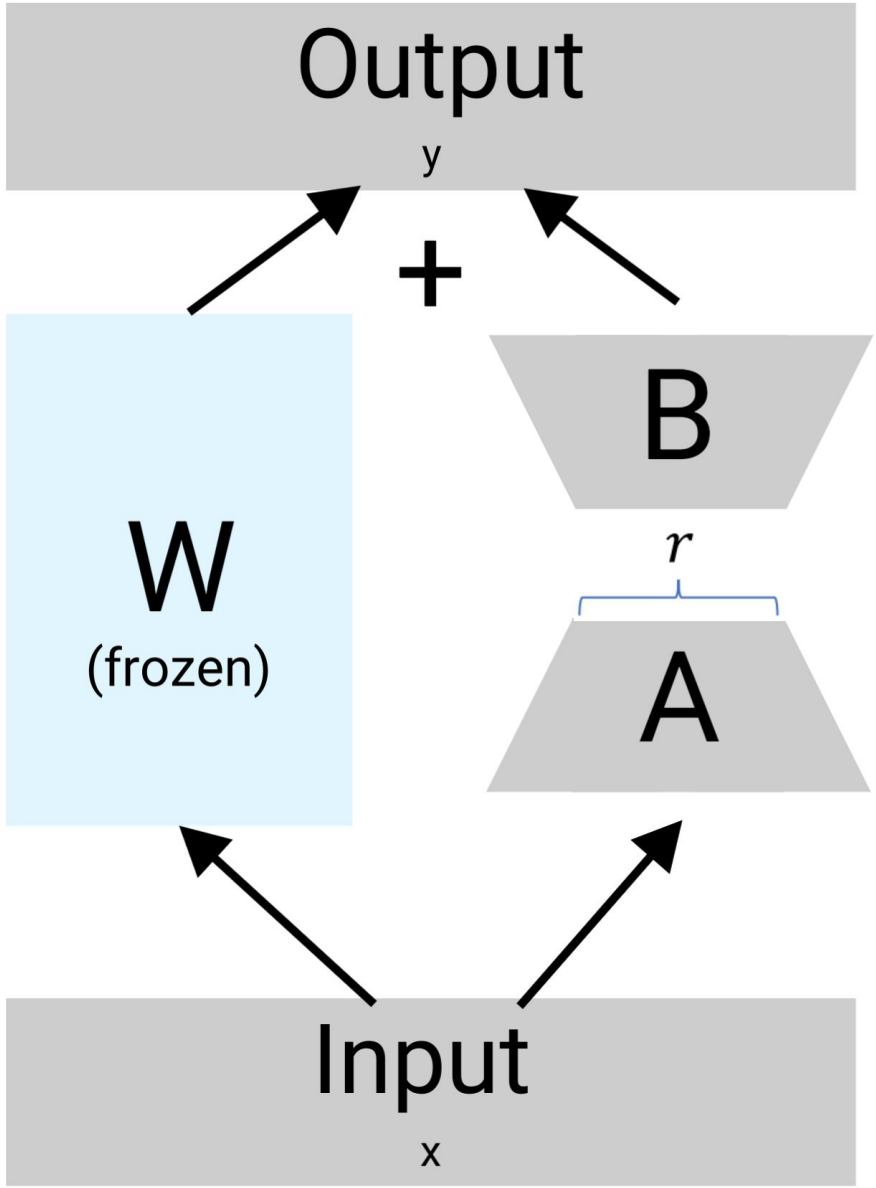

Архитектура LoRa из оригинальной статьи

Данный метод ограничивает ранг матрицы обновления **ΔW,** используя её разложение по рангам.

Он представляет **ΔW□□** как произведение двух матриц низкого ранга **B□r** и **Ar□,**

где **r << min(n, k)** . Это означает, что прямой проход слоя, изначально Wx, модифицируется до **Wx** + **BAx (как показано на рисунке ниже).**

Для A используется случайная гауссова инициализация, а **B** изначально равна **0** , поэтому **BA=0** в начале обучения.

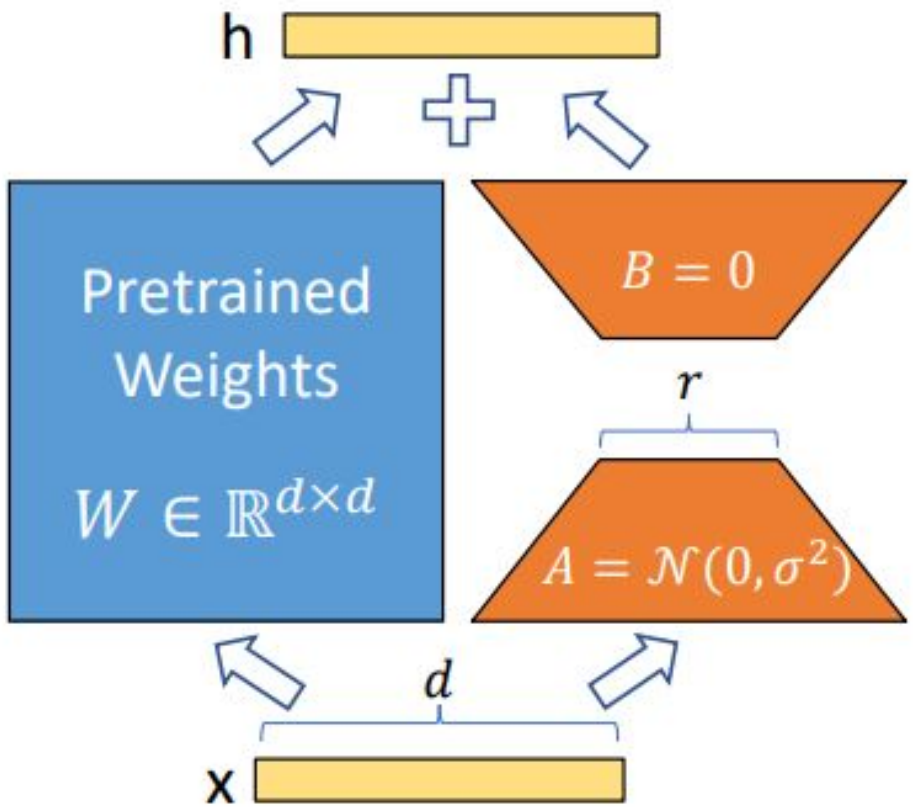

Практические преимущества

- Сокращение времени и пространства обучения : Используя описанную выше методику, в процессе адаптации модели необходимо настроить $r(n + k)$ параметров.
- Отсутствие дополнительного времени на вывод : при использовании в производственной среде мы можем явно вычислить $W' = W + BA$ и сохранить результаты, выполняя вывод как обычно. Это гарантирует отсутствие дополнительной задержки во время вывода.
- Упрощенное переключение между задачами: замена только весов LoRA вместо всех параметров позволяет дешевле и быстрее переключаться между задачами. Можно создавать и легко заменять множество пользовательских моделей.

Применение

Основные области применения:

- **Large Language Models (LLM)**
  адаптация моделей под новые задачи

- **Diffusion models**
  обучение стилей, персонажей и доменных моделей

- **Computer Vision**
  адаптация CNN и Vision Transformers

- **Multimodal models**
  модели текст-изображение и видео-генерации

- **Domain adaptation**
  адаптация моделей под специализированные данные

Вывод

- LoRA используется для эффективного дообучения больших нейронных сетей в разных областях машинного обучения.
- Изначально метод был предложён для **больших языковых моделей**, где он позволил адаптировать модели под новые задачи без полного fine-tuning.
- Позже LoRA получила широкое распространение в **diffusion-моделях**, таких как Stable Diffusion.

  Здесь она используется для обучения новых **стилей, персонажей и визуальных концепций**.
- Также LoRA применяется в задачах **computer vision**, например для адаптации моделей сегментации или классификации.
- Ещё одно направление — **мультимодальные модели**, которые объединяют текст, изображения и видео.
- Таким образом, LoRA стала одним из наиболее популярных методов **parameter-efficient fine-tuning** современных нейронных сетей.

Источники

1. Hu, E. J., Shen, Y., Wallis, P., et al.
   LoRA: Low-Rank Adaptation of Large Language Models.
   arXiv preprint arXiv:2106.09685, 2021.
   https://arxiv.org/pdf/2106.09685
2. Zorin, A.
   LoRA — Low-Rank Adaptation для дообучения больших моделей.
   Habr, 2023.
   https://habr.com/ru/articles/747534/
3. ML6 Team.
   Low-Rank Adaptation: A Technical Deep Dive.
   ML6 Blog, 2023.
   https://www.ml6.eu/en/blog/low-rank-adaptation-a-technical-deep-dive
4. Benkirane, A., et al.
   LoRA-based methods on U-Net for transfer learning in aneurysmal subarachnoid hematoma segmentation.
   arXiv:2508.01772, 2025.
   https://arxiv.org/html/2508.01772v3