ИТМО

Доклад по обработке и генерации изображений

Скелетные модели компьютерного зрения

Автор: Шпилева Анастасия Алексеевна, M34341

14.06.2025

Что такое скелетные модели?

Скелетная модель – это компактное представление формы объекта через его ось или граф ключевых точек. Вместо работы с полным изображением мы можем оперировать только центральной структурой. Это снижает размерность данных, сохраняет топологию и упрощает задачи анализа формы.

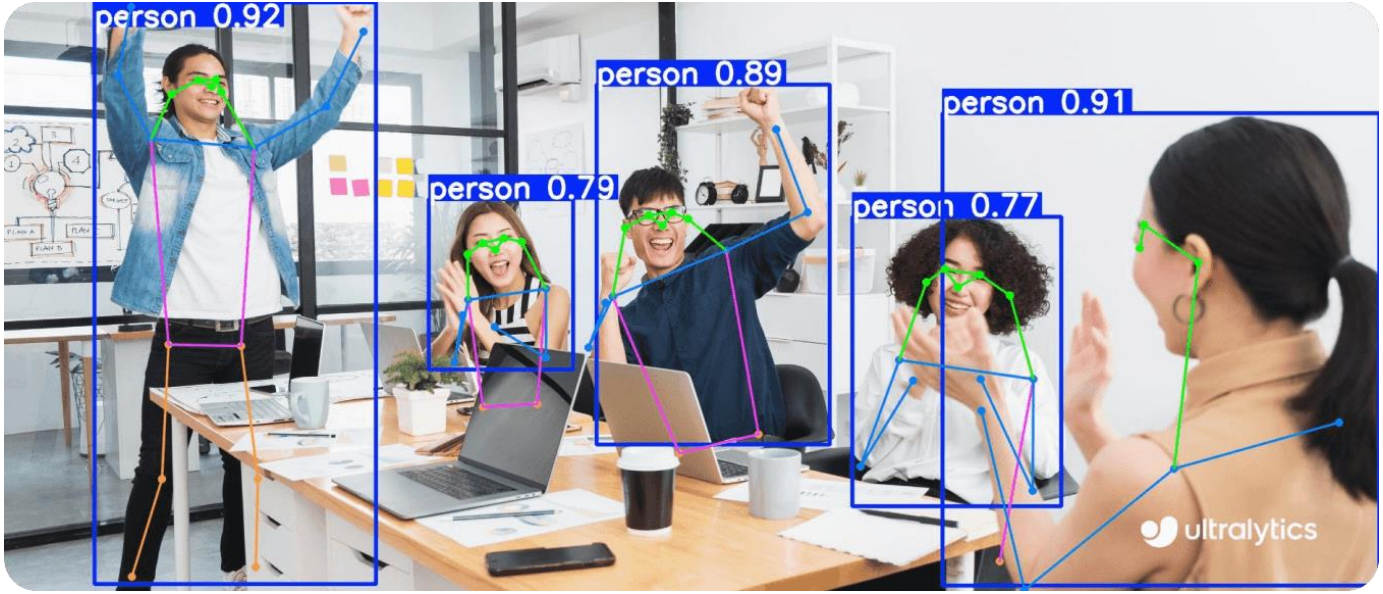

Мотивация: зачем использовать скелетные модели?

1. Компактное представление движения
Скелетная модель описывает человека через ограниченное число ключевых точек, что значительно уменьшает размерность данных по сравнению с изображением.

2. Инвариантность к внешним факторам
Поза менее чувствительна к освещению, фону, одежде и текстуре по сравнению с пиксельным представлением.

3. Интерпретируемость
Координаты суставов легко интерпретировать и анализировать с точки зрения биомеханики и структуры тела.

4. Удобство для анализа динамики
Скелет естественно моделируется как граф, что упрощает анализ движений, траекторий и действий во времени.

Применение

1. Медицина и реабилитация
- Анализ походки и двигательных нарушений
- Оценка прогресса реабилитации

2. Спорт и фитнес
- Биомеханический анализ техники
- Автоматический коучинг и оценка упражнений

3. Видеонаблюдение и безопасность
- Распознавание подозрительного поведения
- Анализ падений
- Мониторинг массовых мероприятий

4. AR/VR и индустрия развлечений
- Motion capture без маркеров
- Управление аватарами
- Игровые интерфейсы на основе движений

5. Робототехника и HRI
- Интерпретация жестов и прогнозирование действий человека

6. Автономные системы
- Предсказание поведения пешеходов и анализ сцен дорожного движения

Математическая модель: формализация

Математическая модель движения человека представляется в виде комбинации из четырех компонентов:

1. ***Опорные точки***: модель опорных точек представляет собой вектор-столбец P с координатами опорных точек $P_1, P_2, \dots, P_{\mathrm{N}}$, где

- $x_1, x_2, \dots, x_{\mathrm{N}}$ — координаты опорных точек по оси OX;
- $y_1, y_2, \dots, y_{\mathrm{N}}$— по оси OY
- Опционально еще можно добавить третье измерение – глубину $\mathrm{z}_1, \mathrm{z}_2, \dots, \mathrm{z}_{\mathrm{N}}$

2. **Смежности точек**: Модель смежности точек описывает ребра графа и представляет собой квадратную матрицу $X(P)$, элементами которой являются значения функции 0 или 1 в зависимости от того, соединены ли они ребром.

3. **Расположение**: Модель расположения описывает изменение положения опорных точек в пространстве и имеет вид матрицы $U(P) = [u_{ij}(P_i)]$, где $u_{ij}(P_i)$— координаты точек P_i , считываемые с каждого кадра видеопотока во времени t.

4. **Движение**: Модель движения описывает непосредственно поведение фигуры и представляет собой вектор-столбец $F(P) = [F_i(P_i)]$, где $F_i(P_i)$ — функция, описывающая движение каждой из точек $P_1, P_2, \dots, P_N$.

$$\mathbf{P} = \begin{bmatrix} P_1 \\ P_2 \\ \vdots \\ P_{15} \end{bmatrix} = \begin{bmatrix} (x_1, y_1) \\ (x_2, y_2) \\ \vdots \\ (x_{15}, y_{15}) \end{bmatrix},$$

$$\mathbf{X}(\mathbf{P}) = \begin{bmatrix} \Delta_{1,1} & \Delta_{1,2} & \cdots & \Delta_{1,15} \\ \Delta_{2,1} & \Delta_{2,2} & \cdots & \Delta_{2,15} \\ \cdots & \cdots & \ddots & \cdots \\ \Delta_{15,1} & \Delta_{15,2} & \cdots & \Delta_{15,15} \end{bmatrix}.$$

$$\mathbf{U}(\mathbf{P}) = \\ = \begin{bmatrix} u_{1,1}(P_1) & u_{1,2}(u_{1,1}(P_1)) & \cdots & u_{1,t}(u_{1,t-1}(P_1)) \\ u_{2,1}(P_2) & u_{2,2}(u_{2,1}(P_2)) & \cdots & u_{2,t}(u_{2,t-1}(P_2)) \\ \cdots & \cdots & \ddots & \cdots \\ u_{15,1}(P_{15}) & u_{15,2}(u_{15,1}(P_{15})) & \cdots & u_{15,t}(u_{15,t-1}(P_{15})) \end{bmatrix} =$$

Математическая модель: визуализация

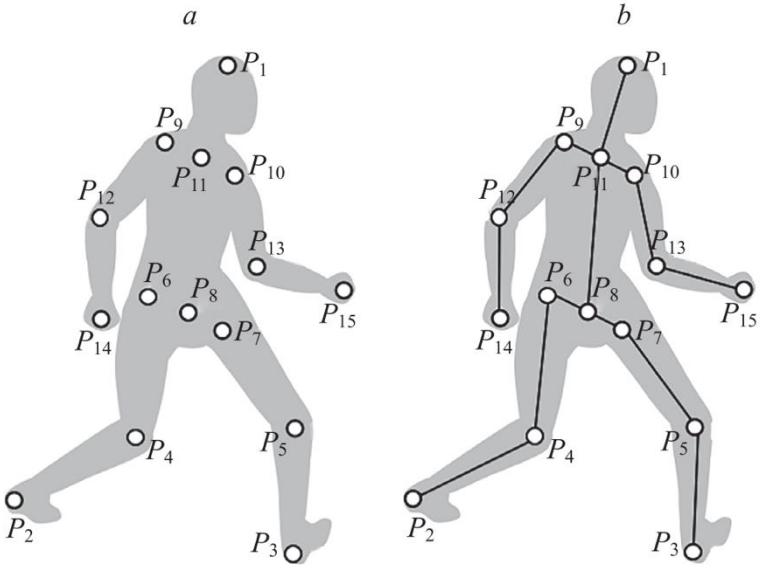

Рис. 1. Расположение точек на фигуре человека (*a*); узлы дерева и связывающие их ребра (*b*)

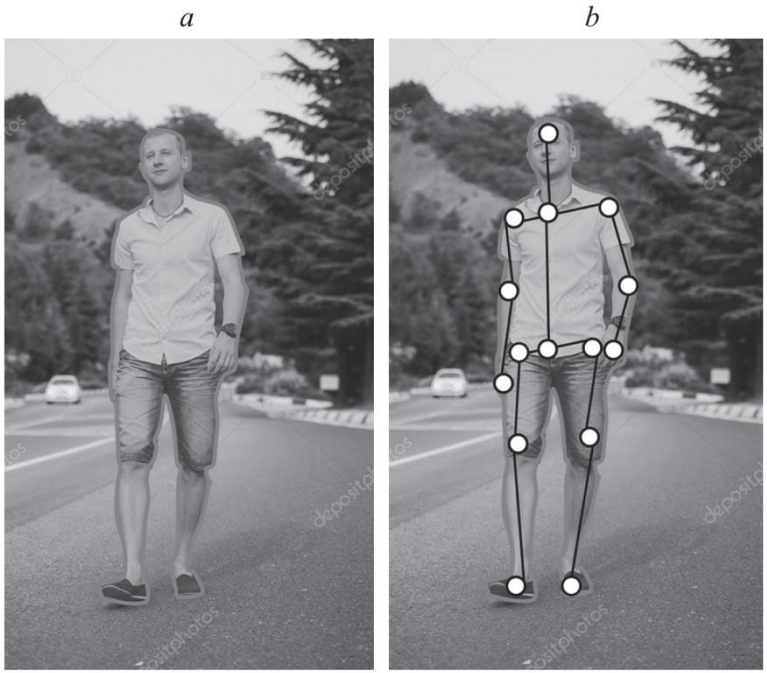

Рис. 2. Изображения с выделенной областью фигуры (*a*) и после построения математической модели (*b*)

Различные матмодели человеческого тела

Различные модели человеческого тела:

- a – модель скелета
- b – плоская модель,
- c – кинематическая модель,
- d – объемная модель.

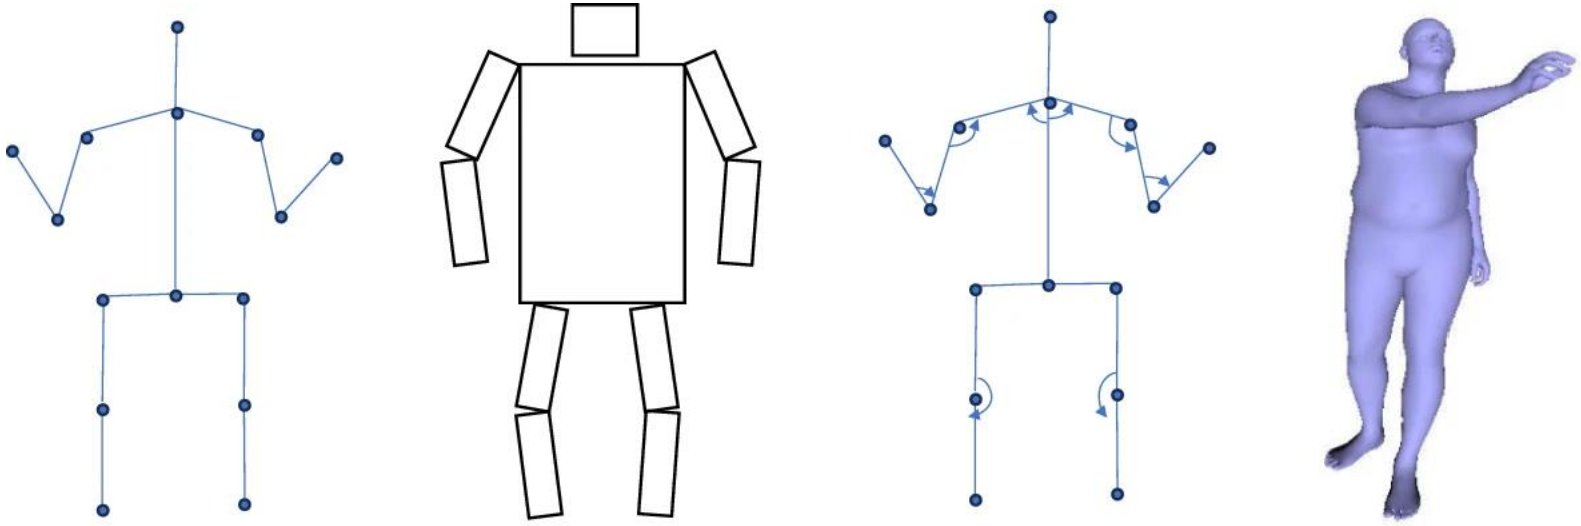

a b c d

Традиционные подходы

До появления моделей глубокого обучения традиционные методы, использующие обнаружение контуров (Jabri et al. 2000) и анализ силуэтов (Haritaoglu et al. 1998), были одними из первых методов определения позы. Однако они не позволяли определять сложные позы и позы при наличии препятствий.

Ключевым поворотным моментом в развитии методов определения позы стало появление таких моделей, как

1. Модель активной формы (Active Shape Model, ASM) (Cootes et al. 1995),
2. Модель активной внешности (Active Appearance Model, AAM) (Cootes et al. 1998). ASM.

Первая использует метод главных компонент и выявляет изменения в форме с помощью статистического моделирования, а AAM идет еще дальше, интегрируя изменения как в форме, так и в текстуре. Эти модели заложили основу для современных методов определения позы человека, таких как извлечение признаков и статистическое обучение.

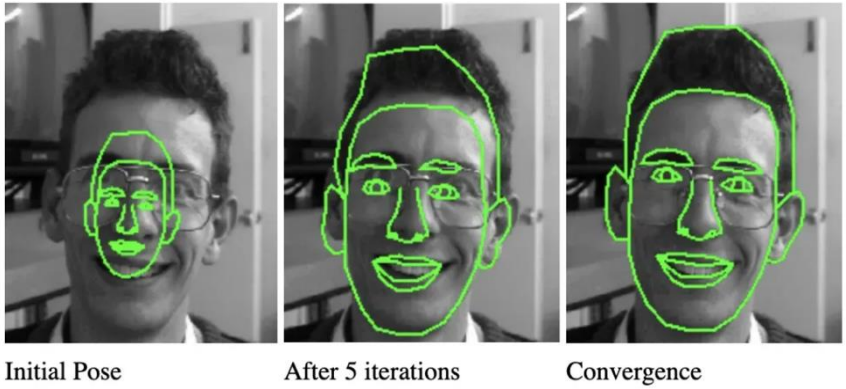

Визуализация работы ASM

DL модели: систематизация

Подходы к pose estimation можно классифицировать по нескольким ключевым осям:

1. По размерности:
- 2D (координаты на изображении)
- 3D (пространственная реконструкция позы)

2. По числу людей:
- Single-person
- Multi-person

3. По архитектуре:
- Top-down (детекция человека → оценка позы)
- Bottom-up (сначала точки → затем группировка)
- One-stage (прямое предсказание скелетов)

4. По способу предсказания:
- Heatmap-based
- Direct regression
- Part Affinity Fields

5. По временной обработке (видео):
- Покадрово
- С учётом временного контекста (RNN, Transformer, фильтрация)

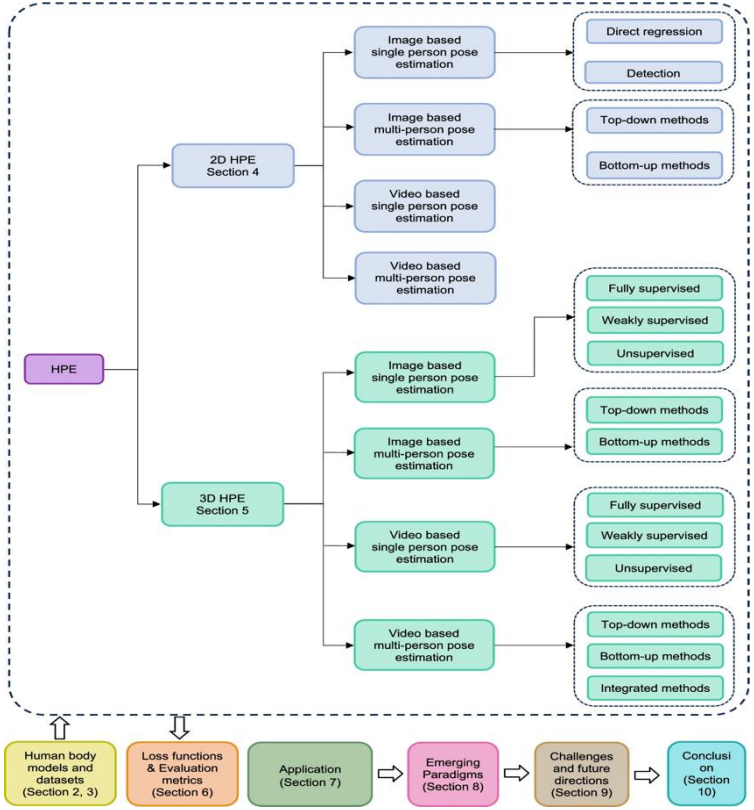

DL модели: Image-based single-person 2D

Методы на основе прямой регрессии
Идея: В методах прямой регрессии модель HPE напрямую предсказывает координаты ключевых точек, те положение (x, y) каждого сочленения на исходном изображении.
Архитектура: CNN → полносвязная сеть.

Методы на основе детекции
Идея: для каждой ключевой точки создается отдельная тепловая карта, где каждый пиксель показывает вероятность ее нахождения. Карты строятся на основе распределения Гаусса с пиком в истинной позиции точки.
Архитектура: модель «песочные часы»:

1. Состоит из кодера (сжатие, выделение признаков) и декодера (восстановление разрешения).
2. Использует K последовательных модулей и skip-связи.
3. На выходе — тепловые карты ключевых точек.

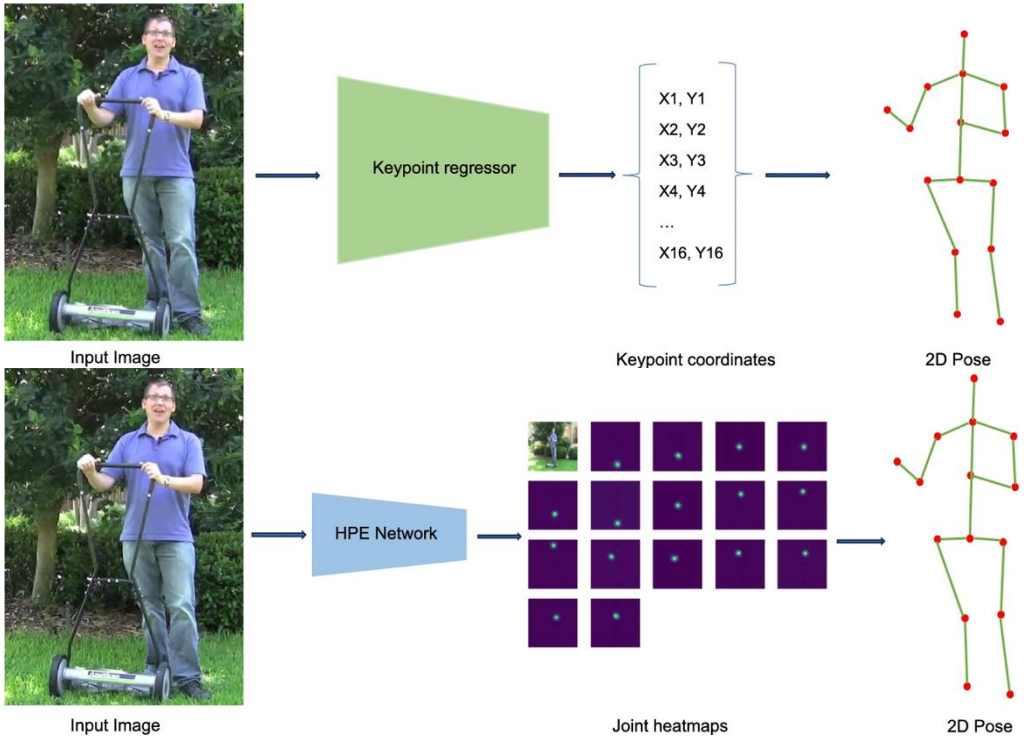

DL модели: Image-based multi-person 2D

Оценка позы нескольких человек применяется к изображениям, на которых изображено несколько людей.

Это более сложная задача, чем оценка позы одного человека, поскольку модели приходится учитывать количество людей и их взаимное перекрытие.

MPPE можно разделить на два подхода: «сверху вниз» и «снизу вверх». На рисунках показаны подходы «сверху вниз» и «снизу вверх» соответственно.

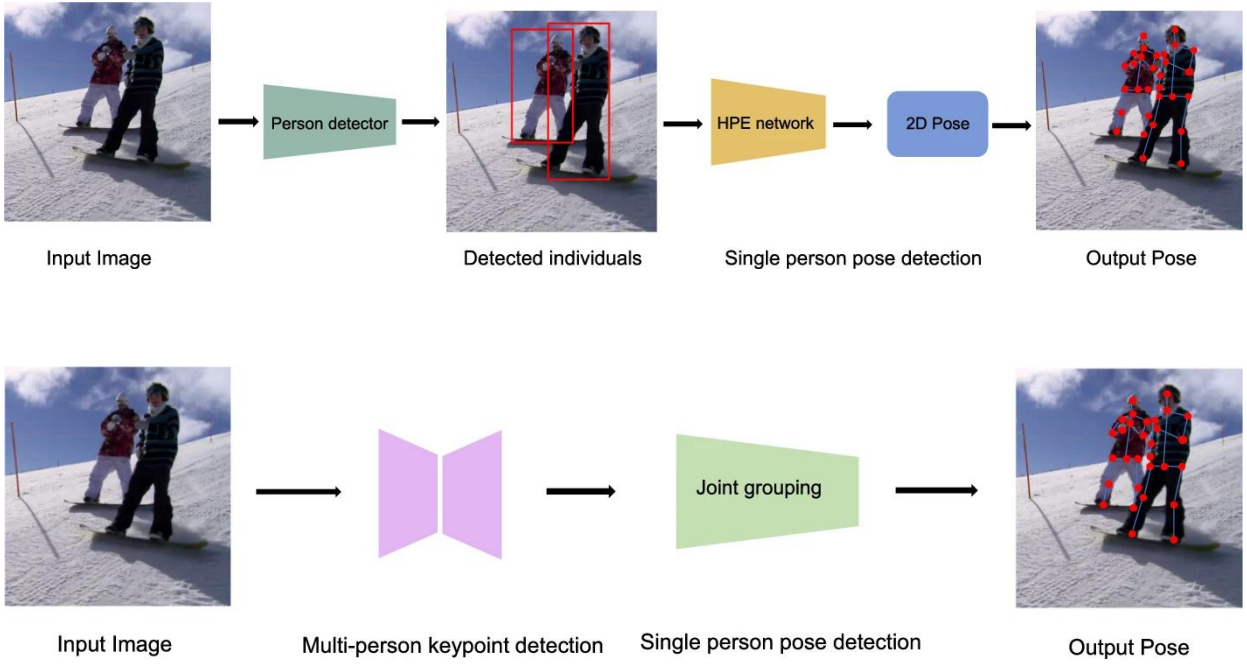

DL модели: разбор YOLO Pose Estimation

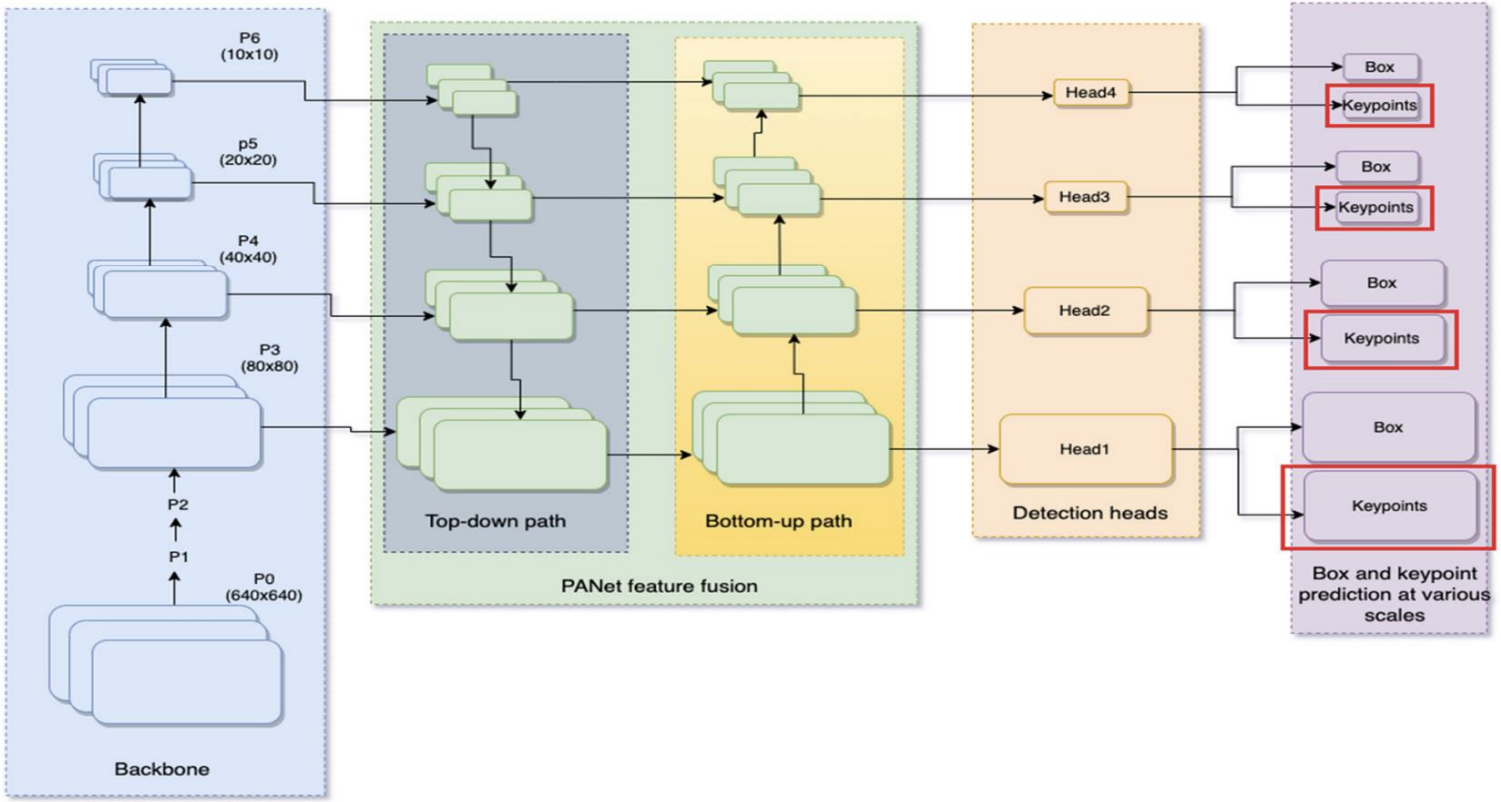

Сравнение подходов image-based SPPE и MPPE

Category	Method	Year	Architecture Type	Dataset	Metric	Performance
SPPE single person	DeepPose (Toshev and Szegedy 2014b)	2014	CNN	FLIC	PCP	0.69
	Stacked Hourglass (Newell et al. 2016)	2016	CNN	MPII	PCKh@0.5	90.9
	TFPose (Mao et al. 2021a)	2021	Transformer	COCO, MPII	AP, PCKh	72.2, 90.4
	Poseur (Mao et al. 2022)	2022	Hybrid (CNN+Transformer)	COCO, MPII	AP, PCKh	75.4, 90.5
	Papaioannidis et al. (2023)	2023	Hybrid (CNN+GAN)	COCO, MPII	AP, PCKh	71.7, 88.3
	LAP (Kappan et al. 2024)	2024	CNN	COCO	AP	72.07
	EL-HRNet (Li et al. 2024b)	2024	CNN	COCO, MPII	AP, PCKh@0.5	67.1, 87.7
MPPE multi person	OpenPose (Cao et al. 2017)	2017	CNN	MPII, COCO, foot dataset	mAP, AP	75.6, 61.0
	Simple Baseline (Xiao et al. 2018)	2018	CNN	COCO, PoseTrack, MPII	AP, mAP	72.2, 73.9
	PifPaf (Kreiss et al. 2019)	2019	CNN	COCO	AP	66.7
	HRNet (Wang et al. 2021a)	2020	CNN	COCO	AP	76.3
	AlphaPose (Fang et al. 2023)	2022	CNN	COCO, PoseTrack	AP, mAP	0.484, 74.7
	DetPoseNet (Ke et al. 2022)	2022	CNN	COCO, OCHuman	AP, mAP	78.3, 0.381
	ViTPose (Xu et al. 2022)	2022	Transformer	COCO	AP	79.1
	Full-BAPose (Artacho and Savakis 2023)	2023	CNN	COCO, CrowdPose	AP	71.9, 72.2
	Qu et al. (2023)	2023	CNN	COCO, CrowdPose	AP	73.7, 74.1
	ViTPose++ (Xu et al. 2024b)	2024	Transformer	COCO, MPII	AP, PCKh	79.4, 94.2

Таблица сравнения image-based моделей

DL модели: Video-based 2D single-person

SPPE на основе видео предполагает определение ключевых точек человека в последовательности кадров. В отличие от методов на основе изображений, которые предсказывают положение тела для каждого кадра/изображения независимо друг от друга, методы на основе видео используют временную согласованность движений человека.

Типовые архитектуры:

Frame-wise + Temporal refinement

1. 2D pose на каждом кадре (CNN/Transformer backbone)
2. Временная модель:

- Temporal Convolution (TCN)
- RNN / LSTM
- Temporal Transformer (attention между кадрами)
- Graph Convolution (по суставам + времени)

End-to-end spatiotemporal модели

- 3D CNN (I3D-подобные)
- Spatiotemporal Transformer
- ST-GCN (пространственно-временные графы)

Модель сразу обрабатывает последовательность кадров

DL модели: Video-based 2D multi-person HPE

Multi-person анализ HPE — это задача прогнозирования и отслеживания поз нескольких людей в видеопотоке. Он гораздо сложнее по сложности модели и времени инференса чем single-person из-за быстрых движений людей и сложных взаимодействий.

Типовые архитектуры:

Detect → Pose → Track (pipeline)

- Детекция людей (YOLO, Faster R-CNN)
- Pose estimation (обычно top-down)
- Tracking: Kalman filter, SORT / DeepSORT, Re-ID embedding

Joint Pose + Tracking (end-to-end)

Модель одновременно: оценивает ключевые точки и связывает их во времени.
Используются:

- Spatiotemporal Graph Networks
- Temporal Transformers
- Pose flow / Keypoint flow (как оптический поток, только на точках)
- Attention между людьми и кадрами

Bottom-up + Temporal grouping

- Детекция всех ключевых точек
- Пространственная группировка
- Временная ассоциация

Сравнение подходов video-based SPPE и MPPE

Если коротко:

Single-person video HPE → пространственно-временные модели для стабилизации и 3D-восстановления.

Multi-person video HPE → пространственно-временные модели + механизм трекинга и ассоциации людей.

Общее: spatiotemporal modeling (TCN, Transformer, GNN).

Различие: необходимость устойчивого tracking во времени.

Category	Method	Year	Architecture type	Dataset	Metric	Performance
SPPE	Pfister et al. (2015)	2015	CNN	BBC Pose	PCK	92
	LSTM Pose Machines (Luo et al. 2018)	2018	CNN	Penn Action, sub-JHMDB	PCK@0.2	97.7, 93.6
	UniPose (Artacho and Savakis 2020)	2020	CNN	LSP, MPII	PCK@0.2, PCKh@0.5	94.5, 92.7
	GLPose (Jiao et al. 2022)	2022	CNN	PoseTrack2017, PoseTrack2018	AP	83.1, 80.8
	DGT (Zhou et al. 2024)	2024	Transformer	Sub-JHMDB	PCK@0.2	98.8
	ListPose (Wu et al. 2025)	2025	Transformer	Penn Action, Sub-JHMDB	PCK	95.0, 89.9
MPPE	Detect-and-Track (Girdhar et al. 2018)	2018	CNN	PoseTrack2017	mAP	60.6
	Wang et al. (2020)	2020	CNN	PoseTrack 2017, PoseTrack 2018	AP	83.8, 81.5
	DCPose (Liu et al. 2021c)	2021	CNN	PoseTrack 2017, PoseTrack 2018	AP	82.8, 80.9
	SLT-Pose (Gai et al. 2023)	2023	Transformer	PoseTrack2017, PoseTrack2018	AP	84.2, 81.5
	DANet (Yang et al. 2024)	2024	CNN	PoseTrack 2017, PoseTrack 2018	AP	82.1, 80.1
	STDPose (Jiao et al. 2025)	2025	Transformer	PoseTrack2017, PoseTrack2018, PoseTrack2021	mAP	90.9, 88.0, 86.9

Таблица сравнения video-based моделей

DL модели: Image-based single-person 3D

Восстановление 3D координат суставов одного человека по одному RGB-изображению.

Типовые архитектуры:

2D → 3D lifting: сначала 2D ключевые точки, затем регрессия 3D позы

End-to-end monocular 3D: прямая регрессия 3D координат из изображения

SMPL-параметризация: предсказание параметров 3D-модели тела

Ключевые сложности

- Неоднозначность глубины самоокклюзии
- Ограниченность 3D-датасетов

DL модели: Image-based multi-person 3D

Восстановление 3D поз нескольких людей в одном изображении.

Типовые архитектуры:

Top-down: детекция людей → 3D поза для каждого.

Bottom-up: обнаружение 2D ключей → группировка → 3D lifting.

End-to-end multi-person 3D сети

Ключевые сложности

- Перекрытия и окклюзии
- Ошибки детекции влияют на 3D реконструкцию
- Необходимость согласованности глубины между людьми

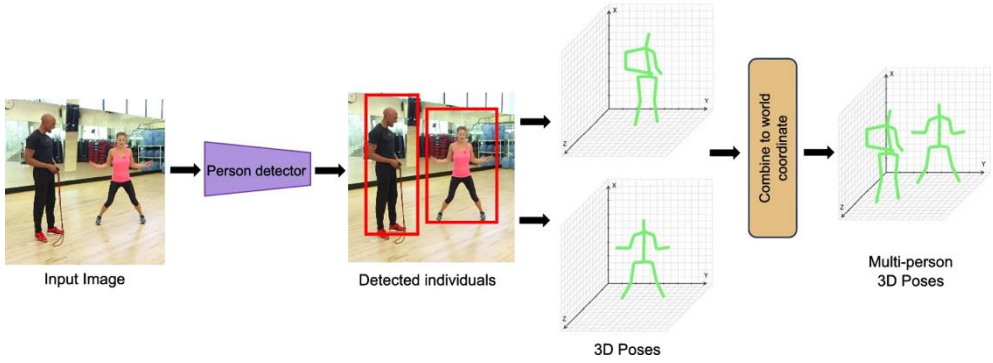

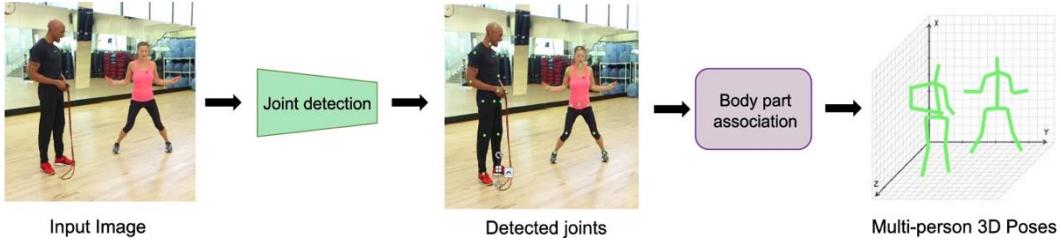

DL модели: Video-based multi and single person 3D

При оценке поз одного человека по видео основное внимание уделяется прогнозированию трехмерных положений суставов человека в последовательности кадров. Методы на основе видео используют пространственную и временную информацию для оценки и отслеживания положений суставов. Так что глобально мало чем отличается от 2D.

Category	Method	Year	Architecture Type	Dataset	Metric	Performance
SPPE	Luo et al. (2017)	2017	CNN	NTU-RGB+D	mAP	66.2
	Zanfir et al. (2020)	2020	CNN+Normalizing Flow	3DPW, H80K	MPJPE	80.2, 84
	Kundu et al. (2020)	2020	CNN	Human3.6M, MPI-INF-3DHP	PMPJPE, MPJPE	89.4, 99.2
	TriPose (Gholami et al. 2021)	2021	CNN	Human3.6M, MPI-INF3DHP	MPJPE	64.4, 105.6
	GAST-Net (Liu et al. 2021a)	2021	Hybrid (Graph Attention + CNN)	Human3.6M	MPJPE	46.2
	MixSTE (Zhang et al. 2022a)	2022	Transformer	Human3.6M, MPI-INF-3DHP	MPJPE	40.9, 54.9
	TCPFormer (Liu et al. 2025)	2025	Transformer	Human3.6M, MPI-INF-3DHP	MPJPE	37.9, 15.0
MPPE	Cheng et al. (2021a)	2021	Hybrid (CNN+GAN)	MuPoTS-3D	PCK	89.6
	Root-GAST-Net (El Kaid et al. 2022)	2022	CNN	MuPoTS-3D	3DPCK	56.8
	POTR-3D (Park et al. 2023)	2023	Hybrid (Transformer+CNN)	MuPoTS-3D	PCK	83.7
	Shen et al. (2023)	2023	CNN	MuPoTS-3D	3DPCK	83.2
	MVD-HPE (Li et al. 2024c)	2024	CNN	Custom dataset	PCP	97.2
	IMPos-DNet (Arora and Gangadharappa 2024)	2024	Hybrid (Transformer+CNN)	Human3.6 M, MuPoTs-3D, 3DPW, MPIINF-3DHP	MPJPE, PCK, PMPJPE, PCK	40.1, 84.4, 50.1, 87.88

Таблица сравнения video-based 3D моделей

Функции потерь и метрики

Метрики

Метрика	Что измеряет	Применение
mAP	Точность идентификации и ассоциации людей.	Multi-person
Percentage of Correct Parts (PCP)	Процент корректно определённых сегментов (линий между суставами)	Ранние 2D HPE
Percentage of Detected Joints (PDJ)	Процент ключевых точек в пределах заданного порога относительно размера тела	2D оценки
Percentage of Correct Keypoints (PCK)	Доля ключевых точек с ошибкой < threshold (относительно размера объекта)	2D HPE, улучшение PDJ
Intersection over Union (IoU)	Пересечение/объединение предсказанного и GT боксов (оценка детекции)	Оценка детектора перед HPE
Object Keypoint Similarity (OKS)	Ключевые точки с весами по важности, похожая на IoU для ключевых точек	COCO-style 2D ключи
Mean Per Joint Position Error (MPJPE)	Средняя евклидова ошибка позиционирования суставов	3D HPE

Функции потерь

Тип выхода	Основная функция потерь	Что минимизирует	Примечания
Регрессия координат	**MSE (Mean Squared Error)**	Среднеквадратичная ошибка между предсказанными и GT точками	Простая и широко используемая для прямой регрессии
	L1 Loss (MAE)	Средняя абсолютная ошибка	Менее чувствительна к выбросам, чем MSE
Heatmap-based	**Pixel-wise Cross-Entropy / KL Divergence**	Ошибка распределения вероятности на heatmap	Используется для обучения тепловых карт ключей
Комбинированные	**Regression + Classification Loss**	Сумма ошибок регрессии и классификации	Часто применяется, когда модель одновременно предсказывает heatmap и координаты
Структурно-направленные	**Bone-Length / Symmetry / Illegal-Angle Losses**	Дополнительные структурные ограничения	Улучшает анатомическую достоверность
Temporal / Smoothness Loss	**Velocity / Acceleration Consistency Loss**	Сглаживает траектории ключей во времени	Важная часть видео-HPE

Новые парадигмы в Human Pose Esimation

Vision-Language fusion: объединение визуальных признаков и языковых описаний для устойчивой локализации и семантического контекста.

Large Language Models (LLMs) in HPE: новые модели (например, LocLLM) используют язык для улучшения обобщения и обработки сложных случаев.

Multi-Modal Pose Estimation: интеграция RGB, глубины, LiDAR, термальных и других сенсорных данных для лучшей устойчивости в реальных условиях.

Эта новая волна исследований расширяет возможности HPE за пределы чисто визуальных методов, позволяя моделям учитывать семантику, дополнительные сенсорные сигналы и комплексный контекст.

Основные датасеты для 2D и 3D

Dataset	Year	2D/3D	Single pose		Multi pose		Joints	Size	Subjects
			Image	Video	Image	Video			
LSP (Johnson and Everingham 2010)	2010	2D	✓	✗	✗	✗	14	2K images	–
LSPE (Johnson and Everingham 2011)	2011	2D	✓	✗	✗	✗	14	10K images	–
FLIC (Sapp and Taskar 2013a)	2013	2D	✓	✗	✗	✗	10	5K images	–
JHMDB (Jhuang et al. 2013)	2013	2D	✗	✓	✗	✗	15	928 sequences	–
MPII (Andriluka et al. 2014)	2014	2D	✓	✗	✓	✗	16	40K images	–
COCO (Lin et al. 2015)	2017	2D	✓	✗	✓	✗	17	328K images	–
PoseTrack17 (Iqbal et al. 2017)	2017	2D	✗	✓	✗	✓	14+head box	60 sequences	2 to 16
PoseTrack18 (Andriluka et al. 2018)	2018	2D	✗	✓	✗	✓	15	550 sequences	2 to 16
PoseTrack21 (Doering et al. 2022)	2022	2D	✗	✓	✗	✓	15	763 sequences	–
EHPT-XC (Cho et al. 2024)	2024	2D	✗	✗	✗	✓	14	158 sequences	82 subjects
Human3.6M (Ionescu et al. 2014)	2013	3D	✗	✓	✗	✗	32	3.6M frames	11 subjects
MPI-INF-3DHP (Mehta et al. 2017a)	2017	3D	✗	✓	✗	✗	17	1.3M frames	8 actors
SURREAL (Varol et al. 2017)	2017	3D	✓	✓	✗	✗	-	6 M frames	145
Fit3D (Fieraru et al. 2021)	2021	3D	✗	✓	✗	✗	-	2.96M images	13 subjects
WorldPose (Jiang et al. 2024)	2024	3D	✗	✗	✗	✓	-	150K frames	88 subjects
AthletePose3D (Yeung et al. 2025)	2025	3D	✗	✓	✗	✗	55/86	1.3M frames	8 subjects

ИТМО

Доклад по обработке и генерации изображений

Спасибо за внимание!

Автор: Шпилева Анастасия Алексеевна, M34341

14.06.2025