Соответствие изображений и текста

Корнильев Артемий M4145

Проблема

Мало размеченных данных, но они нужны чтобы обучать модели

Решение

В интернете у многих картинок есть текстовое описание, можно взять его

Задачи:

- Найти лучшее изображение по тексту и наоборот
- Сгенерировать описание изображения (ImageCaptioning)

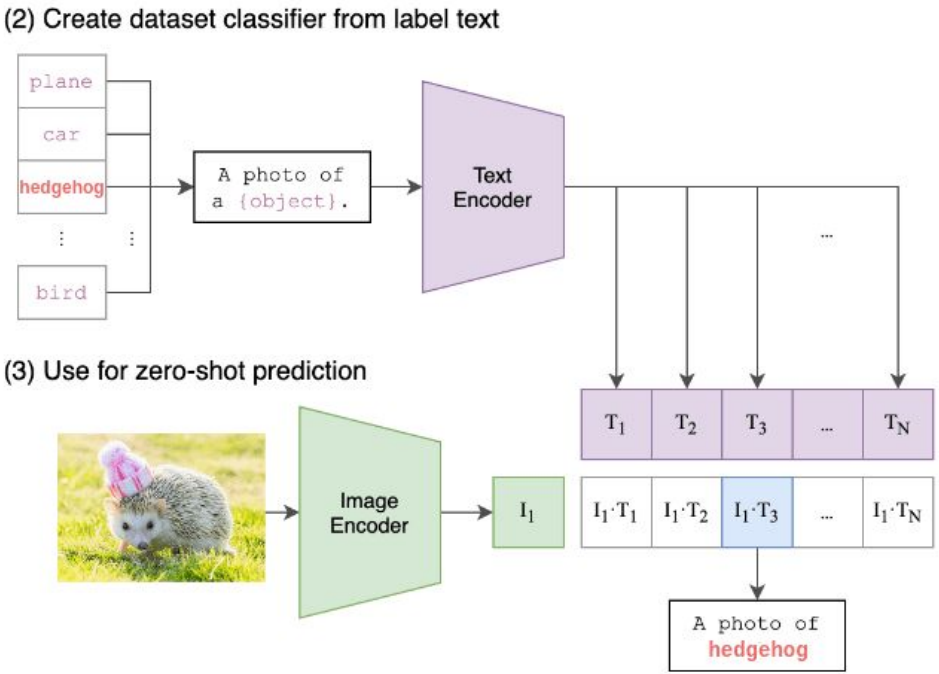

DeVISE (2013)

Обучаем текстовый и визуальный энкодер. После: проецируем визуальный эмбеддинг в векторное пространство.

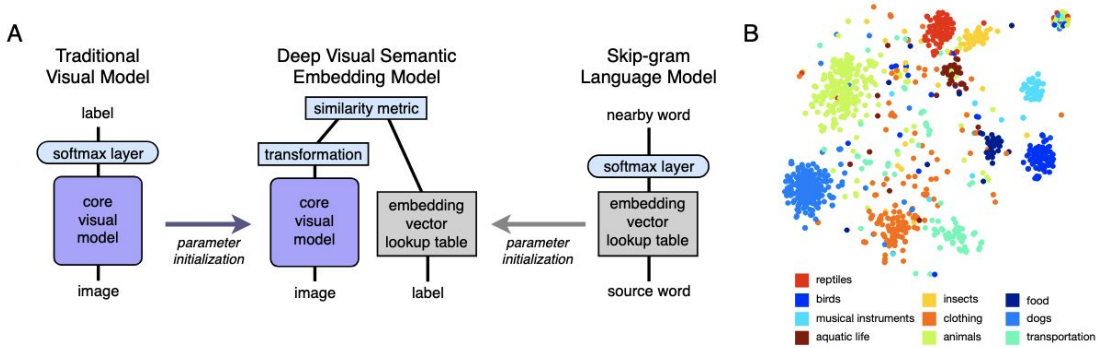

DeVISE (2013)

1) Обучаем и фиксируем word2vec CBOW
2) Обучаем CNN как классификатор
3) Добавляем линейный слой который преобразует эмбеддинги картинок в текстовые. Обучаем только матрицу проекции.
4) Дообучиваем CNN.

$$loss(image, label) = \sum_{j \neq label} \max[0, margin - \vec{t}_{label} M \vec{v}(image) + \vec{t}_j M \vec{v}(image)]$$

$\vec{v}(image)$ – Эмбеддинги изображения

M – Матрица проекции

$\vec{t}_{label}$. – Эмбеддинг правильного слова

$\vec{t}_j$. – Эмбеддинг неправильного слова

DeVISE (2013)

Приемущества:

- Может распознавать классы которых не было в обучении
- Масштабируется по числу классов
- Простая архитектура

Недостатки:

- текстовые эмбеддинги не дообучаются
- Некоторые классы становятся центрами
- Одностороннее сопоставление (Image -> Text)

SCAN (2018)

Идея: выучить точное соответствие между словами предложения и регионами изображения.

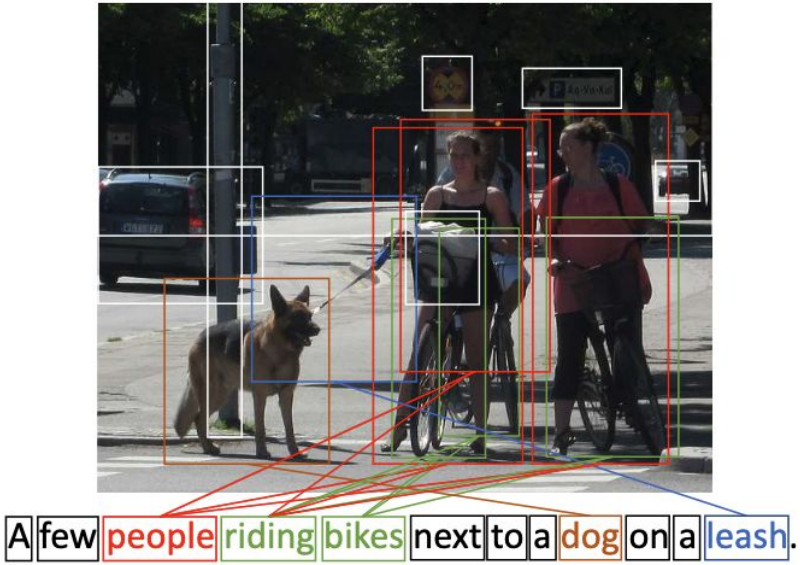

SCAN (2018)

- Картинка разбивается на 36 регионов

- Каждое слово сопоставляется каждому региону, и наоборот через Image-Text stacked cross attention.

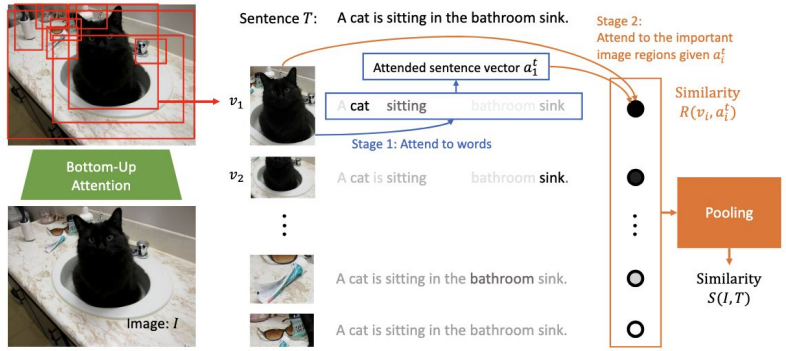

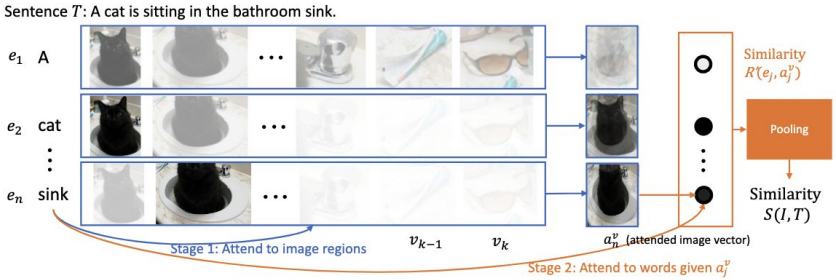

SCAN (2018)

- Вычисляются эмбеддиинги текста и изображения
- Находим косинусное сходство
- Получаем веса через softmax, учитываем вектор слова с соотвествующим весом.
- Находим косинусное сходство между новым эмбеддингом слова и эмбеддингом картинки

$$s_{ij} = \frac{v_i^T e_j}{||v_i||||e_j||}, i \in [1, k], j \in [1, n].$$

v_i – Эмбеддинги i-го сегмента изображения

e_j – Эмбеддинги текста

$$\alpha_{ij} = \frac{exp(\lambda_1 \bar{s}_{ij})}{\sum_{j=1}^{n} exp(\lambda_1 \bar{s}_{ij})},$$

$$a_i^t = \sum_{j=1}^{n} \alpha_{ij} e_j,$$

$$R(v_i, a_i^t) = \frac{v_i^T a_i^t}{||v_i||||a_i^t||}.$$

SCAN (2018)

$$L(I,T) = \sum_{\hat{T}} \left[\alpha - S(I,T) + S(I,\hat{T})\right]_+ + \sum_{\hat{I}} \left[\alpha - S(I,T) + S(\hat{I},T)\right]_+$$

где:

- I — изображение
- T — правильное текстовое описание изображения
- $\hat{T}$ — неправильное (негативное) описание
- $\hat{I}$ — неправильное изображение
- $S(I,T)$ — функция сходства между изображением и предложением
- α — margin (минимальный зазор между правильной и неправильной парой)

SCAN (2018)

Приемущества:

- Ищет соответствия между сегментами изображения и текстом.
- Высокая точность поиска текста по картинке и наоборот (SOTA на момент выхода)
- Простая архитектура

Недостатки:

- Высокая вычислительная сложность
- Сильно зависит от image энкодера

Show and tell: Neural Image Caption Generator (2015)

Через CNN получаем эмбеддинг изображения, который подается в RNN/LSTM декодер

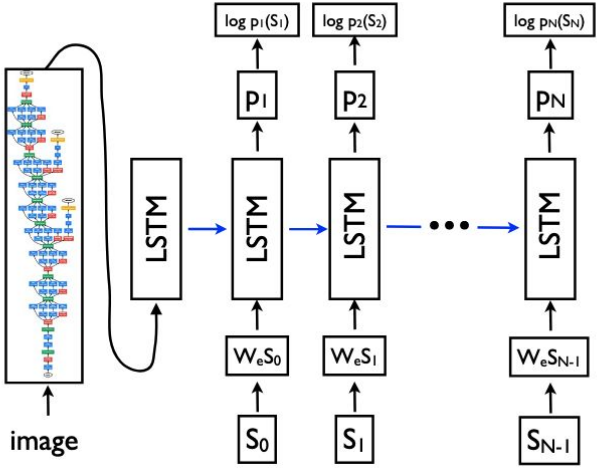

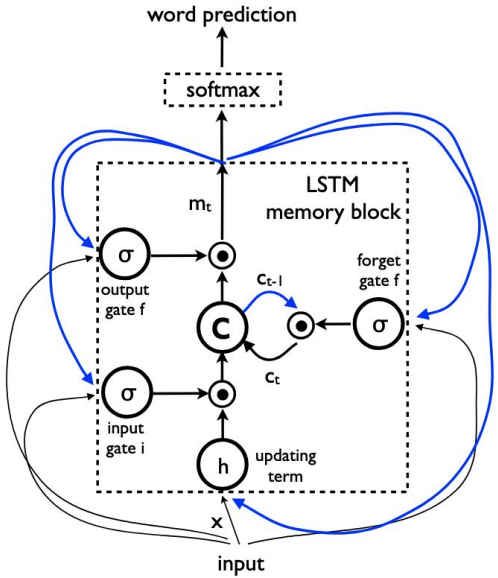

Transformer for Image Captioning (2022)

Принцип такой же как и в Show and tell, но дополняется spatial attention и scale-aware reinforcment.

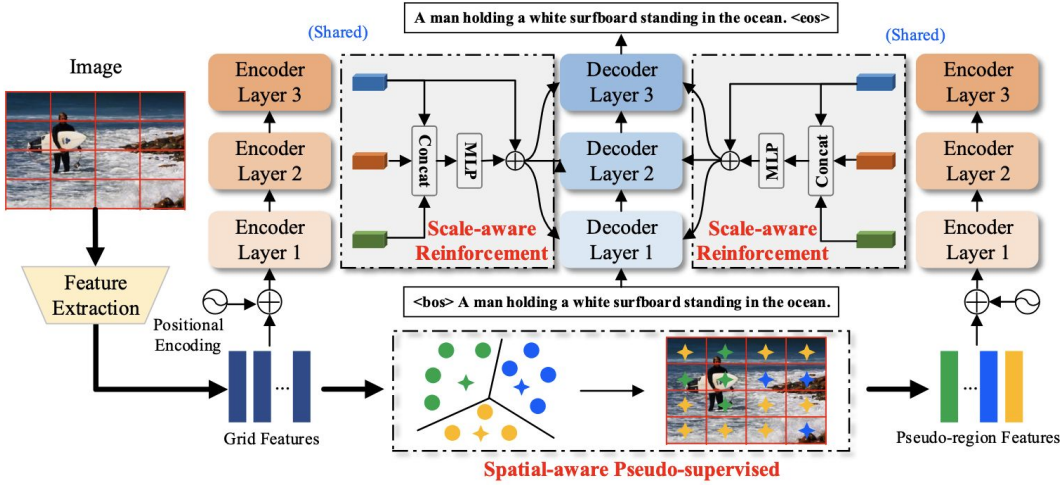

Spatial attention

Проблема: ViT плохо учитывает пространственную структуру изображения.

Решение: создать псевдо-регионы, которые будут похожи на регионы объектов, но без использования детекторов. Это делается через набор обучаемых кластеров c_n.

В итоге получаем вероятность принадлежности каждому кластеру.

После делаем ввешенную сумму эмбеддингов сегмента и получаем предаствление региона изображения.

$$r_{m,n} = \frac{\exp(g_m c_n^T + b_n)}{\sum_{k=1}^{N} \exp(g_m c_k^T + b_k)}$$

c_N – обучаемый кластер

g_m – эмбеддинги сегмента изображения

$$p_n = Norm(\sum_{m=1}^{M} r_{m,n}(g_m - \tilde{c}_n)),$$

Scale aware reinforcement

Идея: использовать информацию со всех уровней encoder трансформера, а не только из последнего слоя.

$$\tilde{G} = [\bar{G}_1, \bar{G}_2, ..., \bar{G}_L]$$

$$G' = (\tilde{G} W_1^T) W_2^T$$

Объединяются признаки со всех слоев, для этого используется 2 обучаемых матрицы.

VLM

Модель, которая может обрабатывать изображения и текст. Такие модели могут использоваться для решения нескольких задач одновременно:

- Image Captioning
- Visual Question Answering
- image-text retrieval
- multimodal reasoning
- multimodal chat

LLaVA 1.0 (2023)

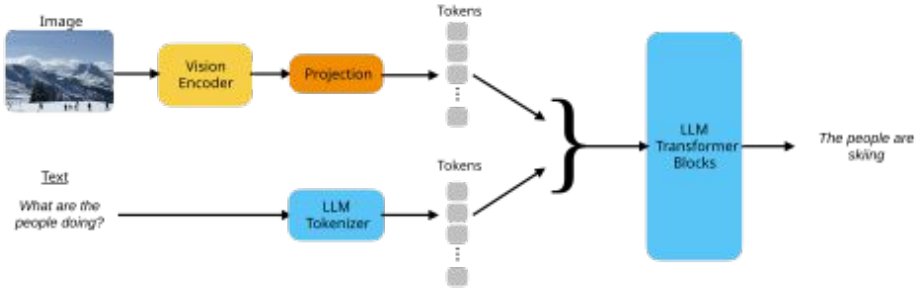
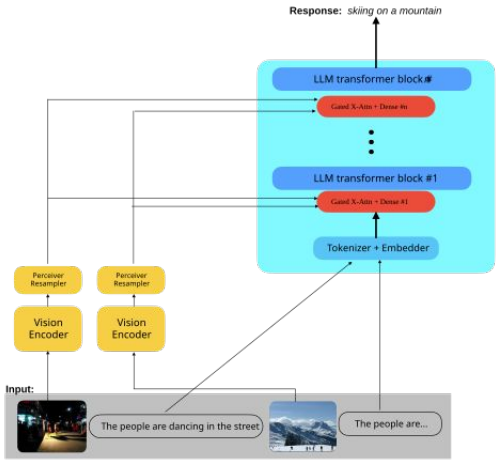
Flamingo (2022)